10．声をモデル化してみよう

- 入出力数の違いによるパターン認識問題の分類


$\longrightarrow (x_1, x_2, \ldots, x_d) \longrightarrow$ 4

1入力1出力の問題


$\mathbf{X}_1 = (x_1, x_2, \ldots, x_d)$
$\mathbf{X}_2 = (x_1, x_2, \ldots, x_d) \longrightarrow$ 不整脈
$\vdots$
$\mathbf{X}_n = (x_1, x_2, \ldots, x_d)$

複数入力1出力の問題

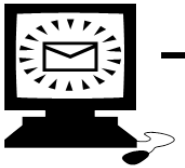
$\longrightarrow (x_1, x_2, \ldots, x_d) \longrightarrow$ 重要? yes
緊急? no
仕事? yes

1入力複数出力の問題

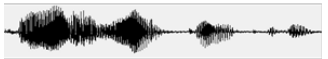
$\mathbf{X}_1 = (x_1, x_2, \ldots, x_d)$
$\mathbf{X}_2 = (x_1, x_2, \ldots, x_d) \longrightarrow$ 今日 は よい 天気 です
$\vdots$
$\mathbf{X}_n = (x_1, x_2, \ldots, x_d)$

複数入力複数出力の問題

音声認識

10.1 連続音声の認識

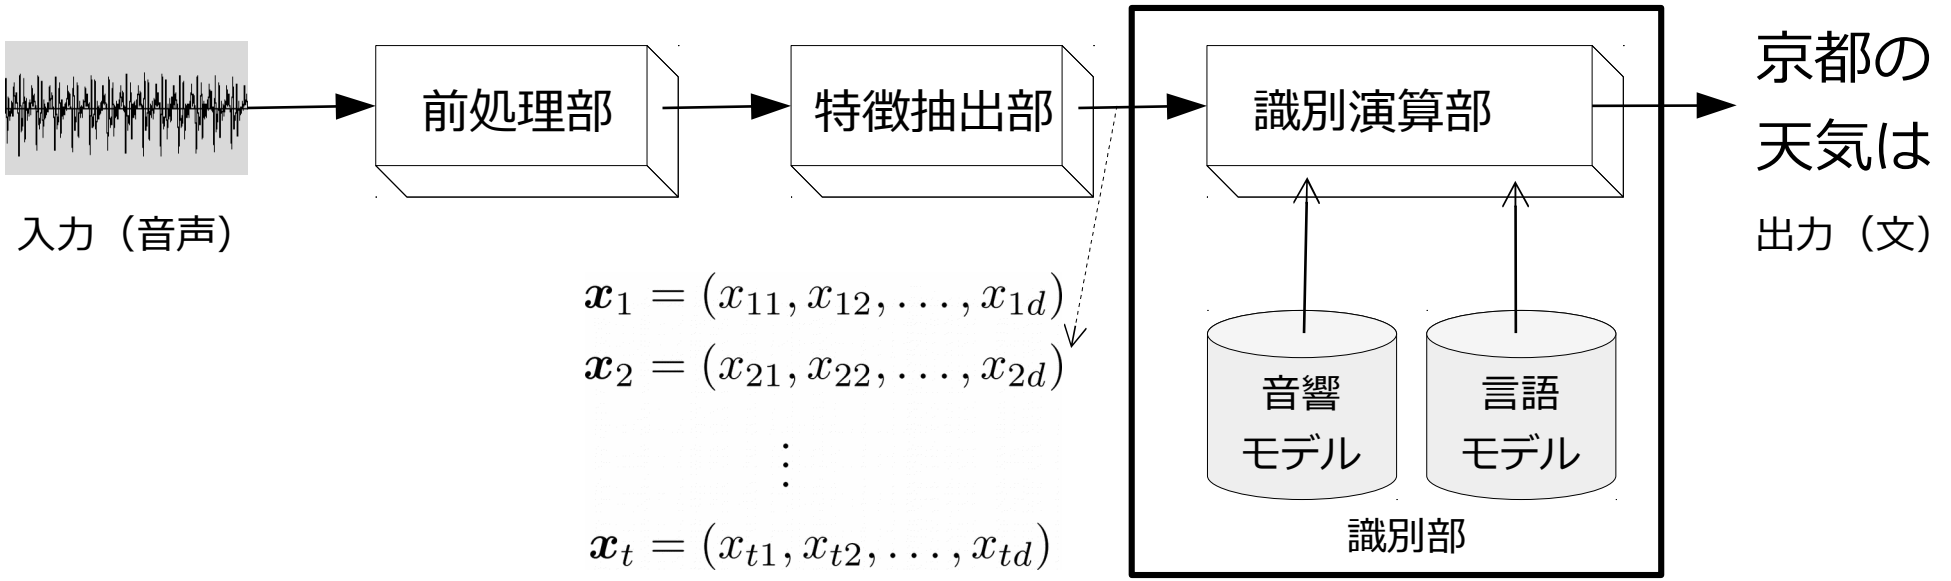
入力（音声）
前処理部
特徴抽出部
識別演算部
京都の
天気は
出力（文）
$\boldsymbol{x}_1 = (x_{11}, x_{12}, \ldots, x_{1d})$
$\boldsymbol{x}_2 = (x_{21}, x_{22}, \ldots, x_{2d})$
$\boldsymbol{x}_t = (x_{t1}, x_{t2}, \ldots, x_{td})$
音響
モデル
言語
モデル
識別部

10.1 連続音声の認識

- 統計的音声認識の定式化
  - 入力系列 $\boldsymbol{x}$ のもとで事後確率を最大にする単語列 $\hat{\boldsymbol{w}}$ を認識結果とする

$$\begin{aligned}\hat{\boldsymbol{w}} &= \arg\max_{\boldsymbol{w}} P(\boldsymbol{w}|\boldsymbol{x}) \\ &= \arg\max_{\boldsymbol{w}} \frac{p(\boldsymbol{x}|\boldsymbol{w})P(\boldsymbol{w})}{p(\boldsymbol{x})} \\ &= \arg\max_{\boldsymbol{w}} p(\boldsymbol{x}|\boldsymbol{w})P(\boldsymbol{w})\end{aligned}$$

ベイズの定理

  - 音響モデル $p(\boldsymbol{x}|\boldsymbol{w})$
  - 言語モデル $P(\boldsymbol{w})$

10.1 連続音声の認識

- 現在の解法
  - 音響モデル $p(\boldsymbol{x}|\boldsymbol{w})$
    - 隠れマルコフモデル (HMM)
    - DNN-HMM 法
  - 言語モデル $P(\boldsymbol{w})$
    - 文法記述
    - n-gram 近似 + 補間法
    - RNN 言語モデル
  - 事後確率最大となる $\hat{\boldsymbol{w}}$
    - ヒューリスティック探索
    - WFST

10.2 音響モデルの作り方

- 音響モデル $p(\boldsymbol{x}|\boldsymbol{w})$ とは
  - *p*(特徴ベクトル系列 | 単語列) を計算するための確率モデル

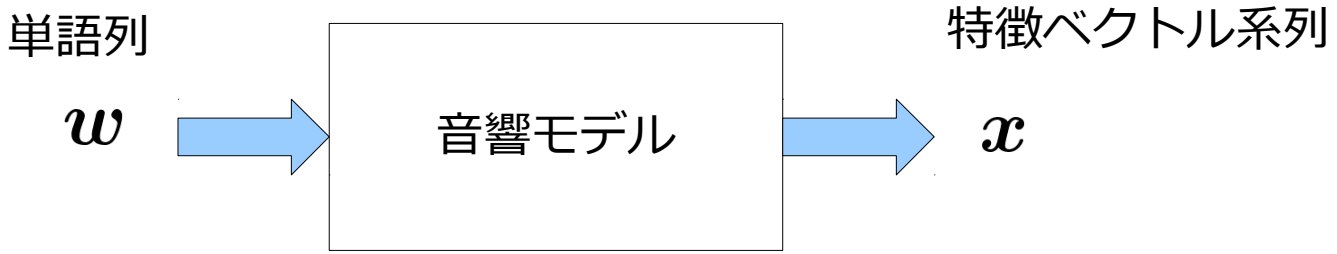

  - まず、単純化のために単語認識問題を扱う
    - 単語は音素の系列で表現されているとする

10.2　音響モデルの作り方

- 設定 1
  - 各音素あたりの特徴ベクトル数が一定
  - 特徴ベクトルを離散値（記号）で近似したときに誤りがない

    → 単語ごとの有限状態オートマトンでモデル化

    – 受理すれば p>0，不受理ならば p=0

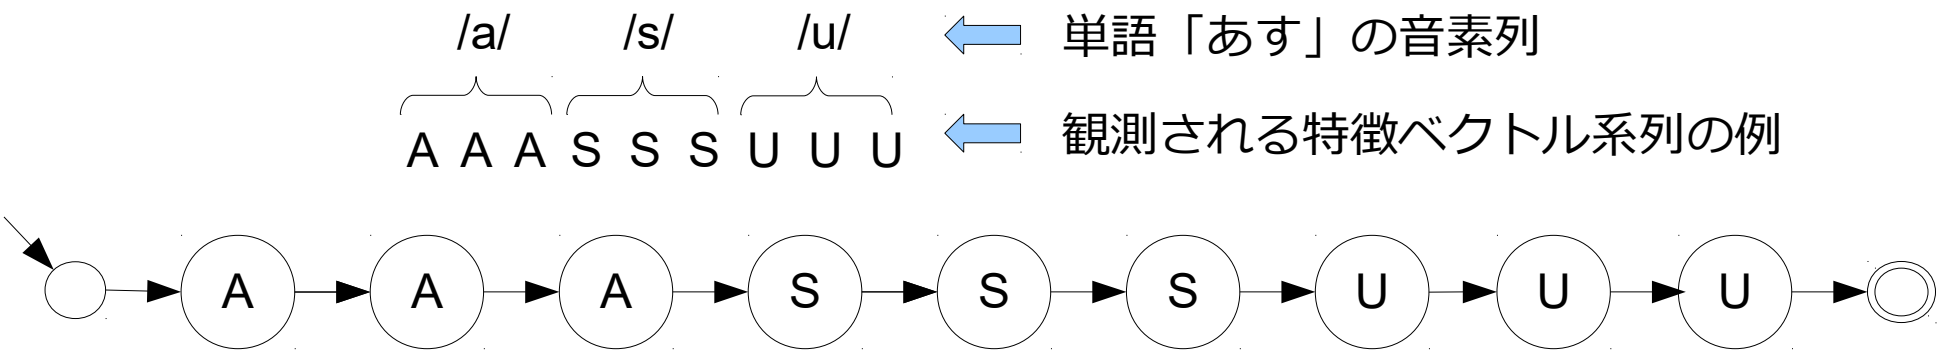

10.2　音響モデルの作り方

- 設定 2
  - 各音素あたりの特徴ベクトル数が一定
  - 特徴ベクトルの近似に誤りがあり得る

    → 単語ごとの確率オートマトンでモデル化
    - 各状態で、全てのシンボルに何らかの生成確率を与える

      p= 各状態における記号の生成確率の積

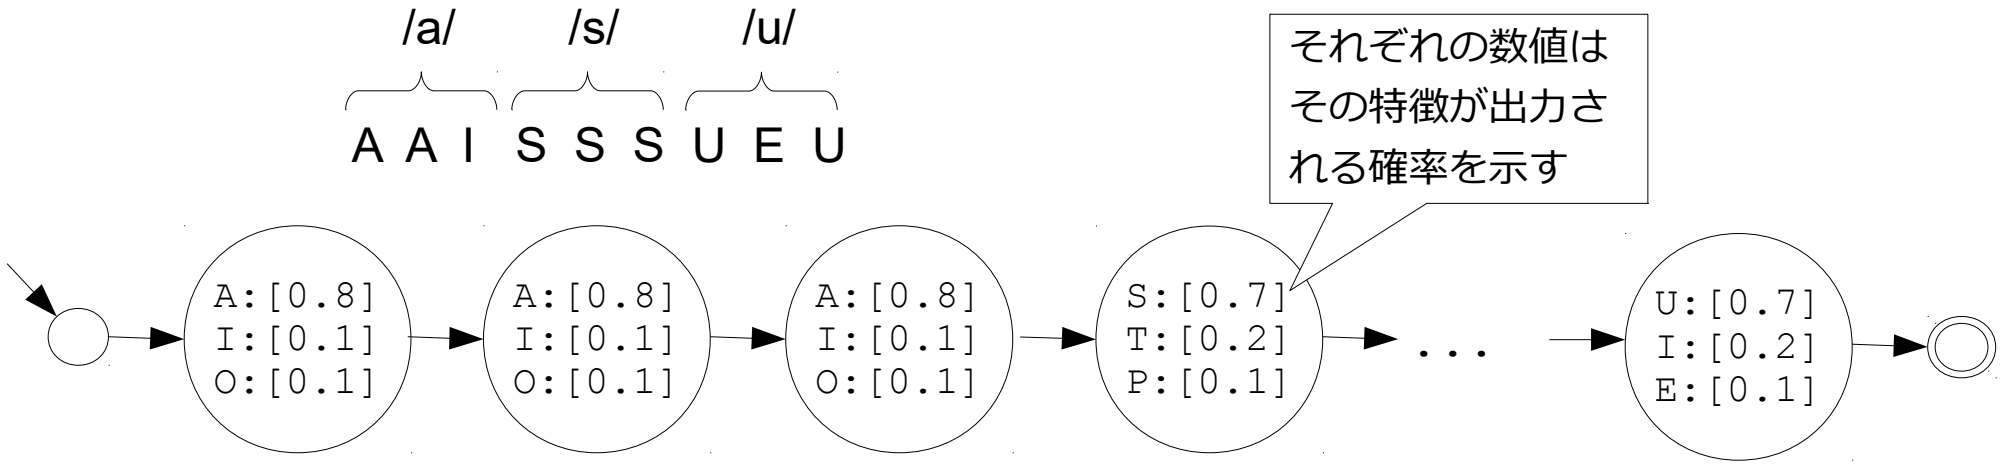

10.2　音響モデルの作り方

- 設定 3
  - 各音素あたりの特徴ベクトル数が不定
  - 特徴ベクトルの近似に誤りがあり得る

    → 非決定性確率オートマトン (=HMM) でモデル化
    - 各状態からの遷移が非決定的かつ確率的

    p= 「各状態における記号の生成確率と遷移確率の積」の可能な遷移に対する和

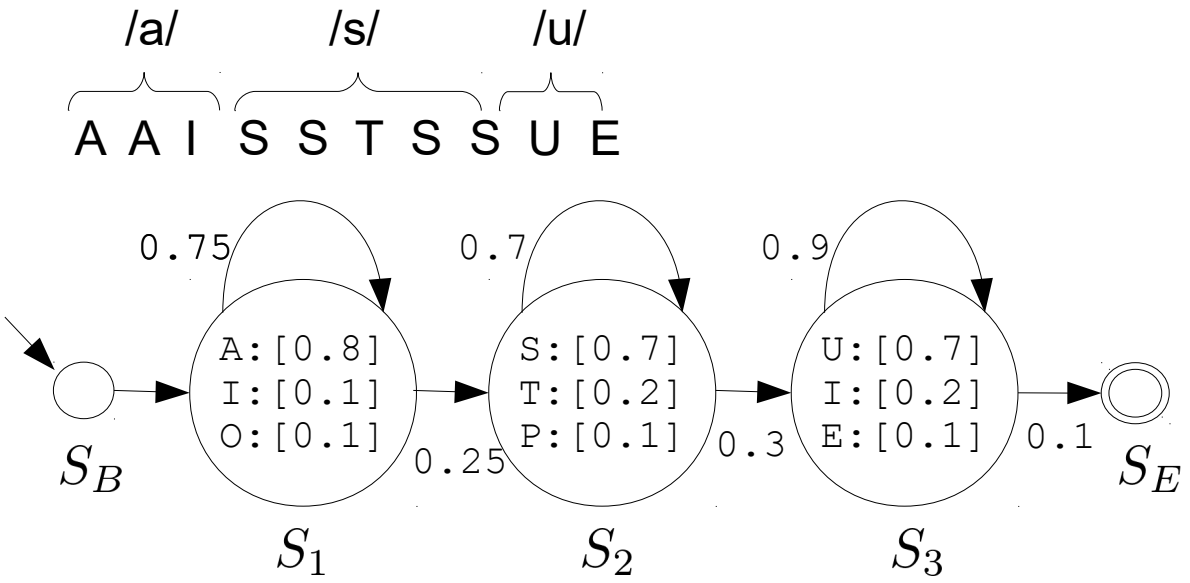

10.2　音響モデルの作り方

- 設定 4
  - 各状態ですべての特徴ベクトルに対して正の確率を割り当てる　→　状態遷移情報が隠れてしまう

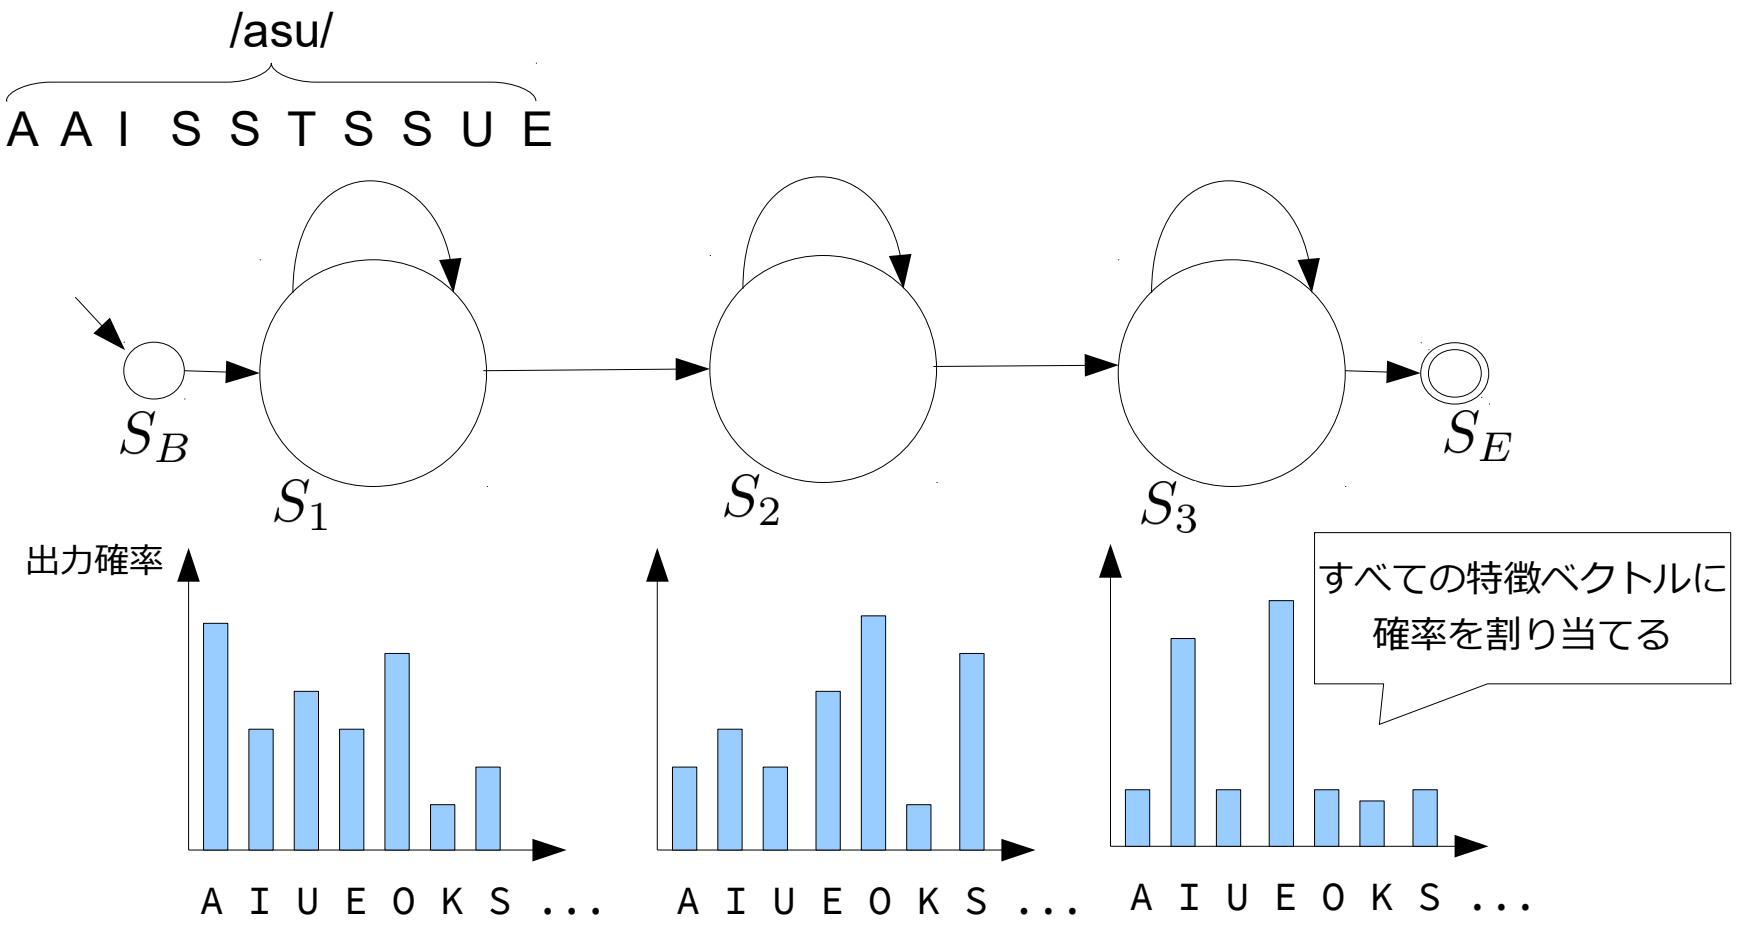

10.2　音響モデルの作り方

- 実際の HMM
  - 各状態での特徴ベクトルの生成確率を混合正規分布で表現

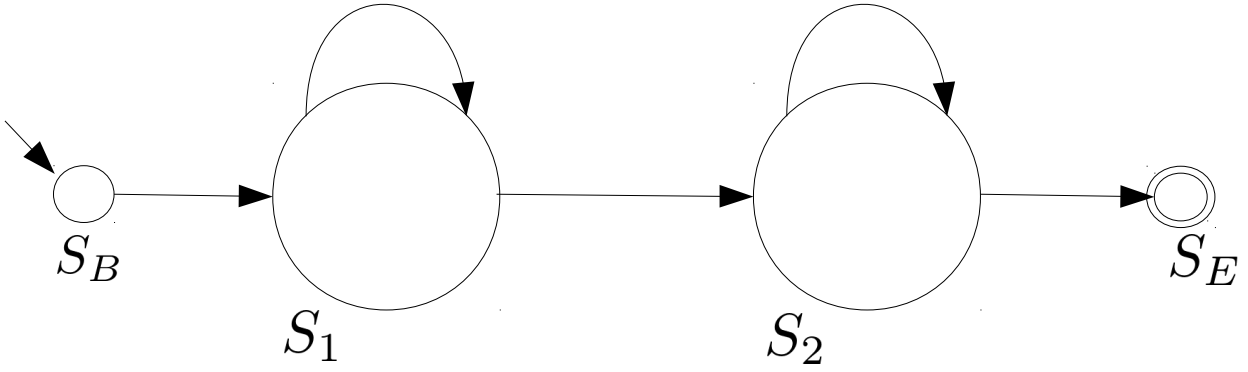

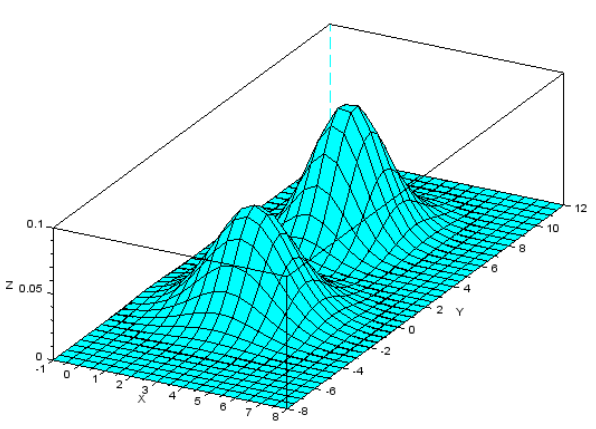

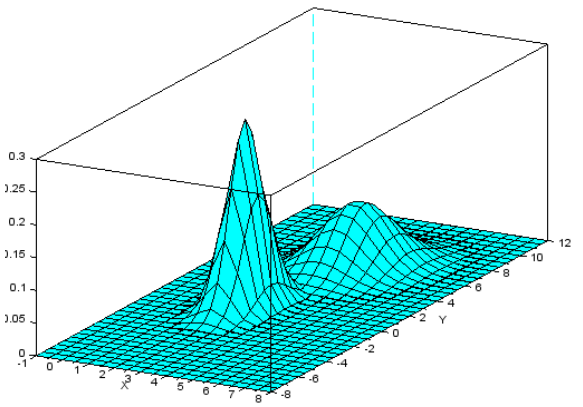

10.4 音響モデルの鍛え方

- HMM の学習
  - 離散記号：最尤推定
  - 連続値：パラメトリックな学習
    - 確率密度関数の平均と分散を学習する
- 学習における問題点
  - 学習データに対して状態遷移系列がわからない

10.4 音響モデルの鍛え方

- 状態遷移系列が既知であれば
  - 状態遷移確率
    - 状態からの遷移を数え上げることによって学習可能
  - 信号出力確率
    - 状態ごとに平均・分散を計算することで学習可能

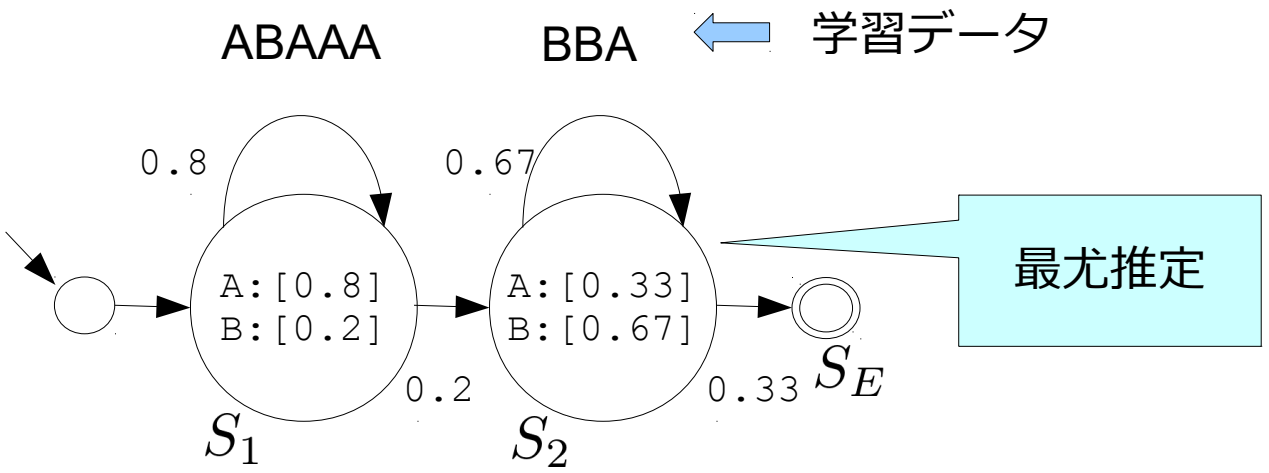

10.4 音響モデルの鍛え方

- 状態遷移系列の確率がわかっていれば
  - 学習結果の重み付き加算

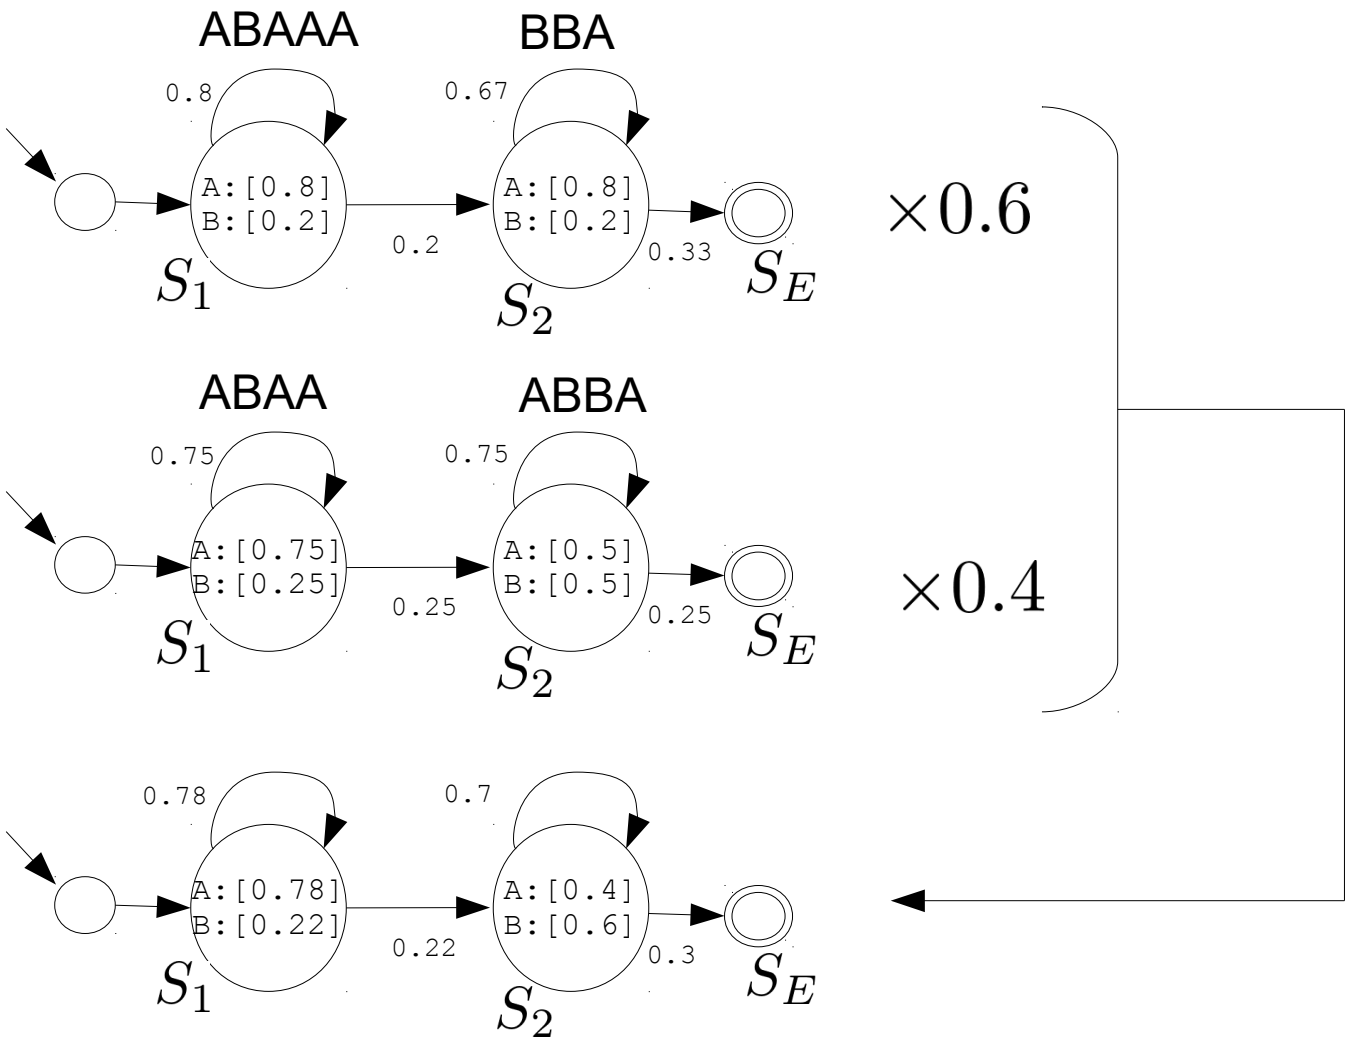

10.4 音響モデルの鍛え方

- Baum-Welch 法による HMM の学習
  - HMM のパラメータを適当な初期値に設定
  - E(Expectation) ステップ
    - 学習データ (入力) に対して、状態遷移を与えたときの確率を現在の HMM を用いて計算
    - それを全ての可能な状態遷移について求める (実際は d 動的計画法を用いて効率的に計算)
  - M(Maximization) ステップ
    - E ステップで得られたデータから HMM のパラメータを最尤推定
  - E,M ステップをパラメータの変化量が一定値以下になるまで繰り返し

ディープニューラルネットを用いた音声認識

DNN-HMM 法

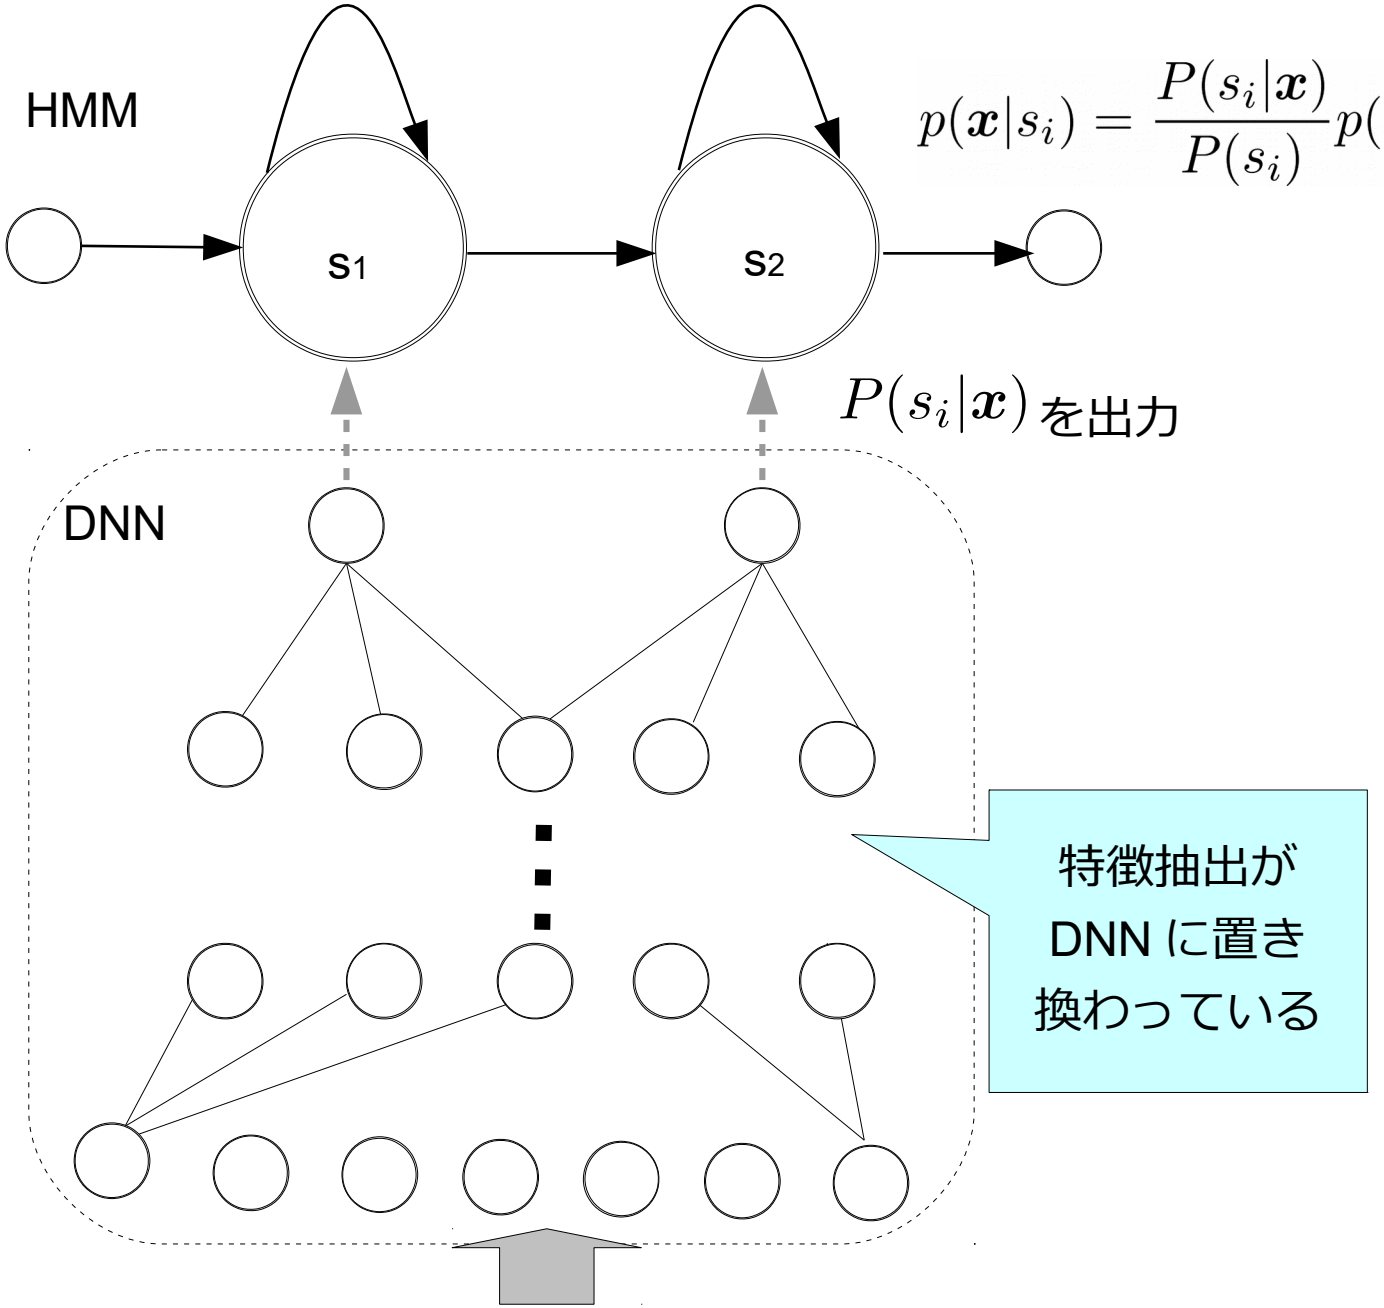

12. 文法規則を書いてみよう

- 言語モデルとは
  - P(単語列) を計算するための確率モデル
- 2 つのアプローチ
  - 文法記述
    - 単語から文を構成する規則を文法として記述
    - 文法が受理する単語列 W に対して *P(W)>0*, そうでなければ *P(W)=0*
  - 統計的言語モデル
    - 大量のコーパスを元に確率を推定
    - $P(W) = P(w_1, \ldots, w_n)$ を何らかの近似で計算

12.2　タスクから文法を設計する

- 例題タスク
  - 新幹線の切符自動販売機の音声インタフェース
  - 機能
    - 乗車区間を指定できる
    - 席の種類を指定できる
    - 枚数を指定できる
  - 例文
    - 「東京から京都まで自由席 1 枚」
    - 「名古屋から品川までグリーン席 3 枚」

12.2 タスクから文法を設計する

- 文法 = 出現可能な単語列パターンの定義
  - 文のパターンを句の並びで定義
    - $ 文　→　$ 区間　$ 席種　$ 枚数
    - 例）東京から京都まで自由席 1 枚
  - 句のパターンを単語または単語集合の並びで定義
    - $ 区間　→　$ 駅名　から　$ 駅名　まで
  - 認識対象とする単語集合（ = 語彙）を定義
    - $ 駅名→東京 | 品川 | 新横浜 | …
    - $ 席種→グリーン席 | 指定席 | 自由席

12.4 Julius での文法記述

- Julius とは
  - フリーの音声認識エンジン
  - 有限状態文法 (DFA) に基づいて，与えられた文法規則の元で入力音声に対して最尤の単語系列を探しだす
  - 統計的言語モデル（ 13 章）も利用可能

12.4 Julius での文法記述

- Julius の文法
  - grammar ファイル：構文制約をカテゴリを終端規則として記述する
  - yomi ファイル：カテゴリごとに単語の表記と読みを登録する

12.4 Julius での文法記述

- grammar ファイル

```
# 文
S: NS_B KUKAN ZASEKI MAISUU NS_E
# 区間
KUKAN: EKIMEI KARA EKIMEI MADE
# 駅名
EKIMEI: TIMEI EKI
EKIMEI: TIMEI
# 枚数
MAISUU: SUUJI MAI
```

で始まる行は
コメント

NS_B、NS_Eはそれぞれ文頭・文末の無音区間

12.4 Julius での文法記述

- yomi ファイル

```
%TIMEI
東京　　とーきょー
品川　　しながわ
新横浜　しんよこはま
名古屋　なごや
京都　　きょーと
新大阪　しんおーさか
%SUUJI
1　いち
2　に
3　さん
%ZASEKI
グリーン席　ぐりーんせき
指定席　してーせき
自由席　じゆーせき
```

```
%KARA
から　　から
%MADE
まで　　まで
%EKI
駅　えき
%MAI
枚　まい
% NS_B #  文頭無音
<s> silB
% NS_E #  文末無音
</s> silE
```

% で始まる行は
非終端記号

13 章　統計的言語モデルを作ろう

- 統計的言語モデルとは
  - P(単語列) を言語統計から計算
  - 正しい文には高い確率を与えたい
  - 誤っている文には低い確率を与えたい

13.1 文の出現確率の求め方

- 単語列 $\boldsymbol{w}$ の生成確率

$$
\begin{aligned}
P(\boldsymbol{w}) &= P(w_1, \ldots, w_n) \\
&= P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \ldots P(w_n|w_1, \ldots, w_{n-1})
\end{aligned}
$$

- $P(w_i|w_1, \ldots, w_{i-1})$ の近似
  - 1- グラム ～ $P(w_i)$
  - 2- グラム ～ $P(w_i|w_{i-1})$
  - 3- グラム ～ $P(w_i|w_{i-2}, w_{i-1})$

13.2 N- グラム言語モデル

- N- グラム言語モデルとは
  - 単語の生起を (N-1) 重マルコフ過程で近似したモデル
  - ある時点での単語の生起確率は直前の N-1 単語にのみ依存すると仮定
  - 3- グラムによる単語列 $w_1, \ldots, w_n$ の生成確率

$$P(w_1, \ldots, w_n) = P(w_1)P(w_2|w_1)\prod_{k=3}^{n} P(w_k|w_{k-2}, w_{k-1})$$

13.2 N- グラム言語モデル

1.コーパスを準備する

- 大量の電子化された文章を集める

  例）新聞記事 DVD-ROM, Web, etc.

2.単語に区切る

- 英語の場合：空白で区切る
- 日本語の場合：形態素解析が必要

3.条件付き確率を求める

- スパースネスの問題を解決したうえで $P(w_i|w_{i-2}, w_{i-1})$ を求める

13.2 N- グラム言語モデル

- 3- グラム確率の推定
  - 最尤推定を用いる
  - C(w): 単語列 w の出現回数

$$f(w_i|w_{i-2}, w_{i-1}) = \frac{C(w_{i-2}, w_{i-1}, w_i)}{C(w_{i-2}, w_{i-1})}$$

  - $P(w_i|w_{i-2}, w_{i-1}) = f(w_i|w_{i-2}, w_{i-1})$ とするとスパースネスの問題が生じる
    - 妥当な単語列であっても偶然コーパスに出現しなければ 3- グラムの確率が 0 になる
    - 補間法、スムージングなどで対処

ニューラルネットワーク言語モデル

- フィードフォワード型
  - 過去 N 単語から次単語の確率分布を求める

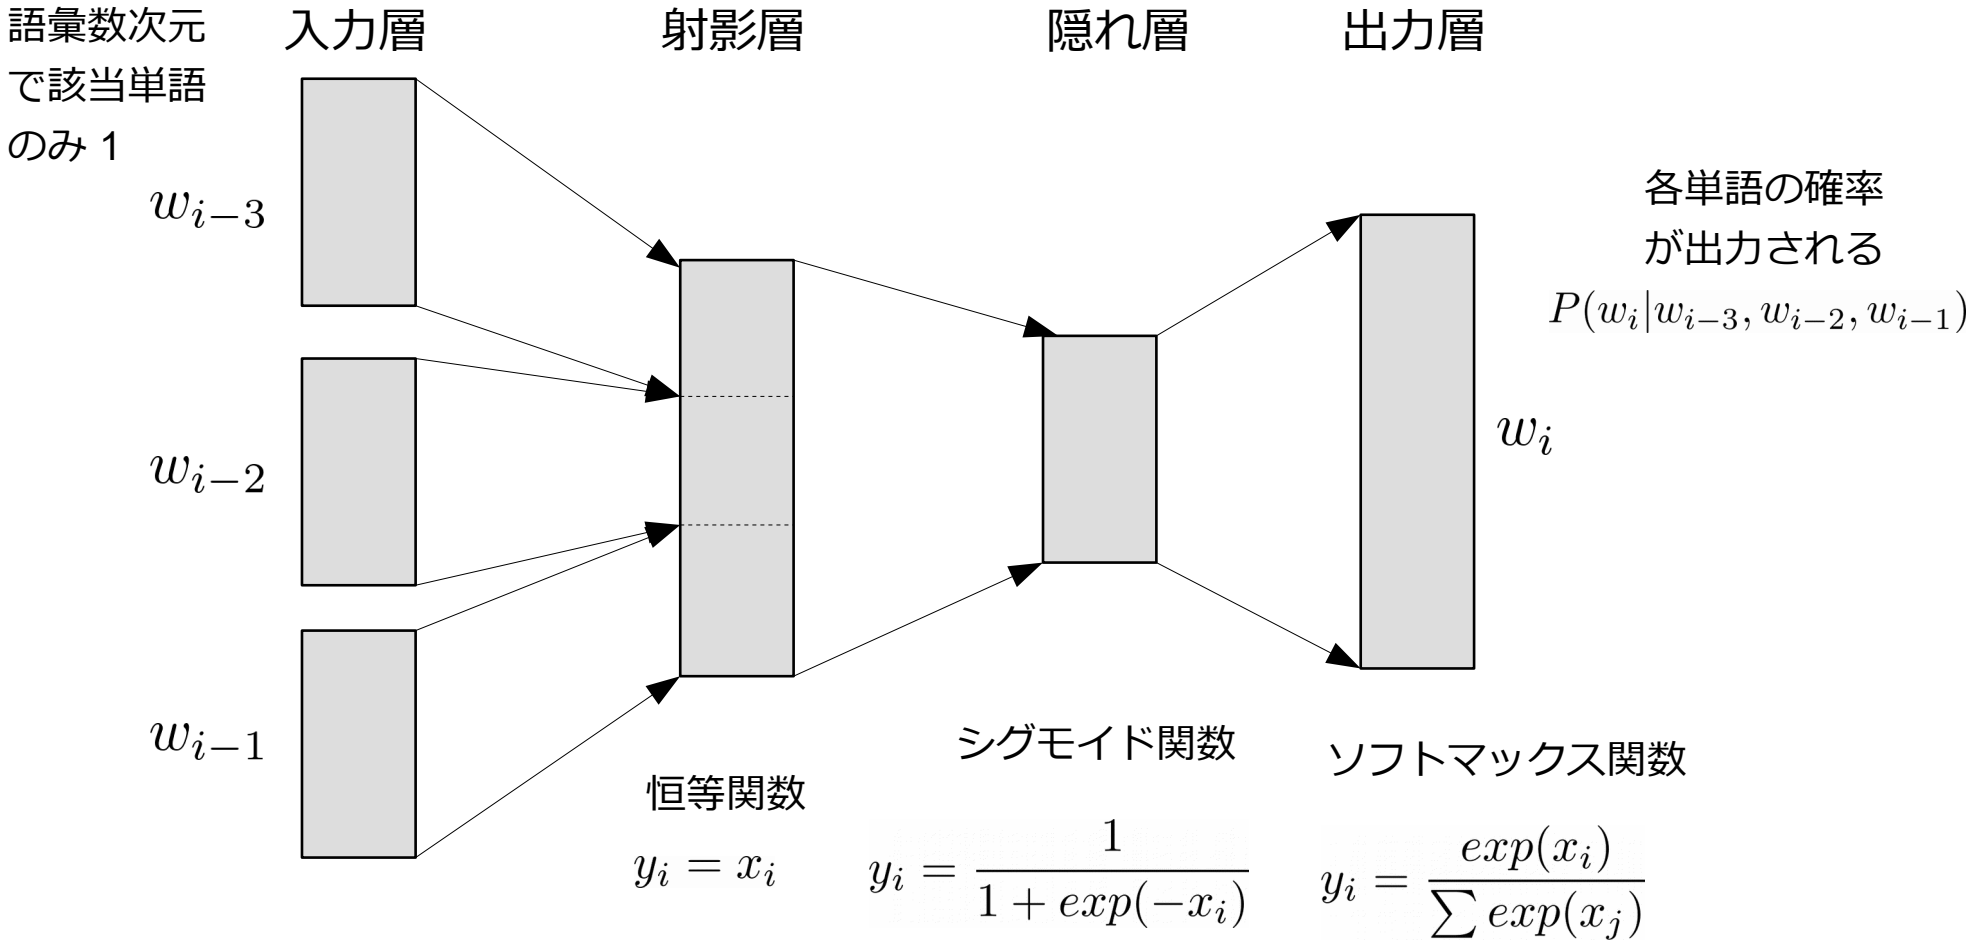

ニューラルネットワーク言語モデル

- リカレント型
  - フィードバックで仮想的にすべての履歴を表現

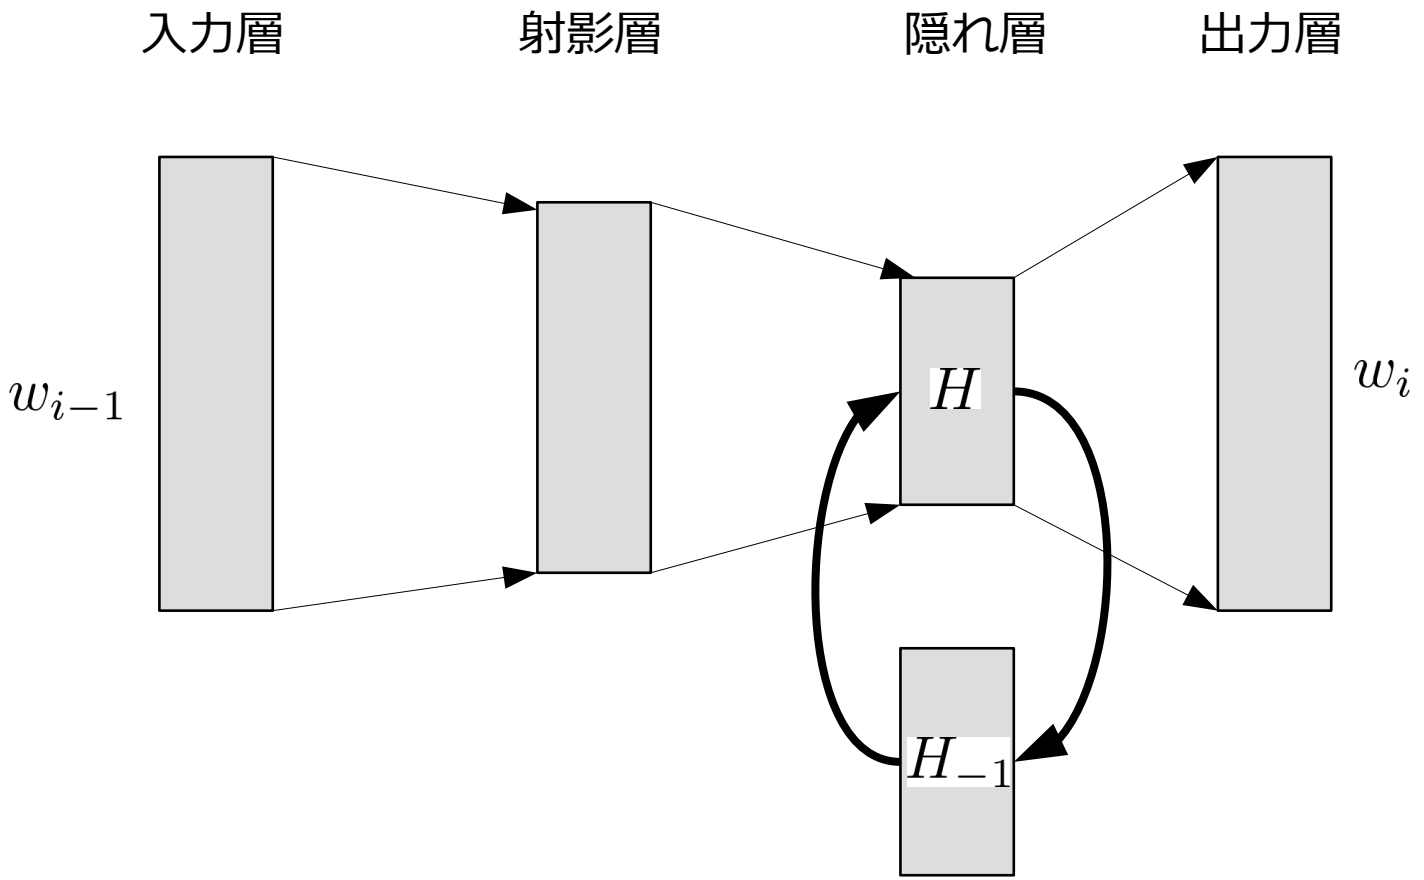

14. 連続音声認識に挑戦しよう

- 音声認識の原理

$$\hat{\boldsymbol{w}} = \arg\max_{\boldsymbol{w}} P(\boldsymbol{w}|\boldsymbol{x}) = \arg\max_{\boldsymbol{w}} P(\boldsymbol{x}|\boldsymbol{w})P(\boldsymbol{w})$$

  - 入力 $\boldsymbol{x}$ のもとで事後確率 $P(\boldsymbol{w}|\boldsymbol{x})$ を最大にする単語列 $\hat{\boldsymbol{w}}$ を認識結果とする
  - $P(\boldsymbol{x}|\boldsymbol{w})$: 音響モデル ...HMM を用いて計算
  - $P(\boldsymbol{w})$: 言語モデル ...N-gram を用いて計算
- 問題点
  - 大語彙（数千語以上）の場合、全ての可能な $\boldsymbol{w}$ をリストアップすることは不可能

14.1 音声認識における探索

- 探索の導入
  - 膨大な候補から解になりそうな部分のみに絞る

- 解の絞り方
  - 探索幅を制限する ... ビームサーチ
  - 評価値の高い候補を優先する
    ... ヒューリスティックサーチ
  - 探索空間を静的に展開し、最適化 ...WFST

ビームサーチ

- 探索幅（ビーム）の導入

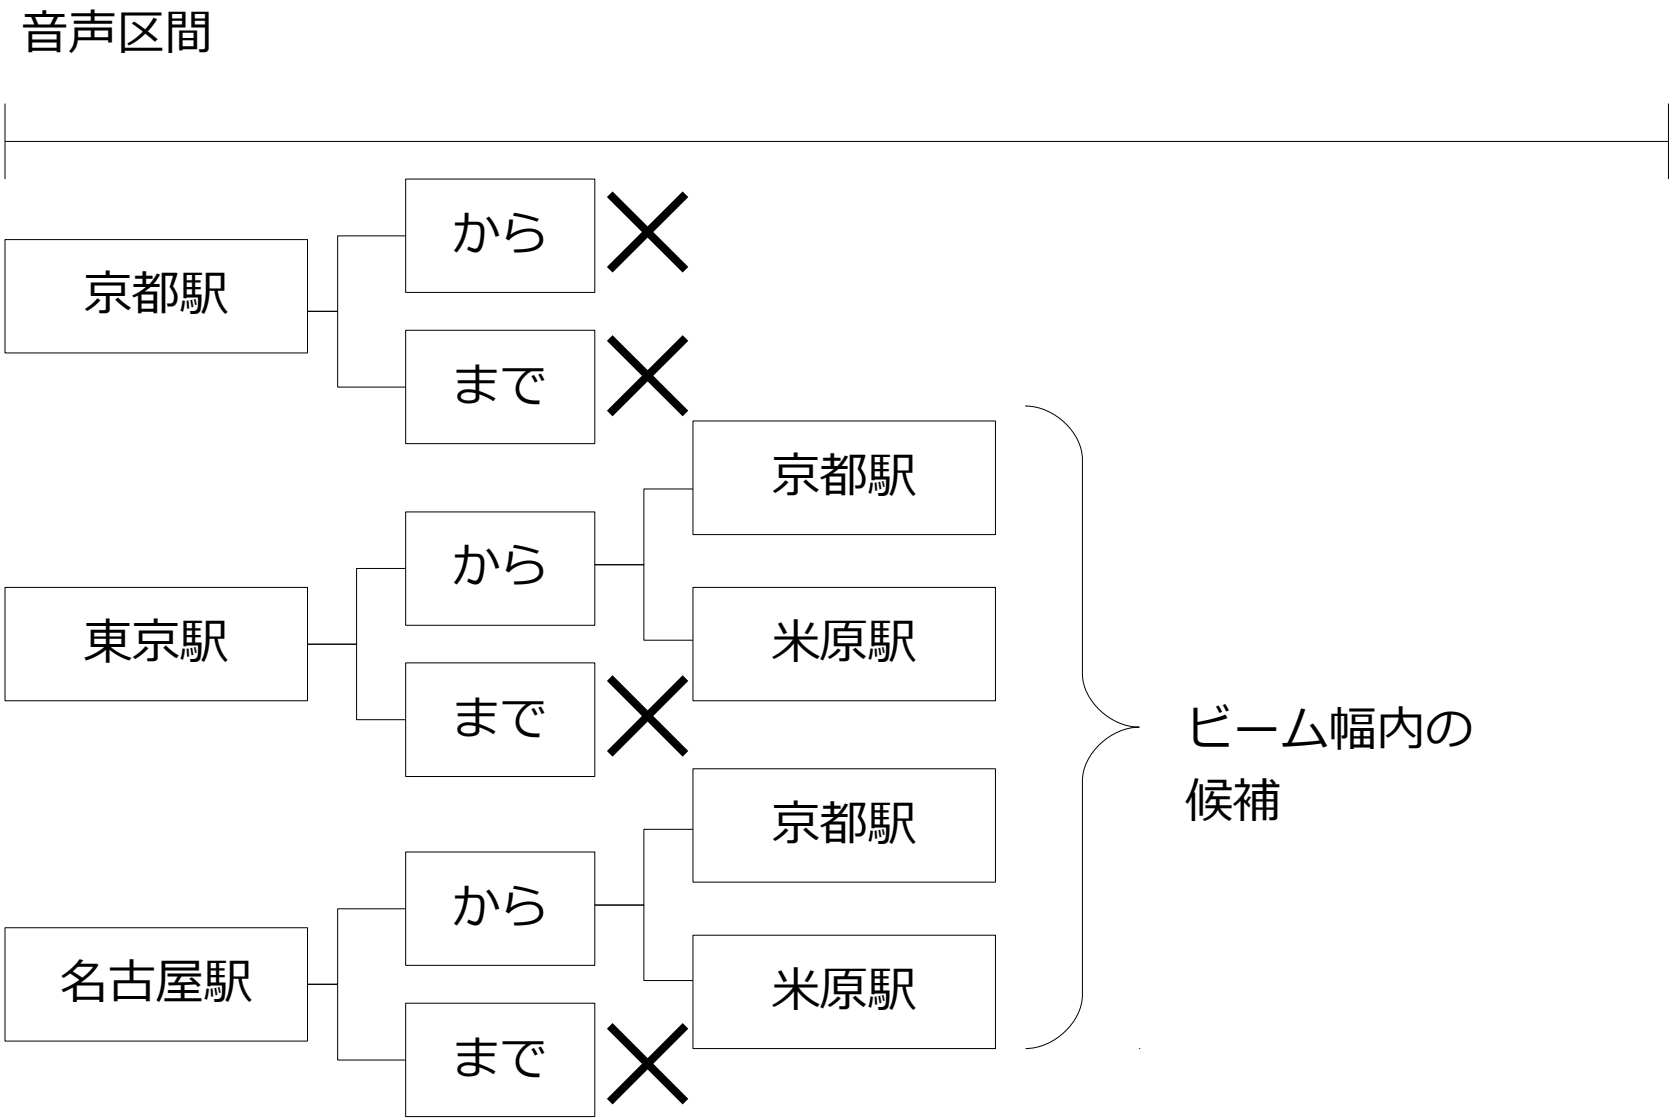

ヒューリスティックサーチ

- ヒューリスティックサーチとは
  - 各候補の**今後の**スコアを予測し、高い順に探索

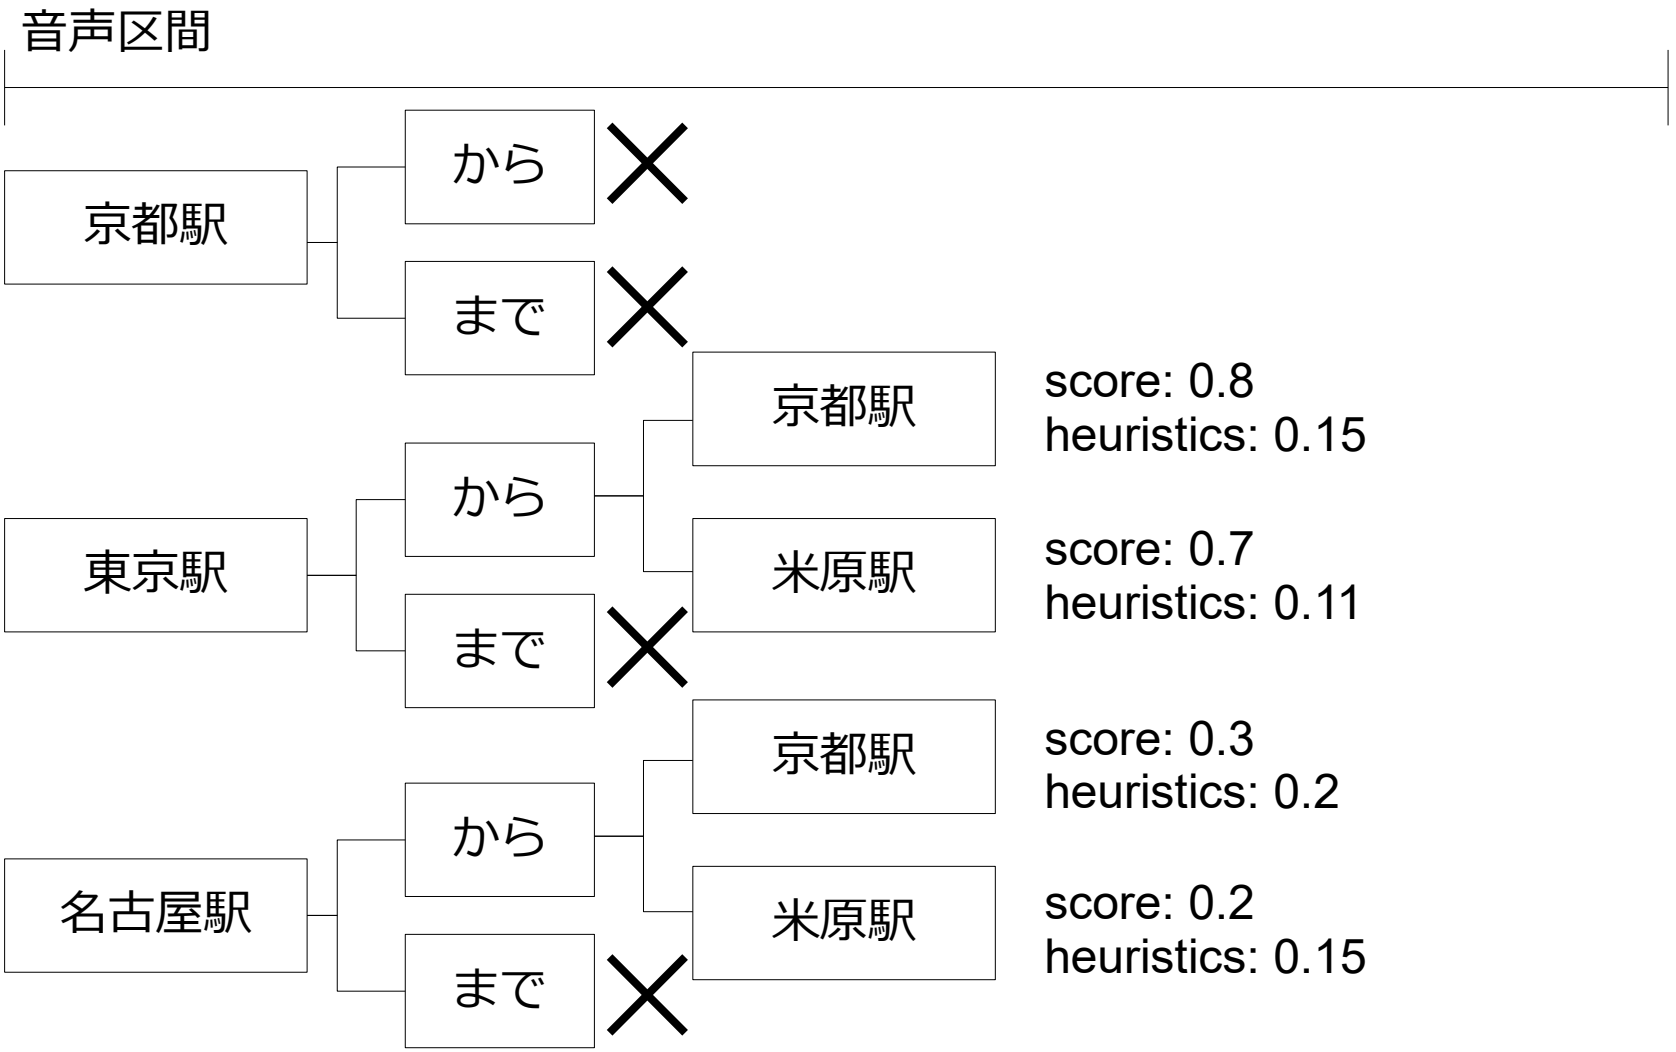

ヒューリスティックサーチ

- Julius における 2 パスサーチ
  - 第 1 パス（フレーム同期ビーム探索）
    - 言語モデルは 2 グラム
    - 単語間の音素変形は考慮しない
    - 出力は単語トレリス（言語モデルスコアの公平な利用）
  - 第 2 パス（スタックデコーディング）
    - 第 1 パスの結果を逆方向に見てヒューリスティックスとする
    - 言語モデルは 3 グラム
    - 単語間にも triphone を適用

WFST によるデコード

- WFST とは
  - Weighted Finite State Transducer （重み付き有限状態トランスデューサ）
  - 記号列を入力し、別の記号列と重みを出力

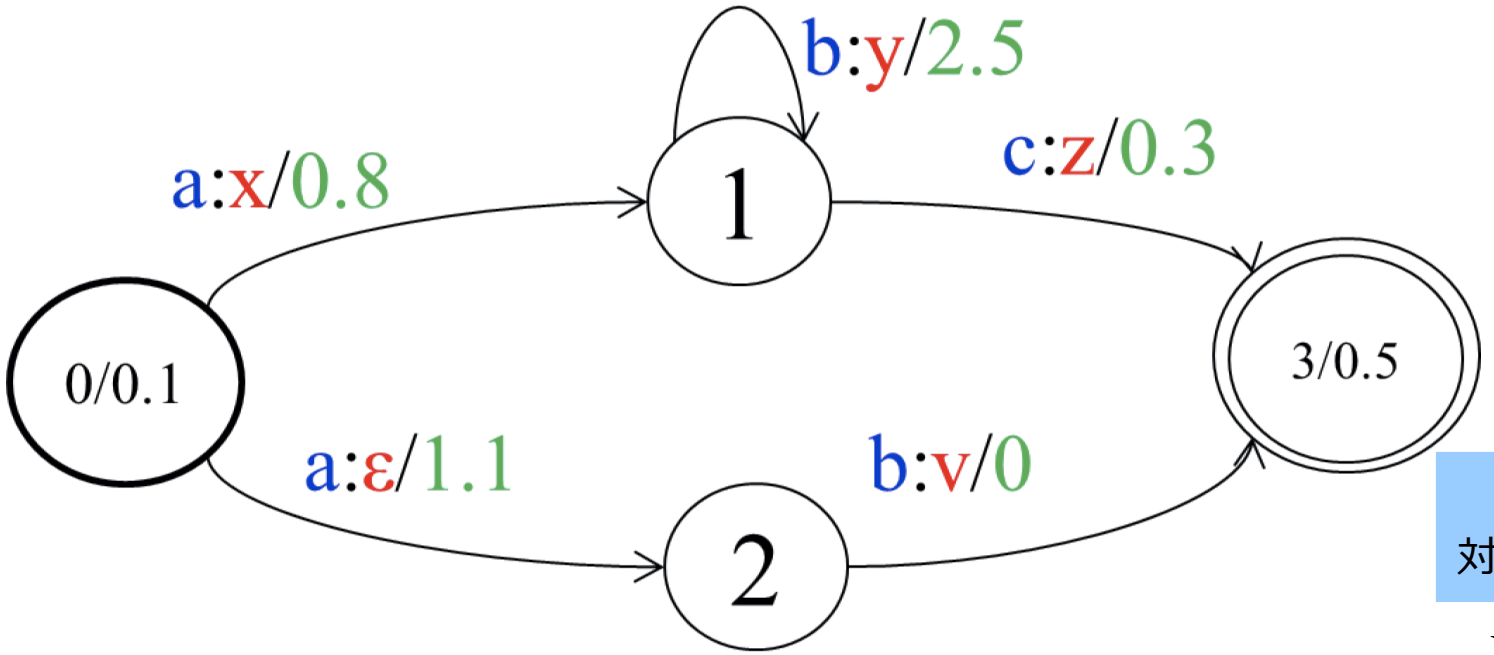

入力 ac に
対する出力は？

xz+0.0012

WFST によるデコード

- WFST によるデコードのアイディア
  - 音声認識に用いる確率モデル（ HMM 、単語辞書、言語モデルなど）は WFST で表現可能
  - 記号列 A を記号列 B に変換する WFST1 と、記号列 B を記号列 C に変換する WFST2 を合成すると、記号列 A を記号列 C に変換する WFST になる
    - ただし、状態数は組み合わせ的に増える
  - WFST には、 FSA と同様、決定化・最小化のアルゴリズムが存在する

WFST によるデコード

- 各種モデルの WFST への変換

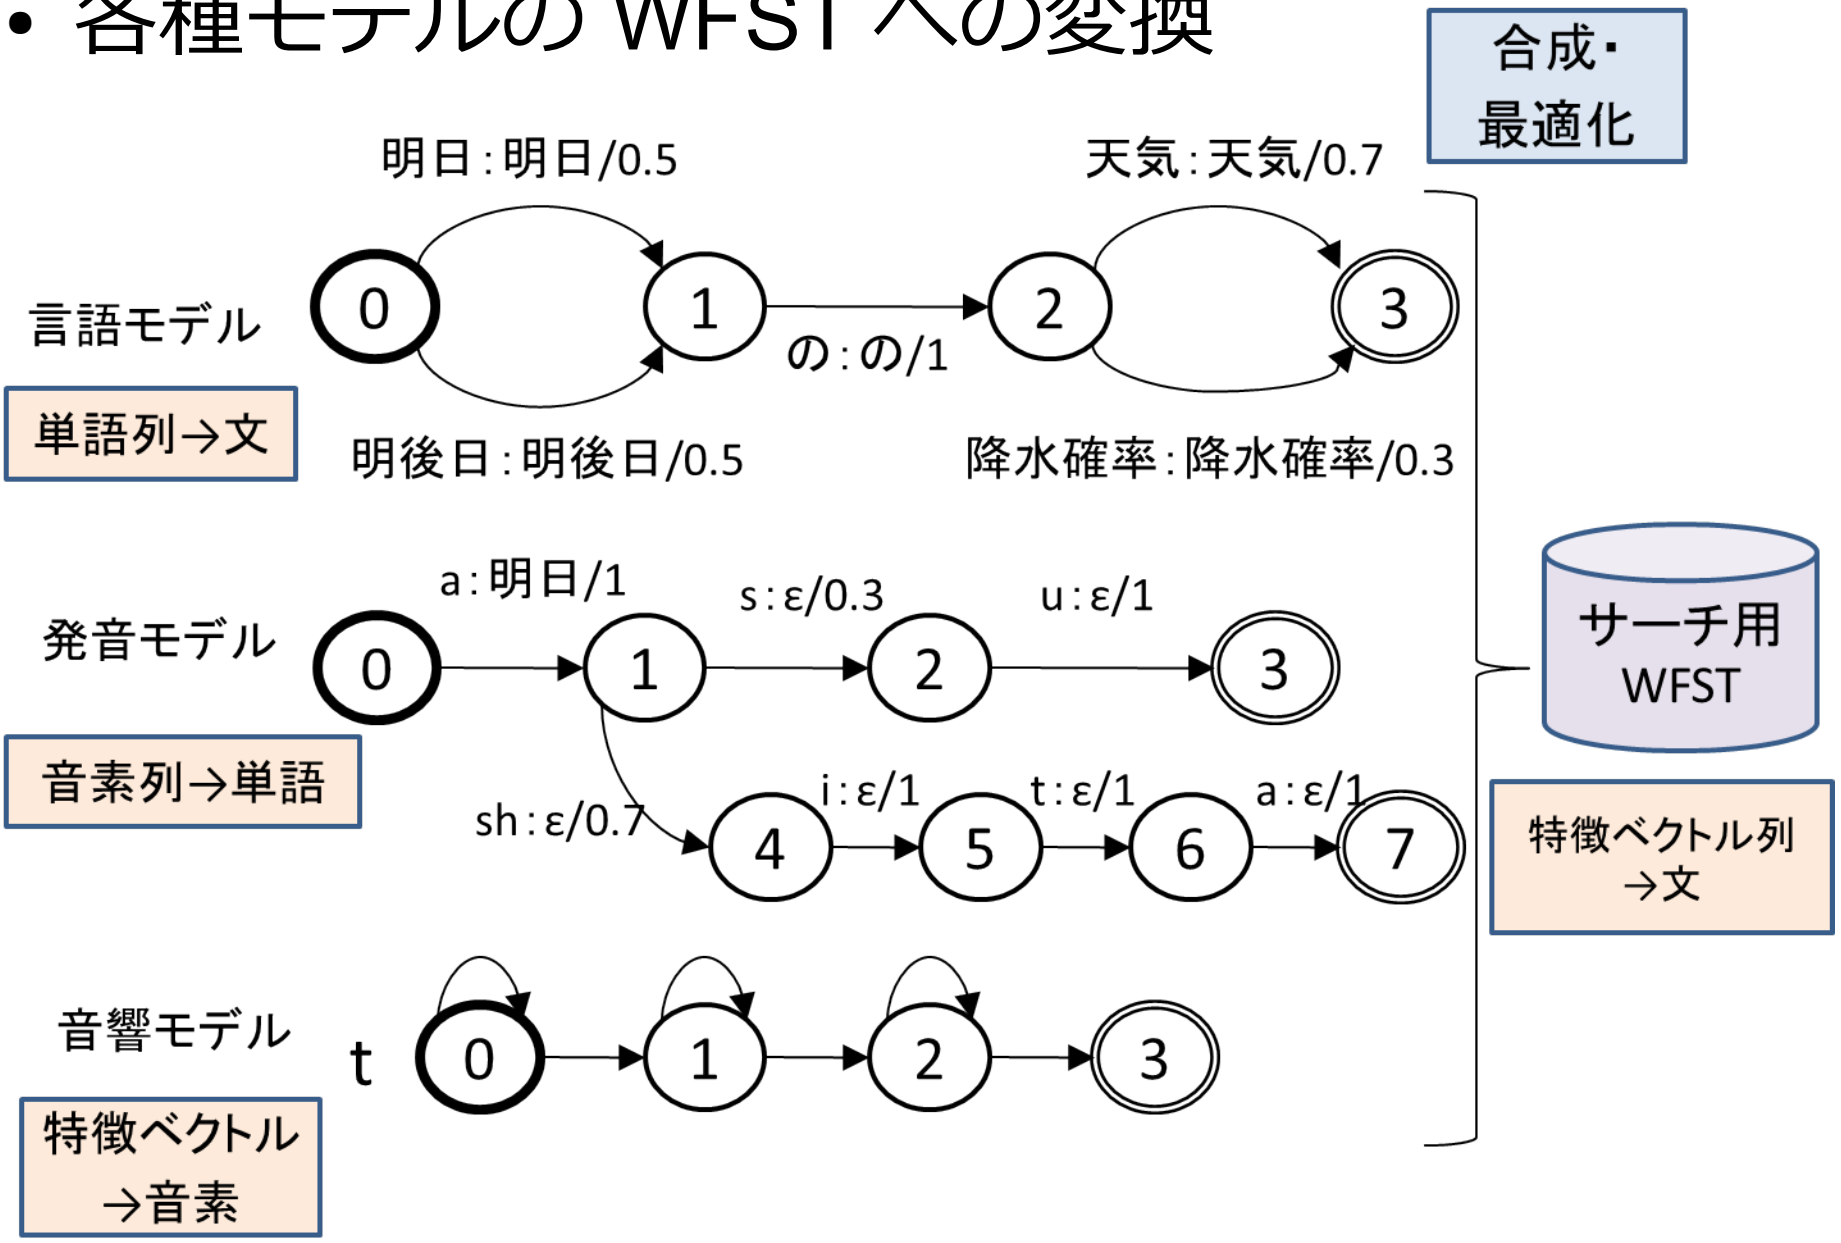

15 章　会話のできるコンピュータを目指して

- 音声対話システムの構成

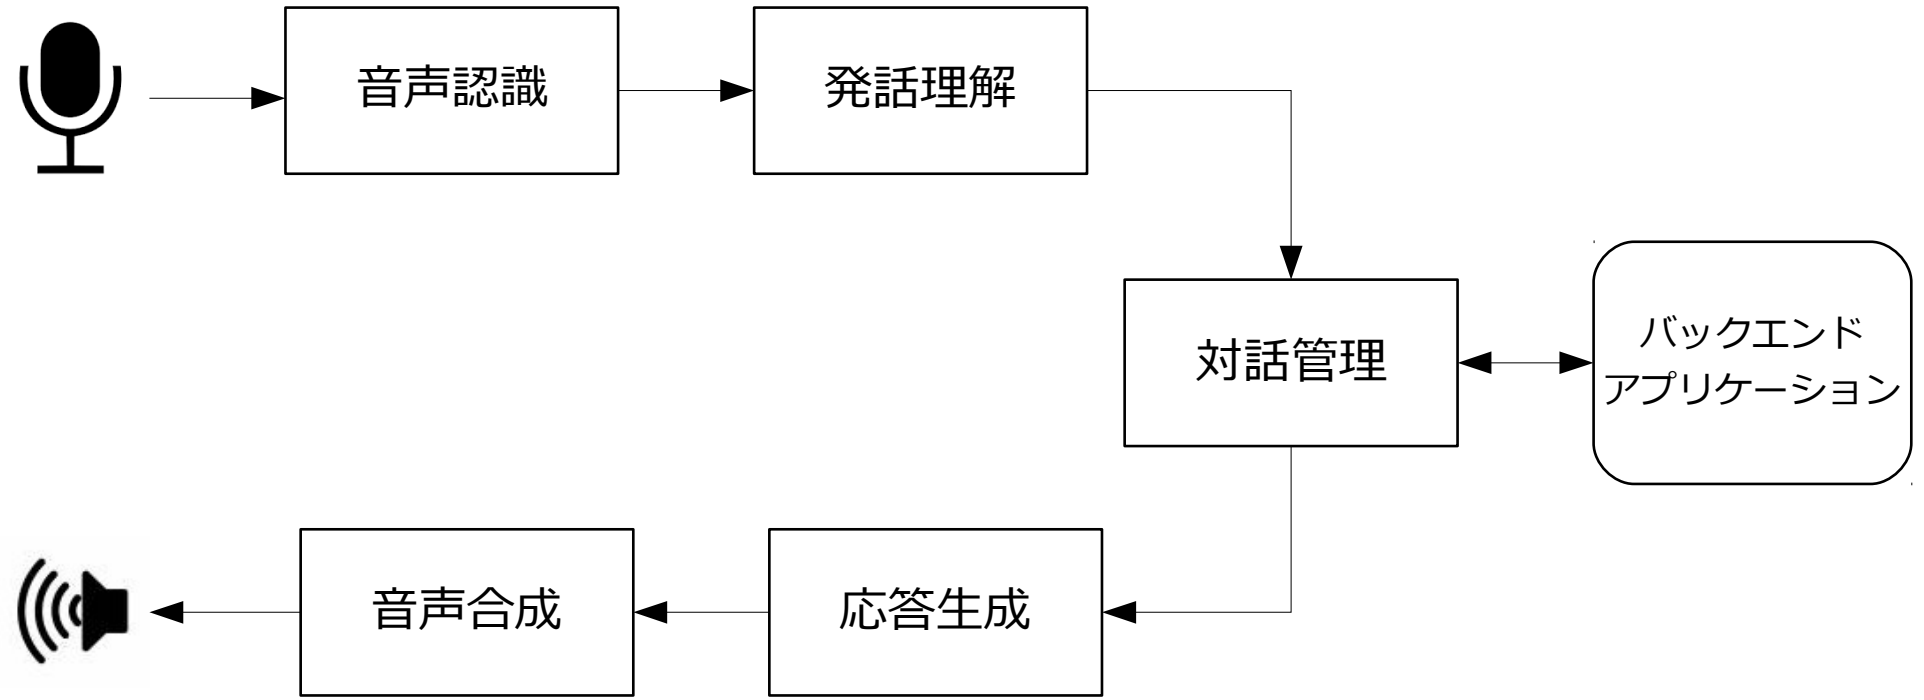

有限状態オートマトンによる対話管理

- 有限状態オートマトン（ FSA ）による対話のモデル化
  - 状態：システム発話
  - 入力：ユーザ発話　or　イベント
  - 遷移規則：ユーザ発話のタイプやイベントの種類によって遷移先を変更

対話システム作成ツール

- MMDAgent
  - FST による対話記述
  - 入力：イベント
    - 音声認識結果
    - 合成音声出力終了
    - タイマー
  - 出力：コマンド
    - 合成音声、動作、画像の出力
    - web ページの表示

MMDAgent の対話記述 -FST-

- 有限状態トランスデューサによる対話記述

現在の状態　遷移後の状態　入力イベント　出力コマンド

1　41　RECOG_EVENT_STOP| 自己紹介

SYNTH_START|...

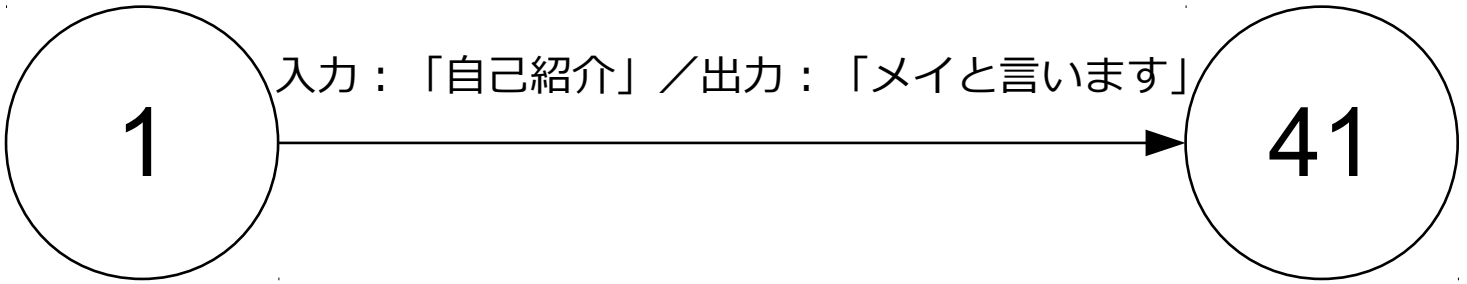

MMDAgent の対話記述

- 入力イベント

イベント名	内容
RECOG_EVENT_STOP	音声認識終了
SYNTH_EVENT_STOP	合成音声出力終了
TIMER_EVENT_STOP	タイマー終了
VALUE_EVENT_EVAL	変数値の評価

MMDAgent の対話記述

- 出力コマンド

コマンド名	内容
SYNTH_START	合成音声出力
MOTION_ADD	エージェント動作出力
TIMER_START	タイマー開始
VALUE_EVAL	変数評価
EXECUTE	外部コマンド実行

MMDAgent の対話記述

- 記述例

```
1  41 RECOG_EVENT_STOP|自己紹介 SYNTH_START|mei|mei_voice_normal|メイと言います.
1  41 RECOG_EVENT_STOP|あなた, 誰  SYNTH_START|mei|mei_voice_normal|メイと言います.
1  41 RECOG_EVENT_STOP|君, 誰   SYNTH_START|mei|mei_voice_normal|メイと言います.
41 42   <eps>                  MOTION_ADD|mei|...\mei_self_introduction.vmd|PART|ONCE
42 43 SYNTH_EVENT_STOP|mei     SYNTH_START|mei|mei_voice_normal|よろしくお願いします.
43 2  SYNTH_EVENT_STOP|mei     <eps>
```