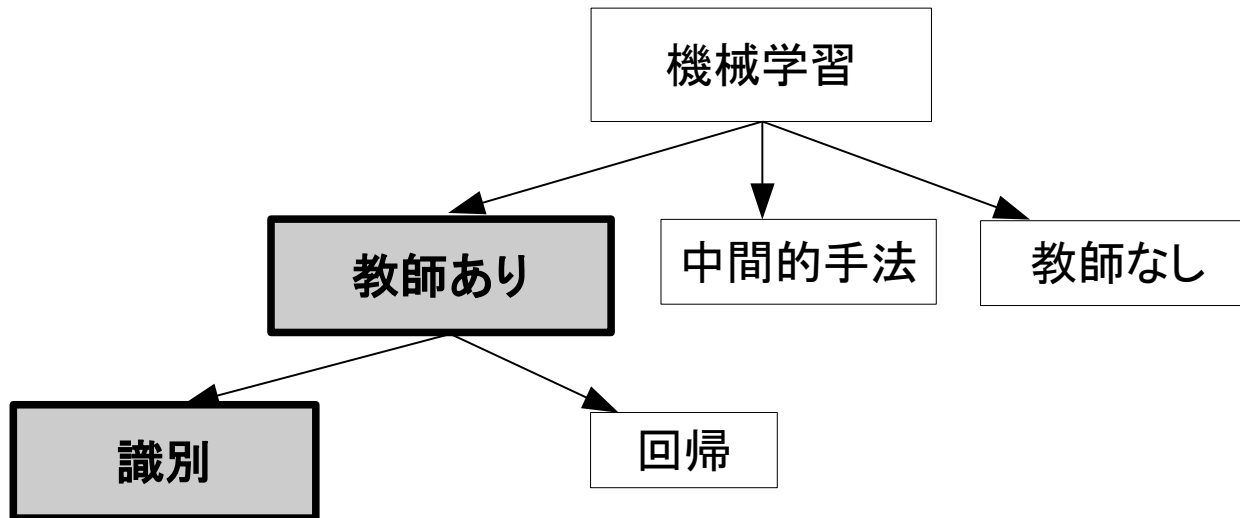



# 3. 識別 —概念学習と決定木—

- 問題設定
  - 教師あり学習
  - ラベル入力 → ラベル出力



- ラベル特徴



- 数値特徴

# contact-lenses データ

年齢・処方・  
乱視・涙量

Viewer					
Relation: contact-lenses					
	1: age Nominal	2: spectacle-prescrip Nominal	3: astigmatism Nominal	4: tear-prod-rate Nominal	5: <b>contact-lenses</b> Nominal
1	young	myope	no	reduced	none
2	young	myope	no	normal	soft
3	young	myope	yes	reduced	none
4	young	myope	yes	normal	hard
5	young	hypermetrope	no	reduced	none
6	young	hypermetrope	no	normal	soft
7	young	hypermetrope	yes	reduced	none
8	young	hypermetrope	yes	normal	hard
9	pre-presbyopic	myope	no	reduced	none
10	pre-presbyopic	myope	no	normal	soft
11	pre-presbyopic	myope	yes	reduced	none
12	pre-presbyopic	myope	yes	normal	hard
13	pre-presbyopic	hypermetrope	no	reduced	none
14	pre-presbyopic	hypermetrope	no	normal	soft
15	pre-presbyopic	hypermetrope	yes	reduced	none
16	pre-presbyopic	hypermetrope	yes	normal	none
17	presbyopic	myope	no	reduced	none
18	presbyopic	myope	no	normal	none
19	presbyopic	myope	yes	reduced	none
20	presbyopic	myope	yes	normal	hard
21	presbyopic	hypermetrope	no	reduced	none
22	presbyopic	hypermetrope	no	normal	soft
23	presbyopic	hypermetrope	yes	reduced	none
24	presbyopic	hypermetrope	yes	normal	none

Undo OK Cancel

推薦コンタクトレンズ  
none, soft, hard

# contact-lenses データ

表 3.2 コンタクトレンズデータの特徴値

attribute	value
age(年齢)	{young, pre-presbyopic, presbyopic} (若年, 老眼前期, 老眼)
spectacle-prescrip(眼鏡)	{myope, hypermetrope} (近視, 遠視)
astigmatism(乱視)	{no, yes} (なし, あり)
tear-prod-rate(涙量)	{reduced, normal} (減少, 正常)
contact-lenses(クラス)	{soft, none} (ソフト, なし)


## 3.2 概念学習とは

- 概念学習とは

- 正解の概念を説明する特徴ベクトルの性質（論理式）を求めること
- 論理式の例


（乱視 = あり）  $\wedge$  （ドライアイ = なし）  $\Rightarrow$  soft

- 学習の方法

- 可能な論理式が少数
  - 正解概念の候補を絞り込んでゆく（候補削除アルゴリズム）
- 可能な論理式が多数
  - バイアス（偏見）をかけて探索する  決定木

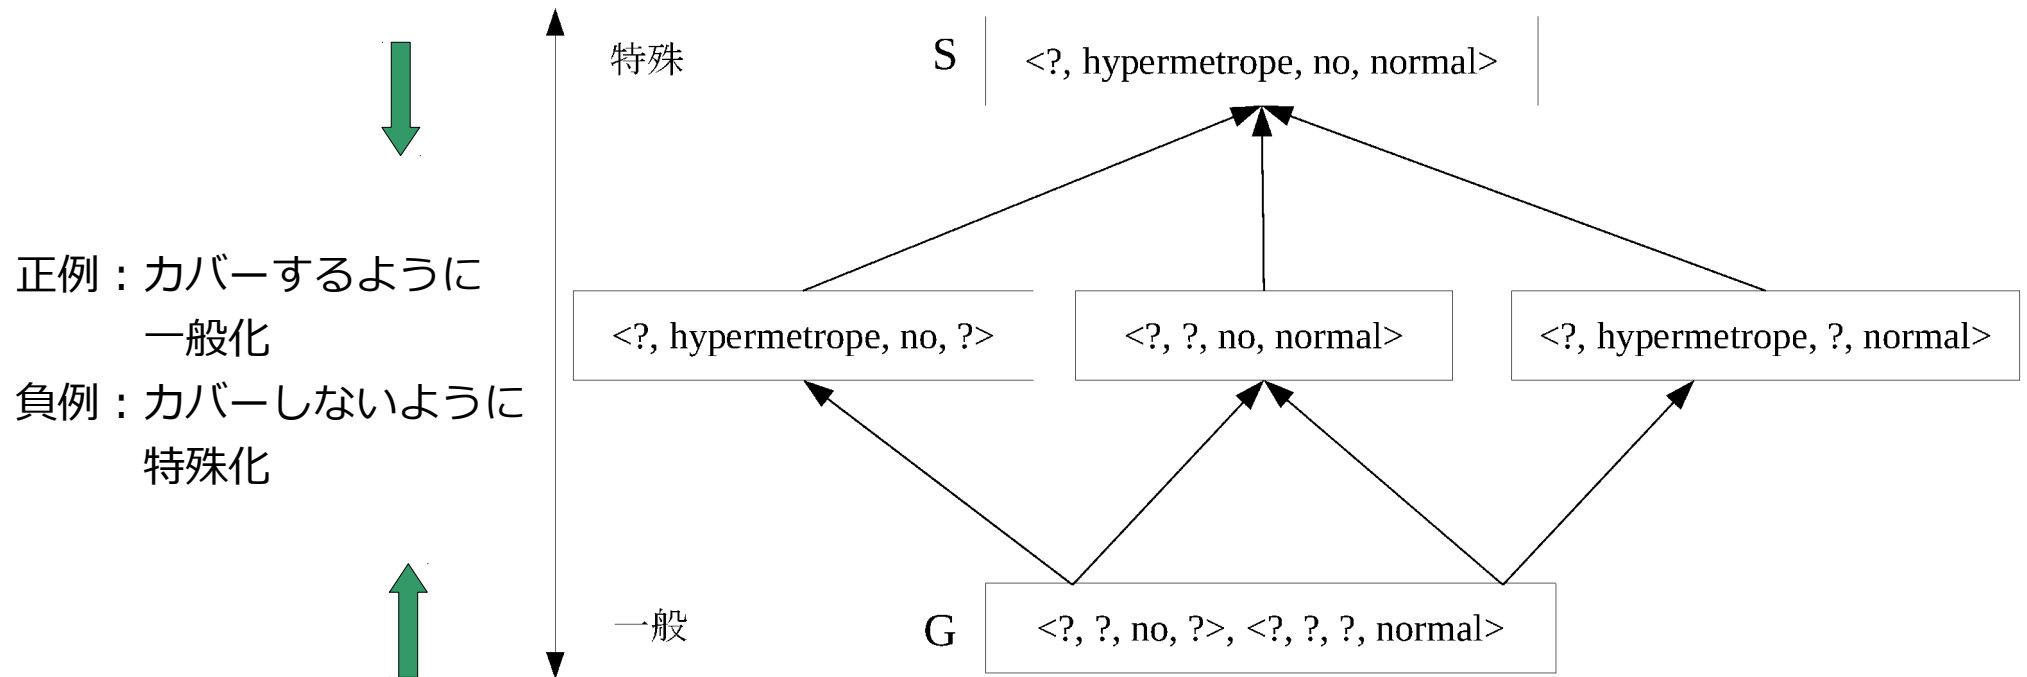
# 3.3 初歩的な概念学習アルゴリズム

## FIND-S アルゴリズム




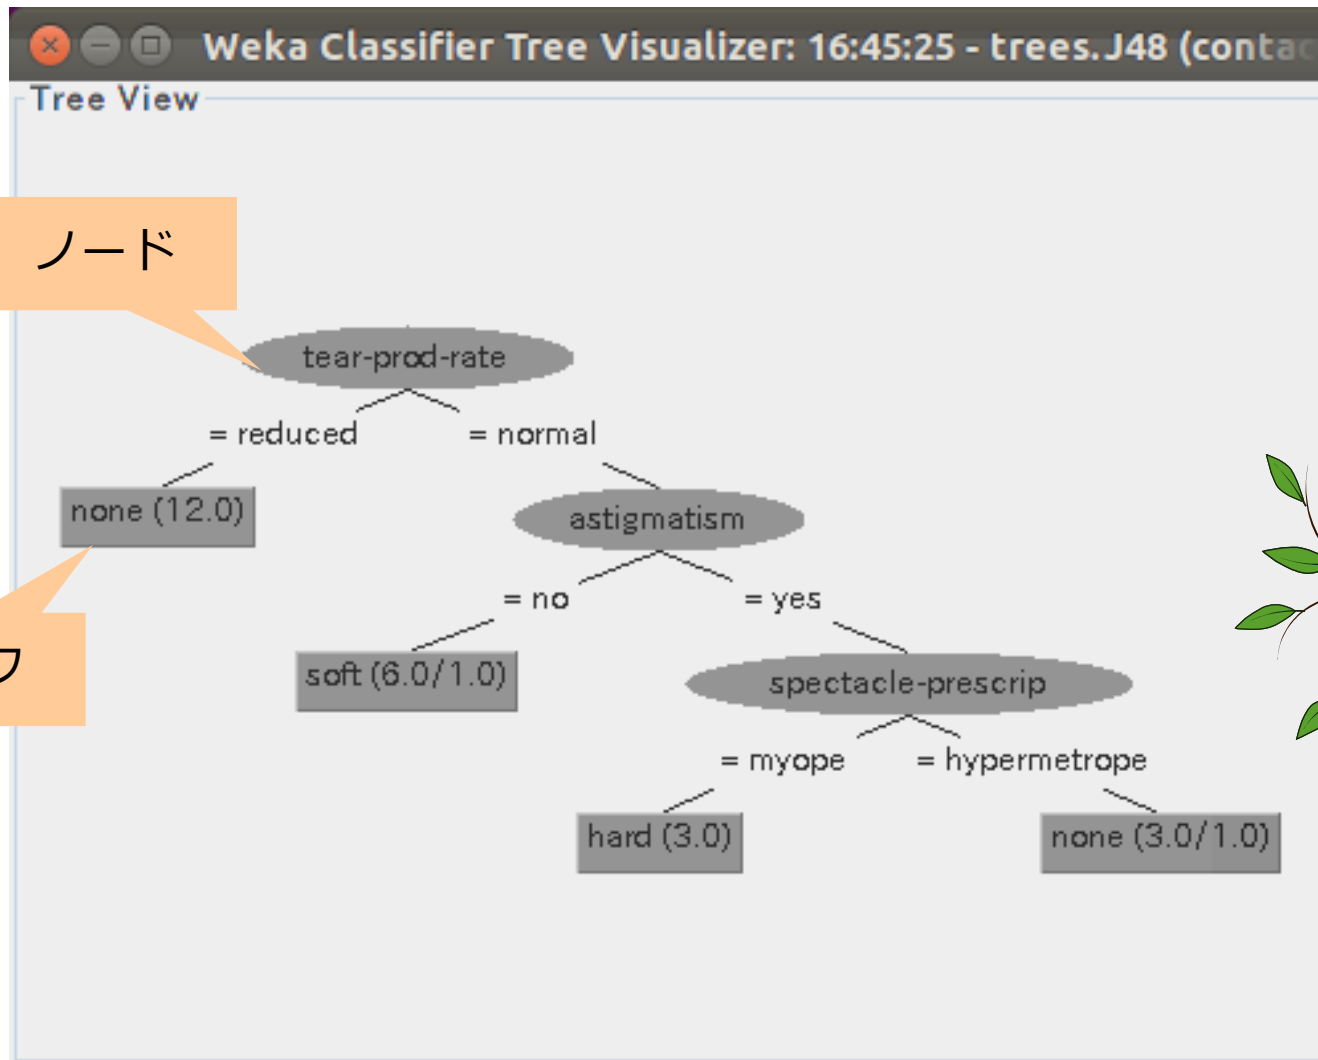
# 3.3 初歩的な概念学習アルゴリズム

## 候補削除アルゴリズム



## 3.4 決定木の学習

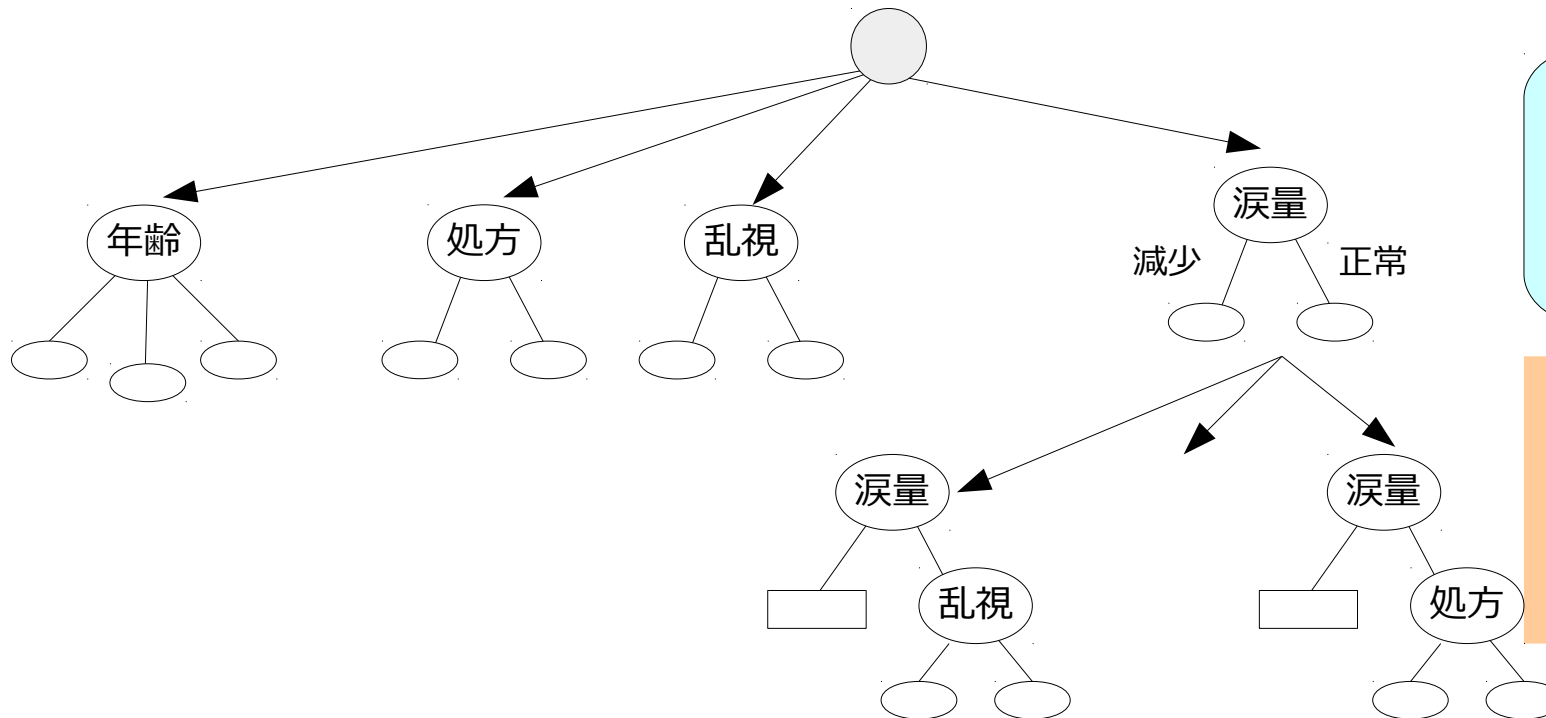
- 学習した決定木の例



## 3.4 決定木の学習

### • 決定木学習の考え方

- ノードは、データを分割する条件を持つ
  - できるだけ同一クラスのデータがリーフに偏るように
- 分割後のデータ集合に対して、同様の操作を行う
- 全てのリーフが単一クラスの集合になれば終了



この手順に従うと、  
一般には小さな木  
ができる

**バイアス**

複雑な説明よりも  
単純な説明の方が  
汎用性が高い



# 決定木の構築 (1/2)

---

## Algorithm 3.3 ID-3 アルゴリズム

---

入力: 正解付学習データ  $D$ , クラス特徴  $y$ , 特徴集合  $A$

出力: 決定木  $T$

root ノードを作成

**if**  $D$  が全て正例 **then**

**return** ラベル Yes

**else if**  $D$  が全て負例 **then**

**return** ラベル No

**else if** 特徴集合  $A == \emptyset$  **then**

**return** データ中の最頻値のラベル

**else**

# 決定木の構築 (2/2)

$a \leftarrow A$  中で最も分類能力の高い特徴

$root$  ノードの決定特徴  $\leftarrow a$

**for all**  $a$  の取りうる値  $v$  **do**

$a = v$  に対応する枝を作成

データの中から値  $v$  を取る部分集合  $D_v$  を作成

**if**  $D_v == \emptyset$  **then**

**return** データ中の最頻値のラベル

**else**

ID3(部分集合  $D_v$ , クラス特徴  $y$ , 特徴集合  $A - a$ )

**end if**

**end for**

**end if**

**return**  $root$  ノード

# 属性の分類能力 (1/2)

- 分類能力の高い属性を決定する方法
  - その属性を使った分類を行うことによって、なるべくきれいにクラスが分かれるように
- エントロピー
  - データ集合  $S$  の乱雑さを表現
  - 正例の割合 :  $p^+$  , 負例の割合 :  $p^-$
  - エントロピーの定義

$$Entropy(S) = -p^+ \log p^+ - p^- \log p^-$$

# 属性の分類能力 (2/2)

- 情報獲得量

- 属性  $A$  を用いた分類後のエントロピーの減少量

- 値  $v$  を取る訓練例の集合 :  $S_v$

- $S_v$  の要素数 :  $|S_v|$

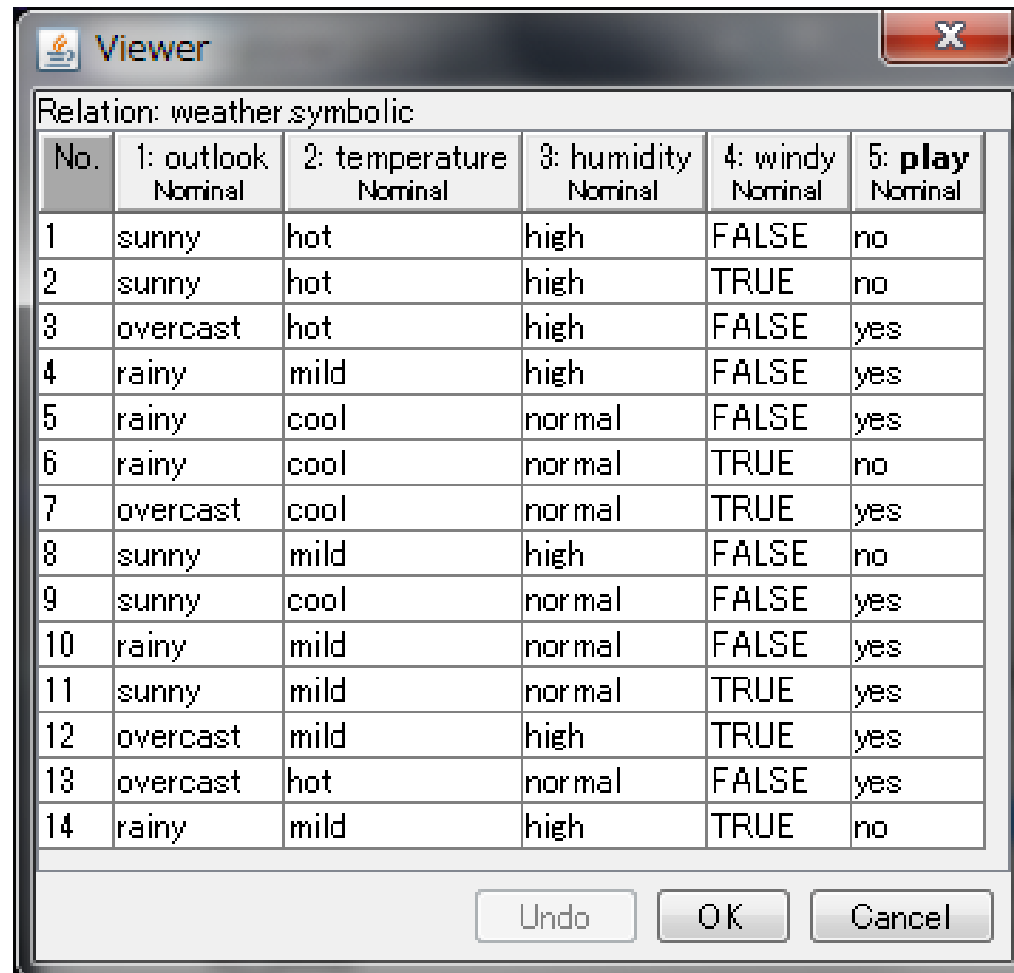
- 情報獲得量の定義

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

# 決定木構築手順の例

- 学習データ

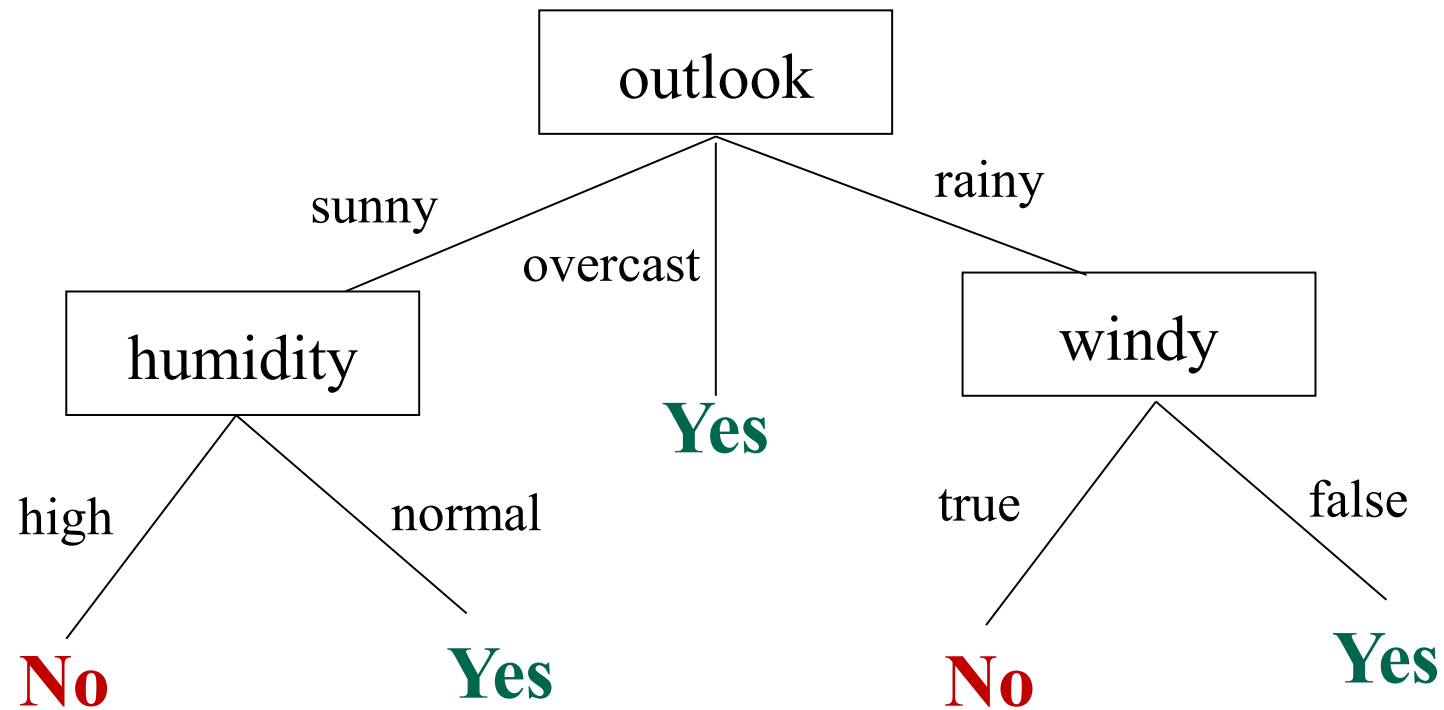
( テニスをする日 ; weather.nominal.arff)



The image shows a software window titled "Viewer" with a close button (X) in the top right corner. Below the title bar, it says "Relation: weather.symbolic". The main area contains a table with 6 columns and 14 rows of data. The columns are labeled: "No.", "1: outlook Nominal", "2: temperature Nominal", "3: humidity Nominal", "4: windy Nominal", and "5: **play** Nominal". The data rows represent 14 different weather conditions and whether tennis was played on those days. At the bottom of the window, there are three buttons: "Undo", "OK", and "Cancel".

No.	1: outlook Nominal	2: temperature Nominal	3: humidity Nominal	4: windy Nominal	5: <b>play</b> Nominal
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no

# 結果として得られる決定木



# 計算例

$$E(D) = -P_+ \log_2 P_+ - P_- \log_2 P_-$$

$$Gain(D, a) \equiv E(D) - \sum_{v \in Values(a)} \frac{|D_v|}{|D|} E(D_v)$$

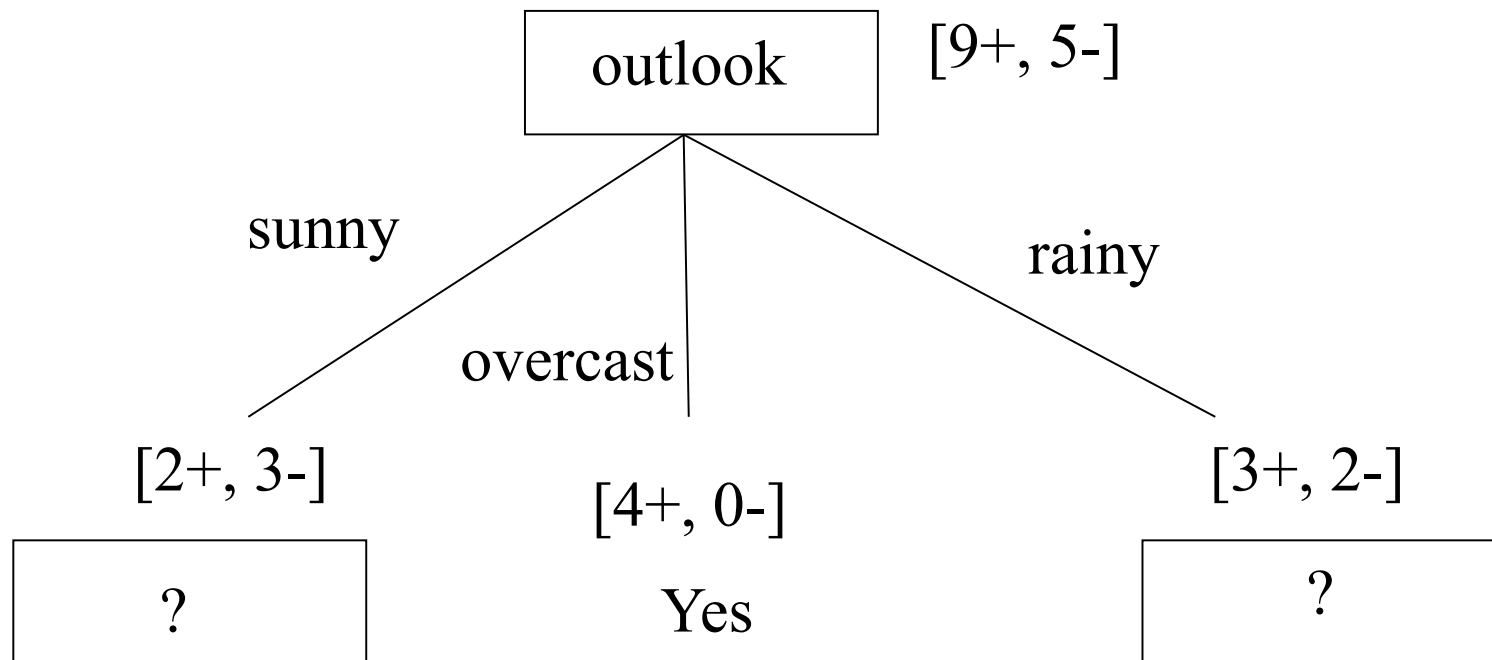
- 情報獲得量

Gain(S, outlook)=0.246

Gain(S, humidity)=0.151

Gain(S, windy)=0.048

Gain(S, temperature)=0.029



# バイアスの検討

## なぜ単純な木の方がよいか

- オッカムの剃刀

「データに適合する最も単純な仮説を選べ」

- 複雑な仮説

- 表現能力が高い

- 偶然にデータを説明できるかもしれない

- 単純な仮説

- 表現能力が低い

- 偶然にデータを説明できる確率は低い

- でも説明できた！

- **必然**



# 連続値属性の扱い

- 連続値  $A$  を持つ属性から真偽値 ( $A < c?$ ) を値とするノードを作成

→  $c$  をどうやって決めるか

気温	40	48	60	72	80	90
playTennis	No	No	Yes	Yes	Yes	No

$$c = (48 + 60) / 2 \\ = 54$$

$$c = (80 + 90) / 2 \\ = 85$$

情報獲得量の多い方