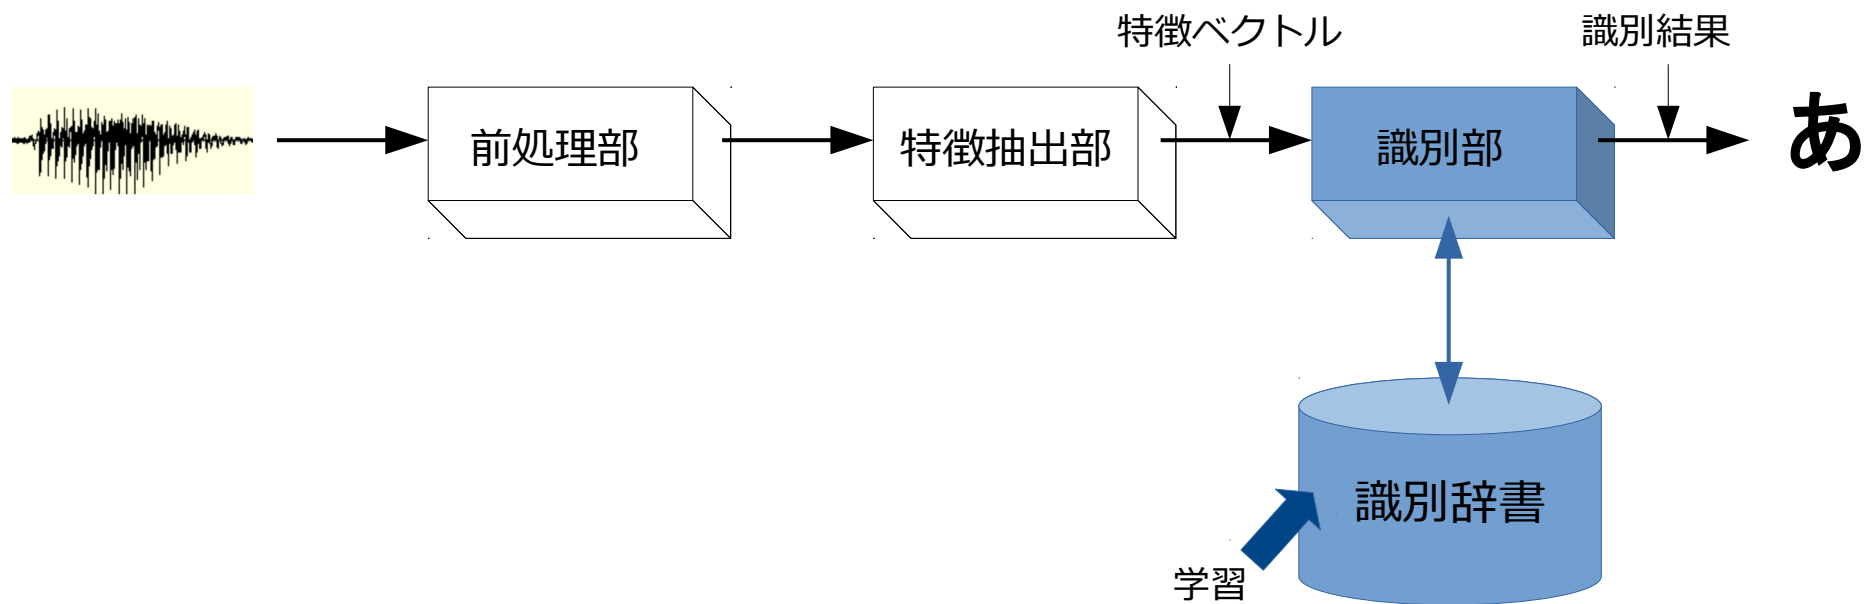


Section 2

- 基本的な識別手法 (4,5章)

4. パターンを識別しよう



4.1 NN 法の定式化と問題設定

4.1.1 「もっとも近い」の定義

- 識別対象のクラス： $\omega_1, \dots, \omega_c$
- プロトタイプ
 - 各クラスの代表となる点

$$\mathbf{p}_i = (p_{i1}, \dots, p_{id})^T \quad (i = 1, \dots, c)$$

- 識別したい入力データ

$$\mathbf{x} = (x_1, \dots, x_d)^T$$

4.1.1 「もっとも近い」の定義

- 入力ベクトルとプロトタイプとの距離

$$D(\mathbf{x}, \mathbf{p}_i) = \sqrt{(x_1 - p_{i1})^2 + \cdots + (x_d - p_{id})^2}$$


- NN 法の判定式

$$\arg \min_{i=1, \dots, c} D(\mathbf{x}, \mathbf{p}_i) = k \quad \Rightarrow \quad \mathbf{x} \in \omega_k$$

最小値のときの
パラメータを返す
関数


4.1.2 プロトタイプと識別面の関係

- 特徴空間の分割
 - 2次元特徴の2クラス問題 ($d = 2, c = 2$) を考える
 - クラスを分離する境界
 - …プロトタイプから等距離にある領域
- 2次元のNN法では垂直2等分線
- 多次元では超平面
- **決定境界**あるいは**識別面**と呼ぶ




4.1.2 プロトタイプと識別面の関係

- 線形分離可能性
 - 直線（超平面）で2つのクラスが誤りなく分割できる場合を**線形分離可能**と呼ぶ





線形分離可能なデータ



線形分離不可能なデータ

4.1.3 プロトタイプ的位置の決め方


- クラスを代表するプロトタイプの設定法
 - 例) クラスの分布の重心



重心ではうまくゆかないことがある

4.2 パーセプトロンの学習規則

- 識別面の学習
 - 線形分離可能なデータに対して、識別誤りが生じない位置にプロトタイプを設定する



4.2.1 識別関数の設定

- 学習とは
 - プロトタイプの正しい位置を自動的に求めること
- 学習パターン
 - 識別部設計（特徴空間の分割）用に収集されたパターン
- 一般的な学習の定義
 - 学習パターンを用いて、学習パターンをすべて正しく識別できるような識別面を見いだすこと

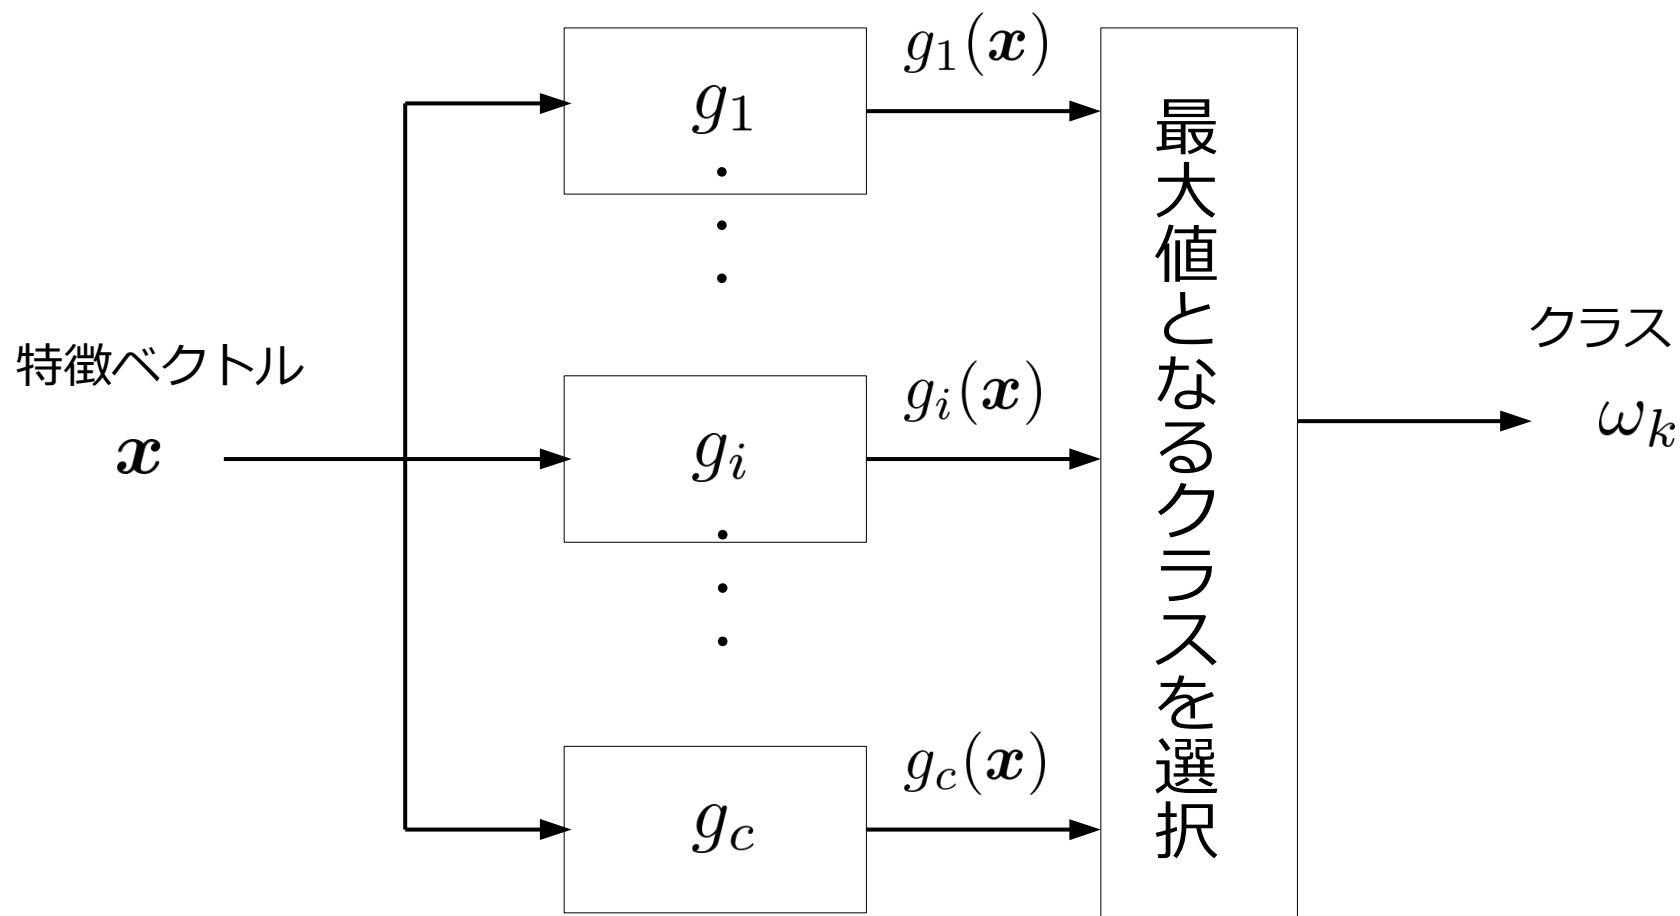
4.2.1 識別関数の設定

- 1 クラス 1 プロトタイプの NN 法の定式化
 - クラス : $\omega_1, \dots, \omega_c$
 - プロトタイプ : $\mathbf{p}_1, \dots, \mathbf{p}_c$
 - 入力パターン : \mathbf{x} (特徴ベクトル)
 - NN 法 : $D(\mathbf{x}, \mathbf{p}_i) = \|\mathbf{x} - \mathbf{p}_i\|$ を最小にする i を探す
 - $\|\mathbf{x} - \mathbf{p}_i\|^2 = \|\mathbf{x}\|^2 - 2\mathbf{p}_i^T \mathbf{x} + \|\mathbf{p}_i\|^2$
 - $g_i(\mathbf{x}) = \mathbf{p}_i^T \mathbf{x} - \frac{1}{2}\|\mathbf{p}_i\|^2$ を最大にする i を探す

識別関数

4.2.1 識別関数の設定

- NN 法による識別部の実現



4.2.2 識別関数とパーセプトロン

- 線形識別関数

- 識別関数の係数を

$$p_{ij} = w_{ij} \quad (j = 1, \dots, d), \quad -\frac{1}{2} \|\mathbf{p}_i\|^2 = w_{i0}$$

と置き換える

$$g_i(\mathbf{x}) = w_{i0} + \sum_{j=1}^d w_{ij} x_j$$

$$= \sum_{j=0}^d w_{ij} x_j \quad (x_0 \equiv 1)$$

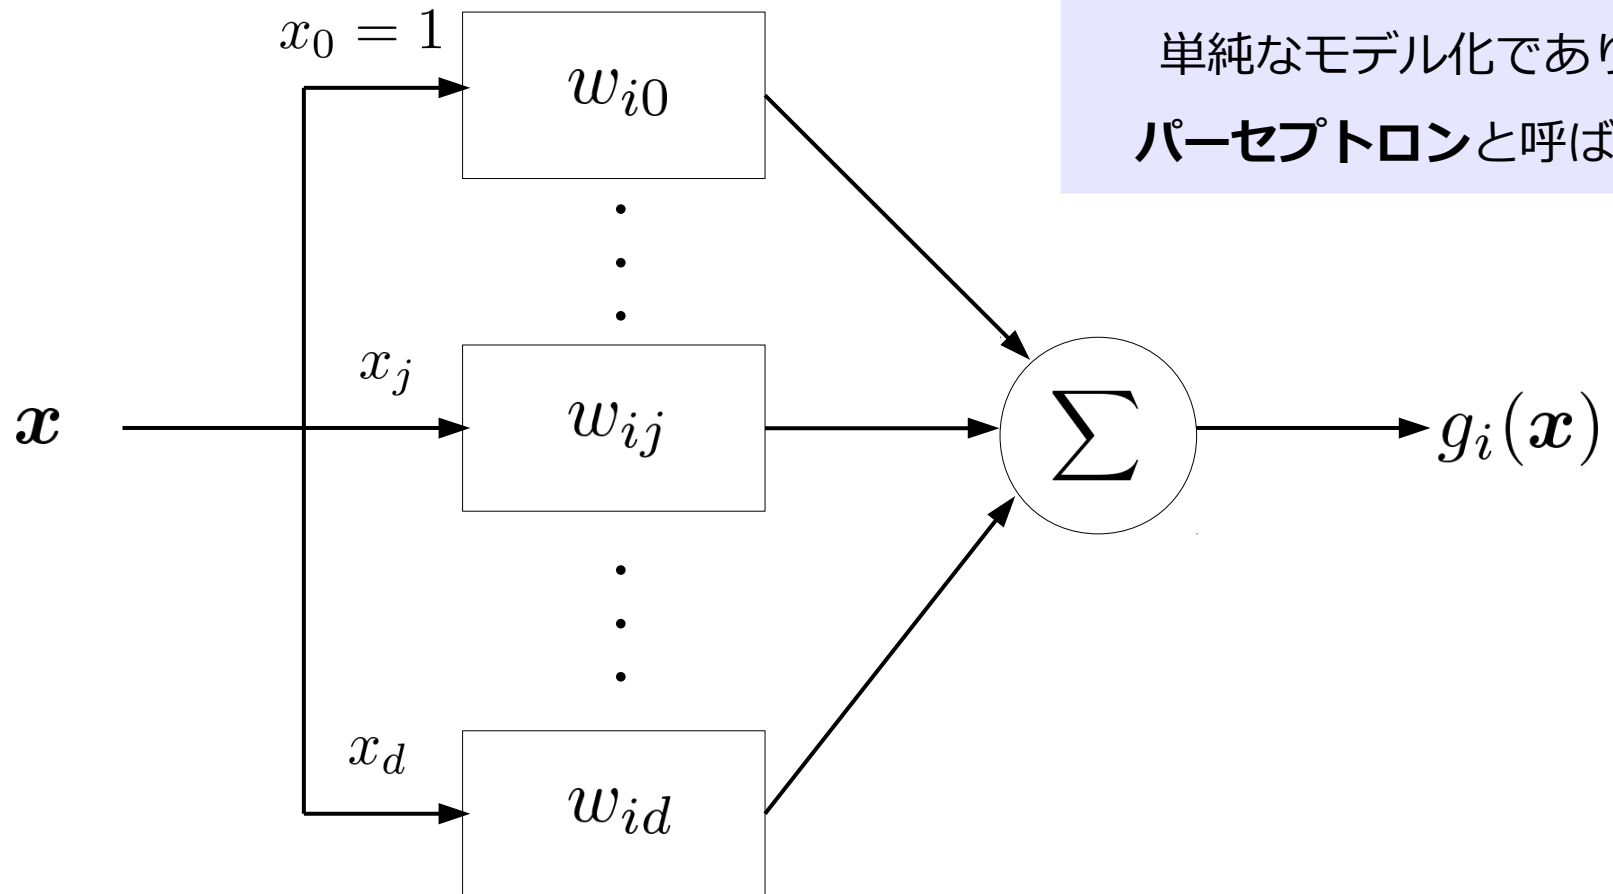
$$= \mathbf{w}_i^T \mathbf{x}$$

重みベクトル

\mathbf{w}_i, \mathbf{x} は $d + 1$ 次元

4.2.2 識別関数とパーセプトロン

- 線形識別関数の計算法



この計算機構は、神経細胞の
単純なモデル化であり、
パーセプトロンと呼ばれる

4.2.3 2 クラスの識別関数の学習

- 線形識別関数の学習

- 学習パターン全体： χ

- クラス ω_i に属する学習パターンの集合 χ_i

の全ての要素 x に対して

$$g_i(x) > g_j(x) \quad (j = 1, \dots, c, j \neq i)$$

が成り立つように重み w_i を決定する

4.2.3 2 クラスの識別関数の学習

- 2 クラスの場合
 - 1 つの識別関数

$$g(\boldsymbol{x}) = g_1(\boldsymbol{x}) - g_2(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x}$$

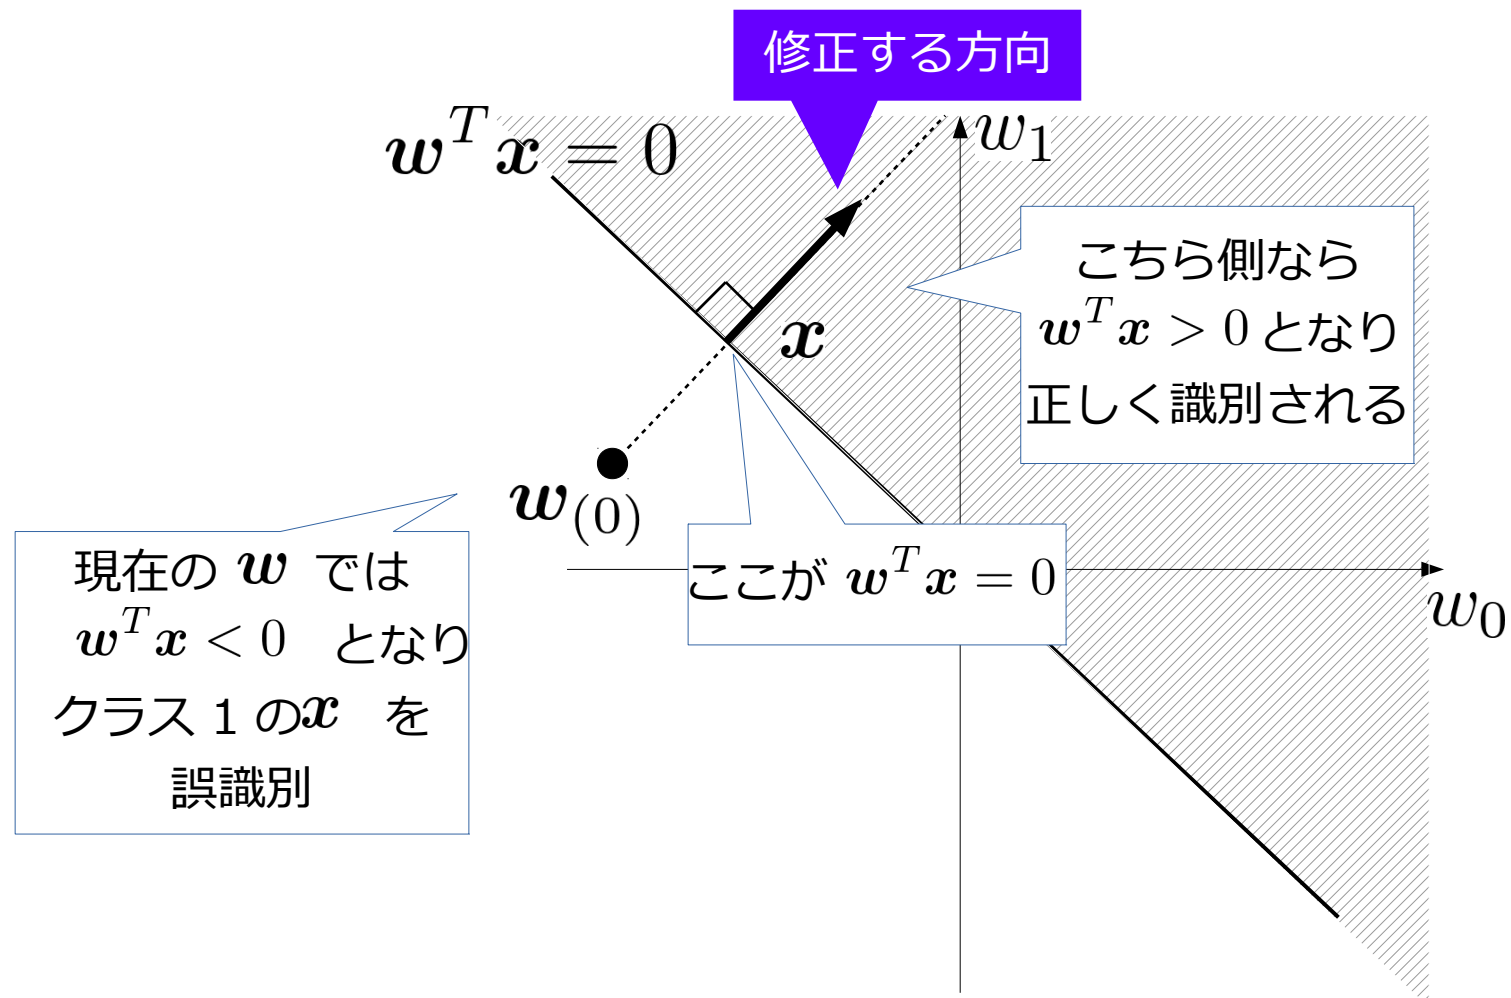
の正負を調べ、

$$g(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} \begin{cases} > 0 & (\boldsymbol{x} \in \chi_1) \\ < 0 & (\boldsymbol{x} \in \chi_2) \end{cases}$$

となる \boldsymbol{w} を求める

4.2.3 2 クラスの識別関数の学習

- 重み空間での重みの修正



4.2.4 パーセプトロンの学習アルゴリズム

- パーセプトロンの学習規則

1. w の初期値を適当に決める
2. 学習パターンからひとつ x を選び、 $g(x)$ を計算
3. 誤識別が起きたときのみ、 w を修正する

$$w' = w + \rho x \quad (\text{クラス 1 のパターンをクラス 2 と誤ったとき})$$

$$w' = w - \rho x \quad (\text{クラス 2 のパターンをクラス 1 と誤ったとき})$$

学習係数

4. 2,3 を全ての学習パターンについて繰り返す
5. すべて識別できたら終了。そうでなければ 2 へ


4.2.4 パーセプトロンの学習アルゴリズム

- パーセプトロンの収束定理
 - データが線形分離可能であれば、パーセプトロンの学習規則は有限回の繰り返しで終了する
- 学習係数 ρ の設定
 - 大きすぎると重みの値が振動する
 - 小さすぎると収束に時間がかかる

一般には小さい値が無難

4.3.4 学習をあきらめるのも一手 k-NN 法

- k-NN法とは
 - 全ての学習データをプロトタイプとする
 - 入力に近い順から k 個のプロトタイプのクラスを調べ、多数決を取る
 - 実験の際のベースラインとして用いられる




5. 誤差をできるだけ小さくしよう

- パーセプトロンの学習規則の欠点
 - 線形分離不可能である場合には利用できない
 - 一般に線形分離可能性を事前に確認するのは困難



- 評価関数最小化法
 - 線形分離不可能な場合にも適用可能



5.1 誤差評価に基づく学習とは

- 学習パターン $\chi = \{\boldsymbol{x}_1, \dots, \boldsymbol{x}_n\}$
- \boldsymbol{x}_p ($1 \leq p \leq n$) に対する c 個の識別関数の出力
 $(g_1(\boldsymbol{x}_p), \dots, g_c(\boldsymbol{x}_p))^T$
- \boldsymbol{x}_p に対する教師ベクトル (教師信号)
 $(b_{1p}, \dots, b_{cp})^T$
 - 正解クラスの要素が 1、他は 0
- 入力パターン \boldsymbol{x}_p に対する識別関数の出力と、教師信号との誤差 ϵ_{ip} ($i = 1, \dots, c$) が小さくなるように重みベクトル \boldsymbol{w} を定める

5.1 誤差評価に基づく学習とは

- 誤差 $\epsilon_{ip} = g_i(\mathbf{x}_p) - b_{ip}$
- ϵ_{ip} の全クラスに対する二乗和を評価関数 J_p とする

$$\begin{aligned} J_p(\mathbf{w}_1, \dots, \mathbf{w}_c) &= \frac{1}{2} \sum_{i=1}^c \epsilon_{ip}^2 \\ &= \frac{1}{2} \sum_{i=1}^c (g_i(\mathbf{x}_p) - b_{ip})^2 \\ &= \frac{1}{2} \sum_{i=1}^c (\mathbf{w}_i^T \mathbf{x}_p - b_{ip})^2 \end{aligned}$$

\mathbf{x}_p に対する誤差

5.1 誤差評価に基づく学習とは

- 全パターンに対する二乗誤差 J

$$\begin{aligned} J(\boldsymbol{w}_1, \dots, \boldsymbol{w}_c) &= \sum_{p=1}^n J_p(\boldsymbol{w}_1, \dots, \boldsymbol{w}_c) \\ &= \frac{1}{2} \sum_{p=1}^n \sum_{i=1}^c (g_i(\boldsymbol{x}_p) - b_{ip})^2 \\ &= \frac{1}{2} \sum_{p=1}^n \sum_{i=1}^c (\boldsymbol{w}_i^T \boldsymbol{x}_p - b_{ip})^2 \end{aligned}$$

この値を最小にする $\boldsymbol{w}_1, \dots, \boldsymbol{w}_c$ を求める

5.1 誤差評価に基づく学習とは

- 2 クラス問題を考える場合

- 識別関数を 1 つにできる

$$g(\boldsymbol{x}) = g_1(\boldsymbol{x}) - g_2(\boldsymbol{x})$$

- 教師信号はクラス 1 のとき 1、クラス 2 のとき -1
- 誤差関数

$$J(\boldsymbol{w}) = \frac{1}{2} \sum_{p=1}^n (\boldsymbol{w}^T \boldsymbol{x}_p - b_p)^2$$

5.2 解析的な解法

- パターン行列

$$\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)^T$$

教師信号ベクトル

$$\mathbf{b} = (b_1, \dots, b_n)^T$$

とすると

$$J(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{b}\|^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{b}) = 0$$

解くべき式

5.2 解析的な解法

- 解くべき式

$$X^T X w = X^T b$$

$X^T X$ が正則であるとき

$$w = (X^T X)^{-1} X^T b$$

- 解が求まらない可能性

- $X^T X$ が正則であるとは限らない
- d が大きい場合は逆行列を求める計算が大変

正則：

逆行列が存在すること

逆行列：

$n \times n$ の正方行列 A に対して、
 $AB = BA = I$ となる B

最小二乗法


5.3 最急降下法

5.3.1 最急降下法による最適化

- w を J の傾きの方向に徐々に修正する

$$w' = w - \rho \frac{\partial J}{\partial w}$$

- 最急降下法のイメージ



5.3.2 Widrow-Hoff の学習規則

- 勾配ベクトルの定義
 - 重みベクトル

$$\boldsymbol{w} = (w_0, \dots, w_d)$$

の関数 $J(\boldsymbol{w})$ に対して、勾配ベクトルを

$$\nabla J = \frac{\partial J}{\partial \boldsymbol{w}} = \left(\frac{\partial J}{\partial w_0}, \dots, \frac{\partial J}{\partial w_d} \right)^T$$

と定義する

5.3.2 Widrow-Hoff の学習規則

- 修正式の導出

$$\begin{aligned}\frac{\partial J}{\partial \mathbf{w}} &= \sum_{p=1}^n \frac{\partial J_p}{\partial \mathbf{w}} \\ &= \sum_{p=1}^n (\mathbf{w}^T \mathbf{x}_p - b_p) \mathbf{x}_p\end{aligned}$$

$$\begin{aligned}\mathbf{w}' &= \mathbf{w} - \rho \frac{\partial J}{\partial \mathbf{w}} \\ &= \mathbf{w} - \rho \sum_{p=1}^n (\mathbf{w}^T \mathbf{x}_p - b_p) \mathbf{x}_p\end{aligned}$$

重みの修正式

5.3.3 確率的最急降下法

- 最急降下法の問題点
 - データ数やパラメータ数が多いと、重み更新に時間がかかる
- 確率的最急降下法
 - 個々のデータの識別結果に基づき、重みを更新
 - データが来る毎に学習するオンライン学習が可能
 - 更新式

$$\boldsymbol{w}' = \boldsymbol{w} - \rho(\boldsymbol{w}^T \boldsymbol{x}_p - b_p) \boldsymbol{x}_p$$

Section2 のまとめ

- パーセプトロンの学習規則
 - データが線形分離可能な場合、有限回の重みの修正で線形識別面を見つけることができる
- 誤差最小の識別面の学習
 - 最小二乗法：解析的に識別面を求めることができる
 - 最急降下法：誤差を徐々に小さくする