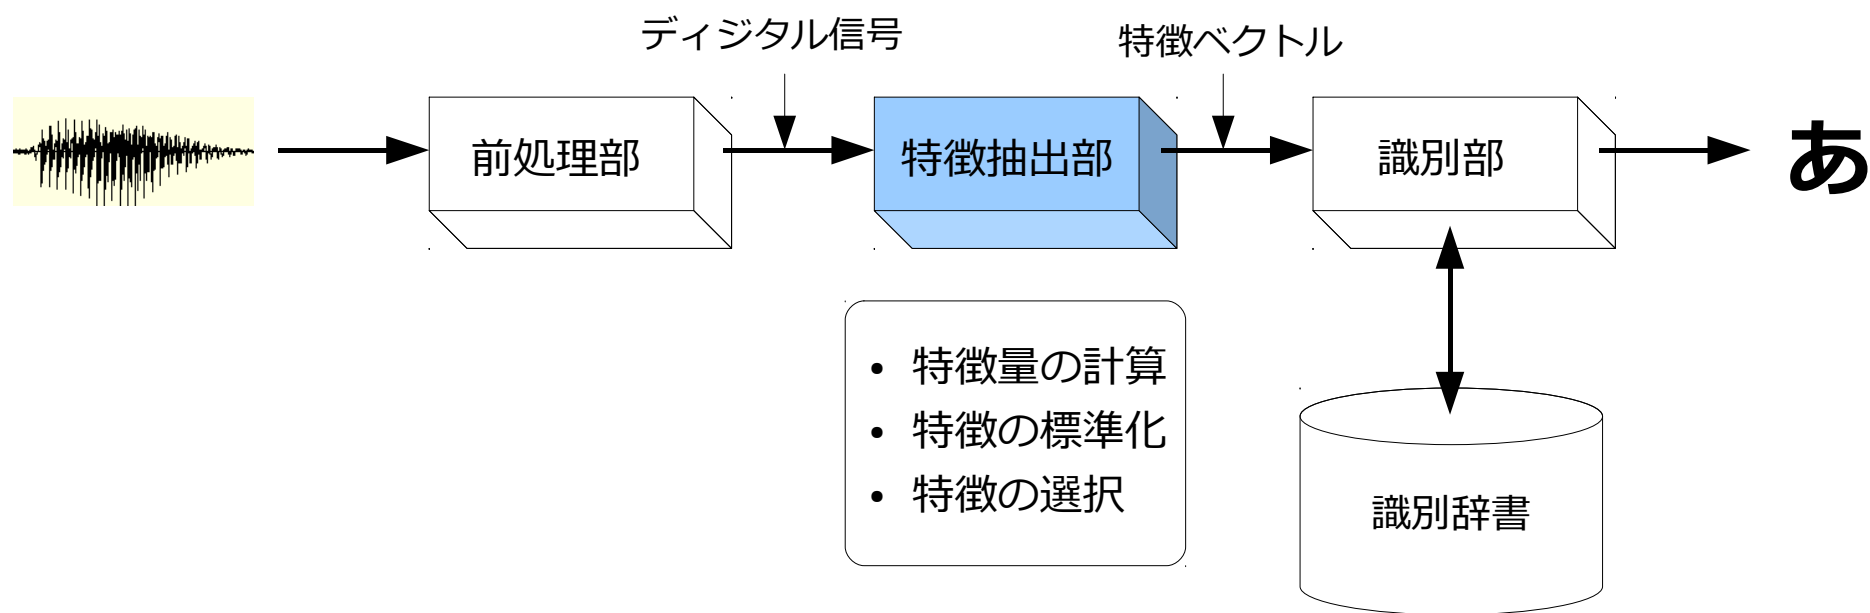



### 3. パターンの特徴を調べよう



## 3.1 変動に強い特徴とは


### 3.1.1 音声の場合

- 音素の違いとは
  - 声帯を振動の有無  
(パルス波か雑音か)
  - 声道 (口の開き具合・舌の位置など) の変形  
→ 共振周波数の違いが大きな特徴



(a) 発声の仕組みと調音のメカニズム

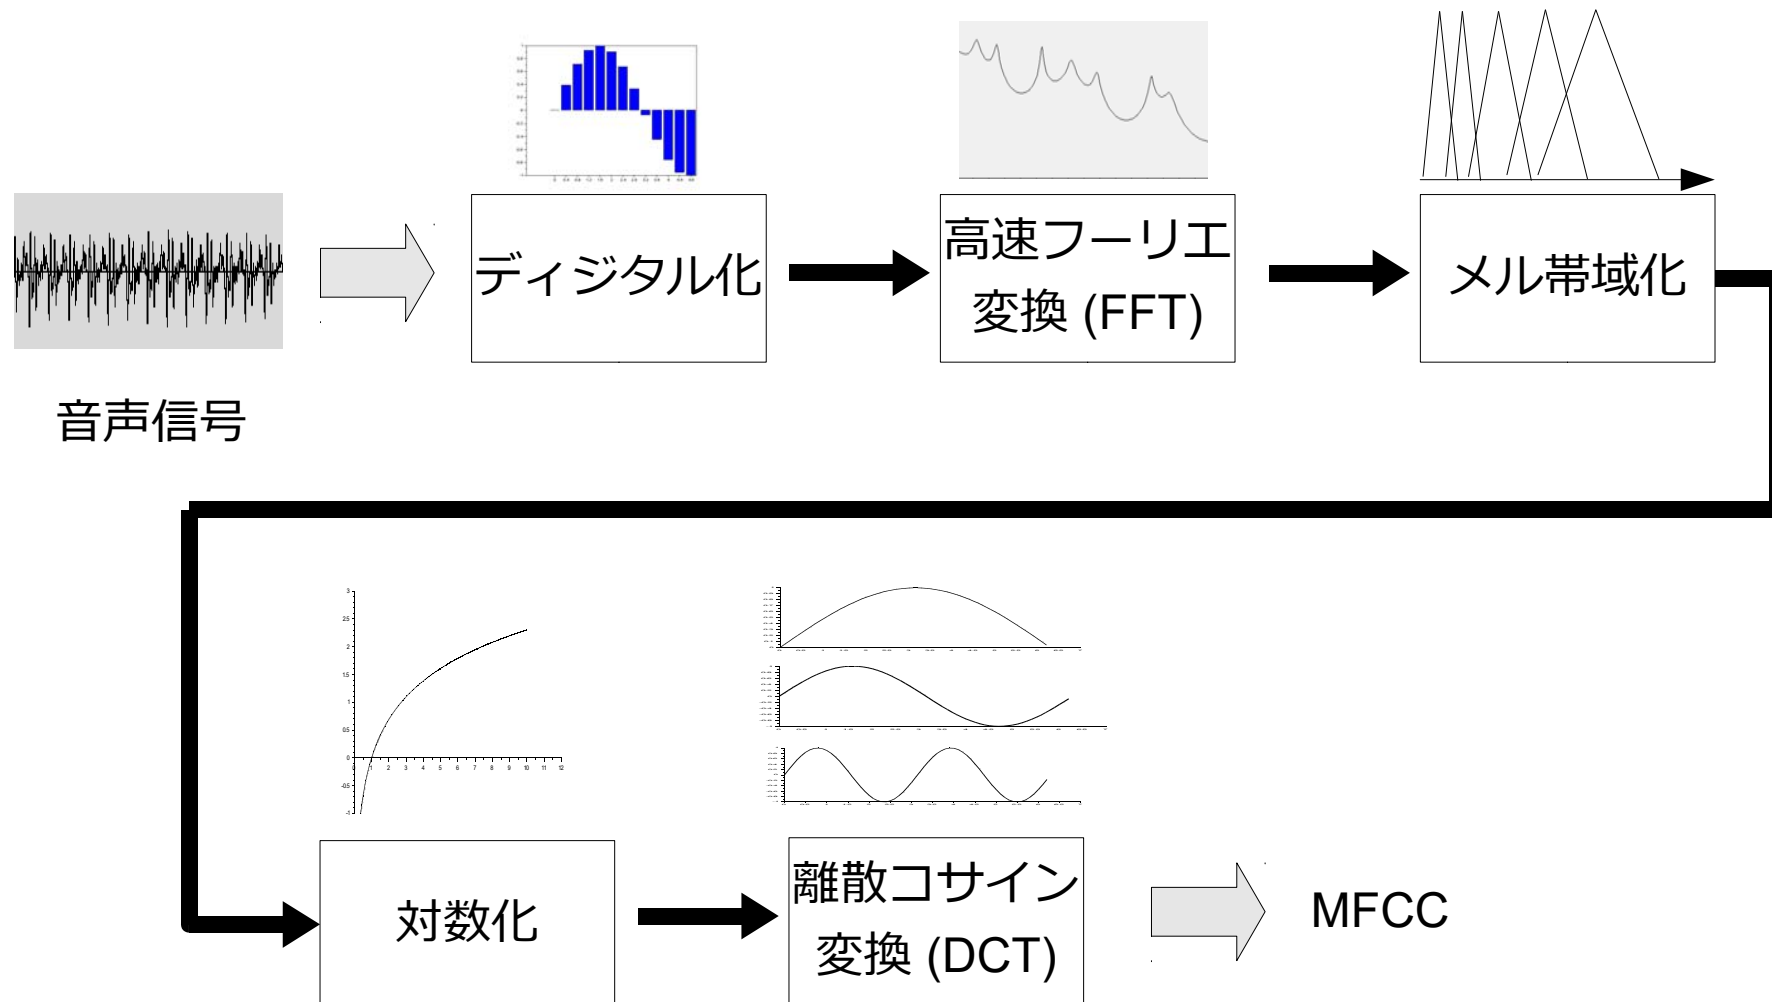
## 3.1.1 音声の場合



(b) 日本語母音識別のための特徴空間 (男性)


## 3.1.1 音声の場合

- MFCC (Mel Frequency Cepstrum Coefficient)
  - スペクトルの概形情報を抽出




## 3.1.2 画像の場合

- 画像の変動
  - 明るさの変化, 拡大・縮小, 回転など
- SIFT 特徴量
  - 2枚の画像の対応抽出などに有効



## 3.1.2 画像の場合


- Bag of Visual Words
  - SIFT 特徴量の似ているベクトルを単語と見なし、その出現頻度を特徴として分類問題に適用



学習画像セット

## 3.2 特徴のスケールを揃える

- 各軸で値のスケールが異なる場合



標準化の必要性

## 3.2 特徴のスケールを揃える

- スケールの揃え方
  - 特徴空間の単位超立方体の体積を軸伸縮の前後で一定に保ち、かつパターン相互の距離を最小化  
→ 各軸の分散を等しくする
- 平均値を 0 にしておくと分析に便利
- 標準化の式

$$x'_i = \frac{x_i - m_i}{\sigma_i} \quad m_i, \sigma_i : \text{軸 } i \text{ の平均、標準偏差}$$



## 3.3 特徴は多いほどよいか

### 3.3.1 偶然に見つかってはまずい

#### (1) 偶然の傾向とは

- 特徴は多いほどよいか
- 特徴が多くデータ数が少ないと、偶然の傾向が現れるかもしれない
  - ▶ 特徴の次元数が高いほど、偶然の傾向が発見される可能性が高い

### 3.3.1 偶然に見つかってしまっはまずい

#### (2) 学習に必要なパターン数

- 超平面の容量  $2(d + 1)$ 
  - $p(n, d)$  :  $d$  次元空間上で、適当に配置された  $n$  個のパターンを任意に 2 クラスに分けたとき、超平面により線形分離できる確率

$$n < 2(d + 1) : p(n, d) \sim 1$$

$$n = 2(d + 1) : p(n, d) = 1/2$$

$$n > 2(d + 1) : p(n, d) \sim 0$$

## 例題 3.3

$$p(4, 1) = 1/2$$

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(a) データの配置

	○	○	○	○	
	○	○	○		×
	○	○	×	○	
	○	○		×	×
	○	×	○	○	
	○	×	○	×	
	○	×	×	○	
	○		×	×	×
	×		○	○	○
	×	○	○	×	
	×	○	×	○	
	×	○	×	×	
	×	×		○	○
	×	×	○	×	
	×	×	×		○
	×	×	×	×	

(b) 二つに分離可能

### 3.3.1 偶然に見つかってしまっはまずい

(3) 見つかるはずのないものが見つかった？



- $n \gg 2(d+1)$  のとき
  - $p(n, d) \sim 0$
  - もしこの条件で識別面が見つかったとしたら
    - 偶然には存在しえないものが見つかった
    - その識別面は必然的に存在していた

## 3.2.2 特徴を減らそう

(1) 力業で次元を減らす

→ 全ての組み合わせを評価する

(2) スマートに主成分分析



## 3.2.2 特徴を減らそう

- 変換行列

- 変換前の特徴空間におけるパターンの共分散行列  $\Sigma$  の上位  $\tilde{d}$  個の固有値に対応する固有ベクトルを列とする行列

$$A = \begin{pmatrix} a_{11} & \dots & a_{1\tilde{d}} \\ \vdots & \ddots & \vdots \\ a_{d1} & \dots & a_{d\tilde{d}} \end{pmatrix}$$

- 次元数の削減  $\mathbf{Y} = \mathbf{XA}$      $d$ 次元から $\tilde{d}$ 次元への削減

# 共分散行列とは

- データの広がりを調べる→共分散行列

- 1次元の場合

平均

$$m = \frac{1}{n} \sum_{i=1}^n x_i$$

分散

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (m - x_i)^2$$

- 多次元の場合

平均ベクトル



$$m = \frac{1}{n} \sum_{\mathbf{x} \in \chi} \mathbf{x}$$

共分散行列

$$\Sigma = \frac{1}{n} \sum_{\mathbf{x} \in \chi} (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^t$$

# 共分散行列とは

平均・各軸の分散が等しいデータ



共分散行列  $\Sigma = \begin{pmatrix} x\text{の分散} & x\text{と}y\text{の相関} \\ x\text{と}y\text{の相関} & y\text{の分散} \end{pmatrix}$