



7. 限界は破れるか (2)

— ニューラルネットワーク —

- 誤差評価に基づく学習
 - 誤差最小・任意形の識別面を学習することはできないか  ニューラルネットワーク

7.1 ニューラルネットワークの構成

- 神経細胞の計算メカニズムをモデル化

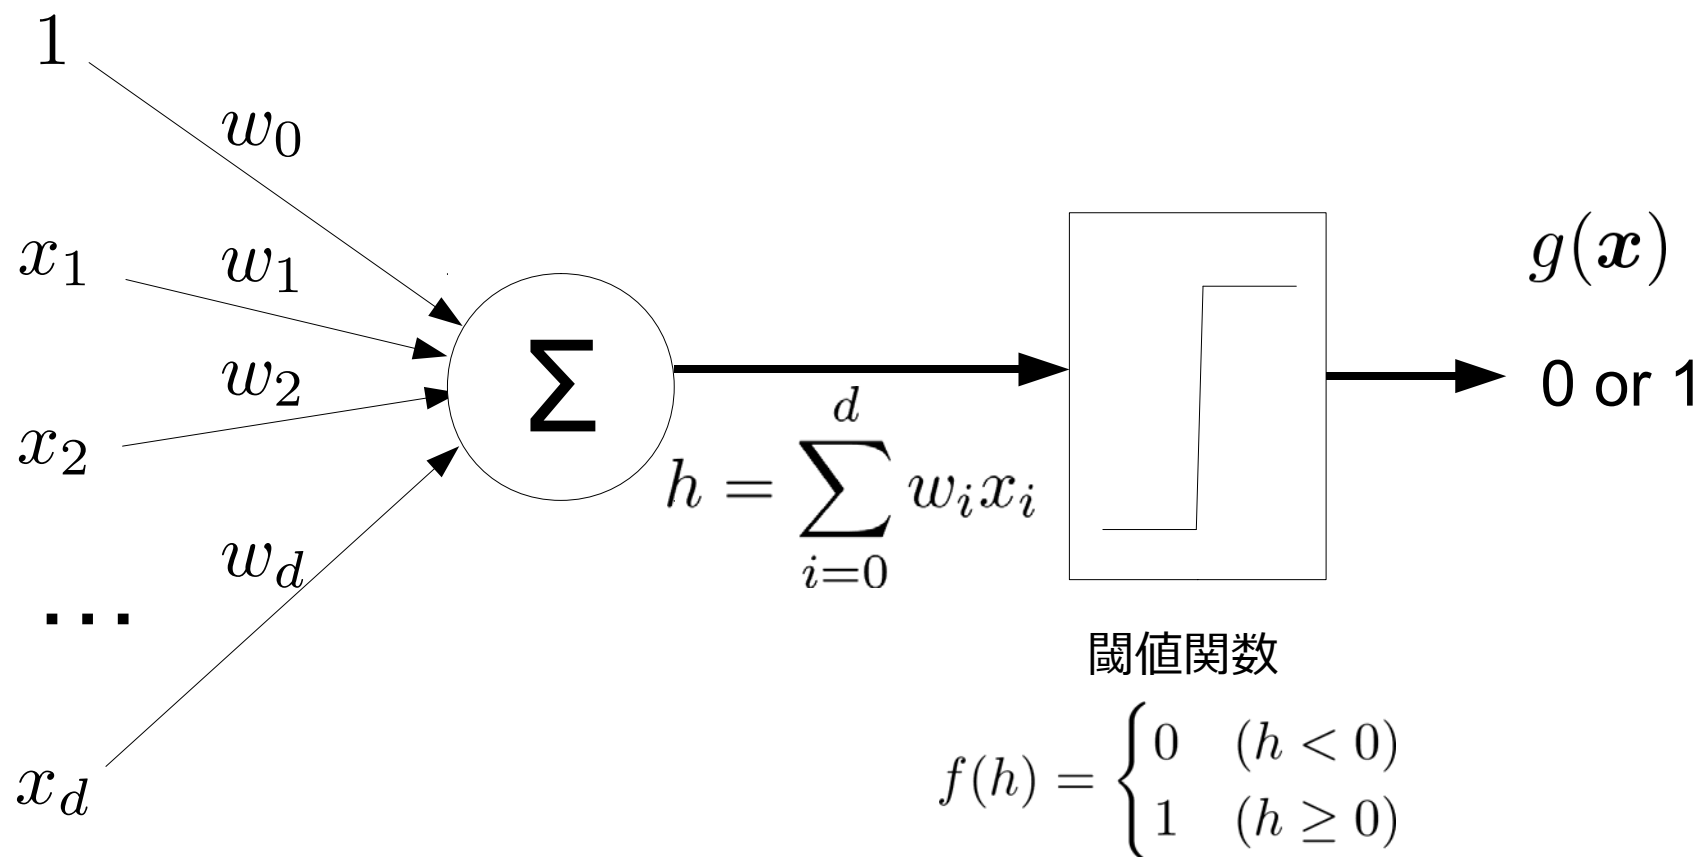


7.1 ニューラルネットワークの構成

- 単層パーセプトロンの定義

以後、 w は w_0 を含む

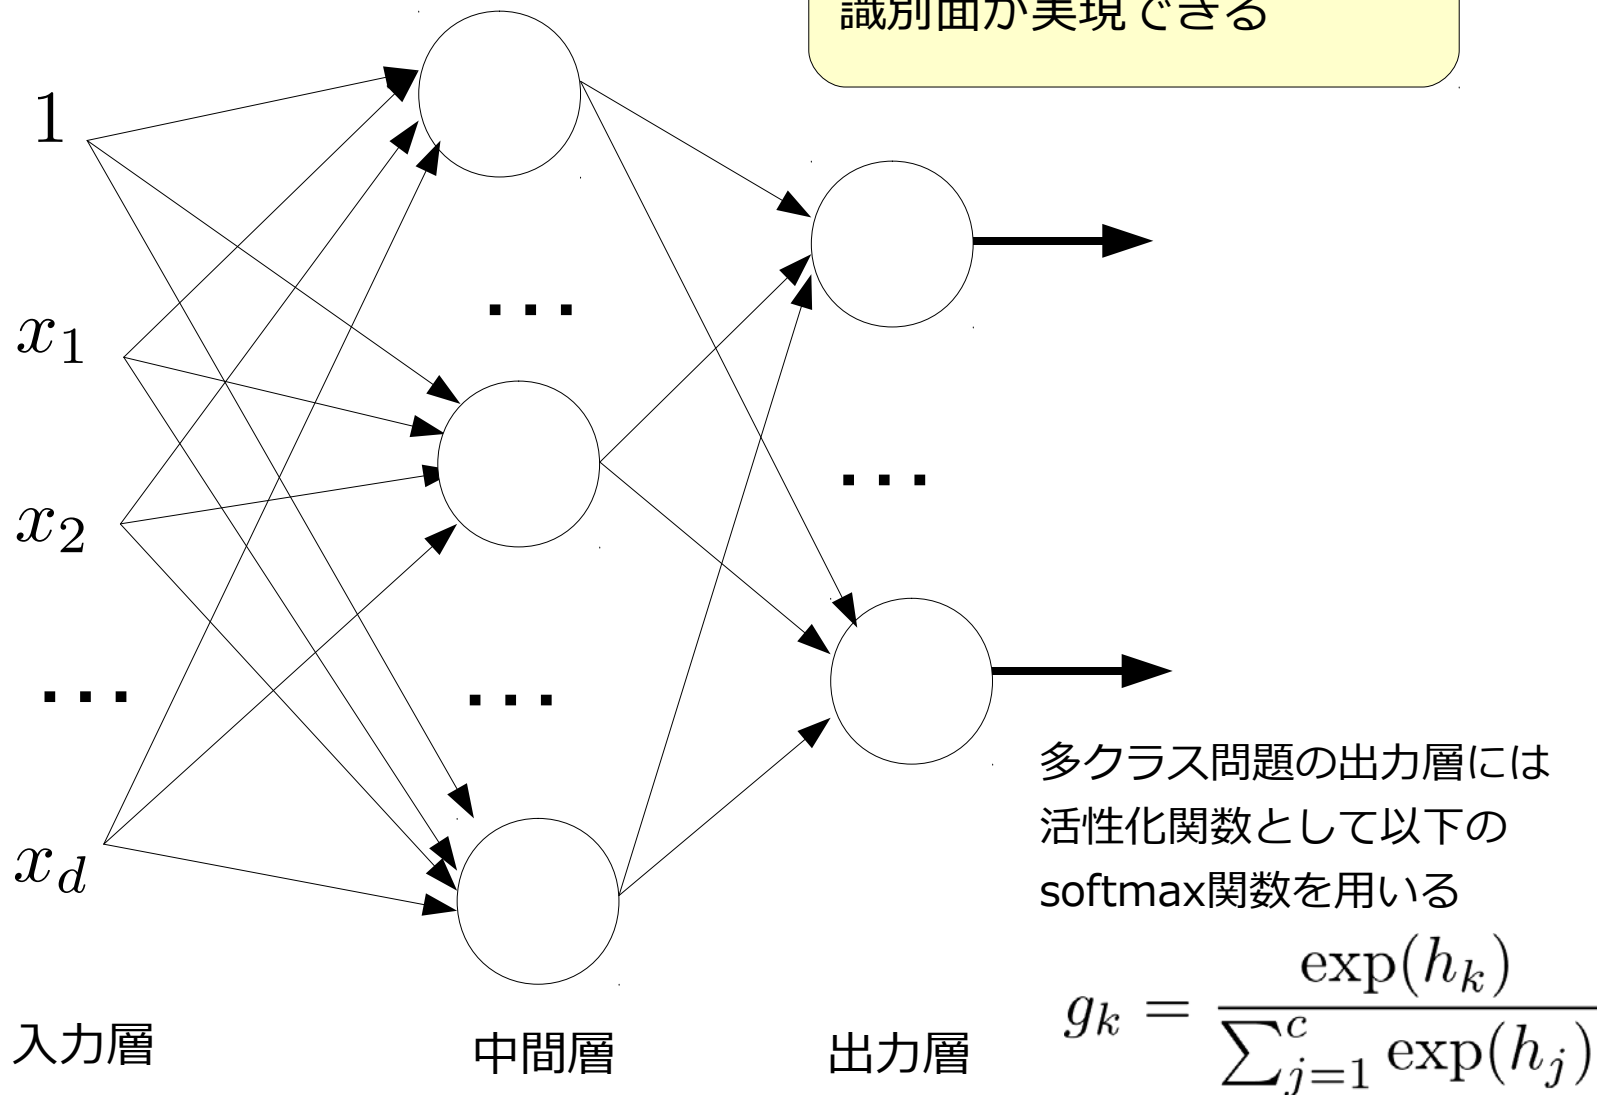
- $w^T x = 0$ という特徴空間上の識別面を表現



7.1 ニューラルネットワークの構成

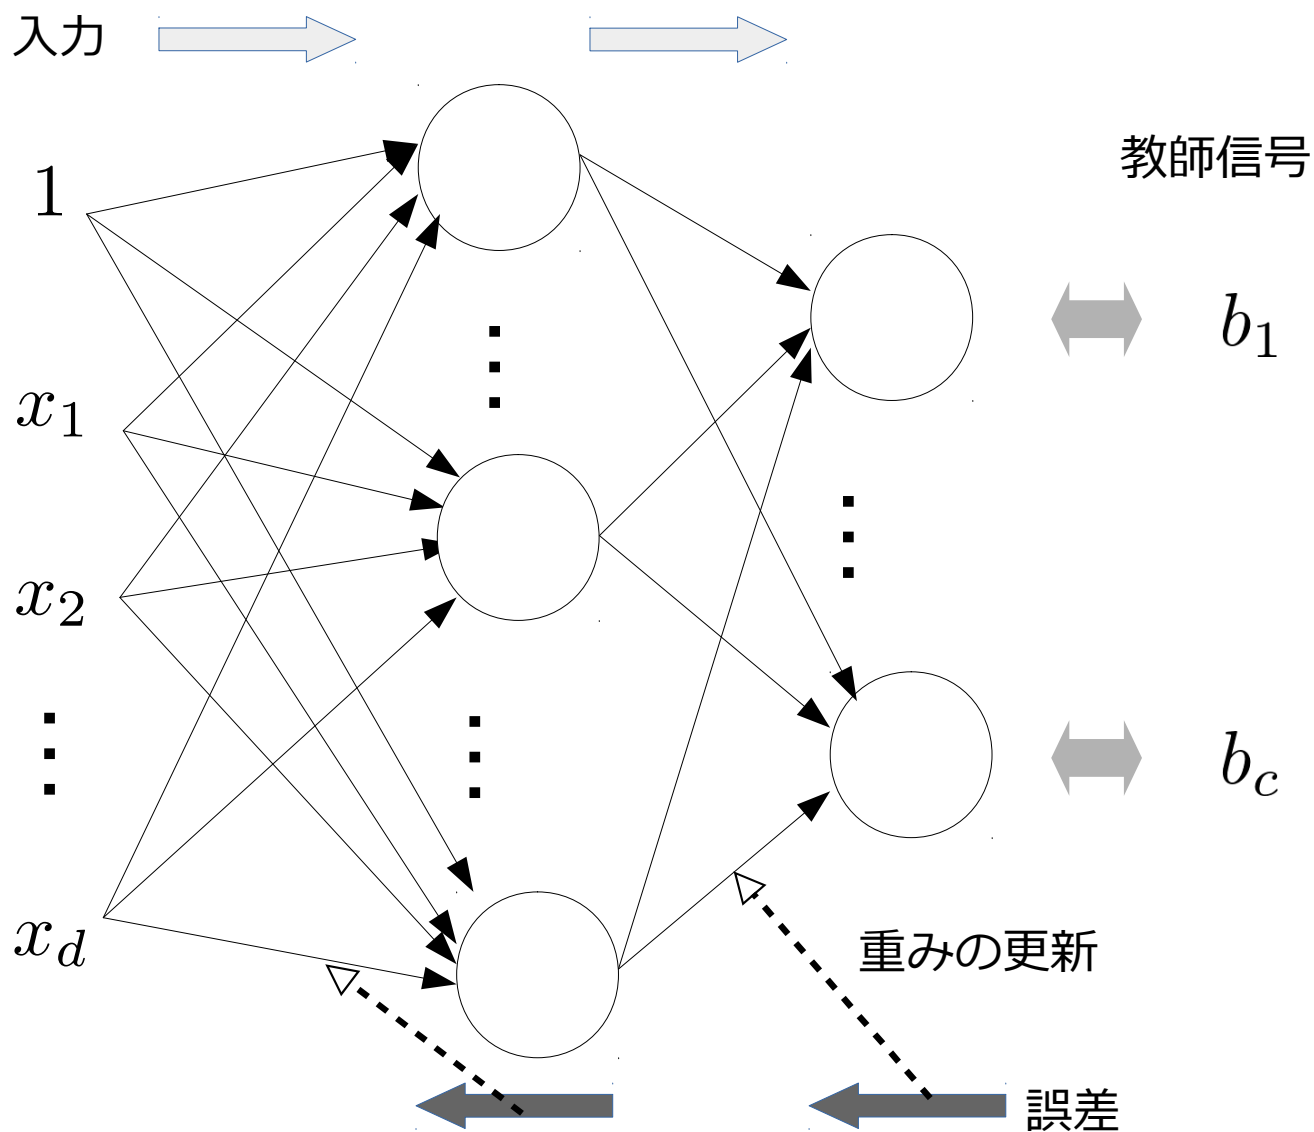
- 多層パーセプトロン

特徴空間上で複雑な非線形
識別面が実現できる



7.2 誤差逆伝播法による学習

- 誤差逆伝播法の名前の由来



7.2 誤差逆伝播法による学習

- 結合重みの調整アルゴリズム


- 二乗誤差

$$J(\boldsymbol{w}) \equiv \frac{1}{2} \sum_{p=1}^n (g(\boldsymbol{x}_p) - b_p)^2$$

全データに対する
正解と関数の出力
との差の2乗和

- J は \boldsymbol{w} の関数

- \boldsymbol{w} を J の勾配方向へ一定量だけ動かすことを繰り返して、最適解へ収束させる (→最急降下法)




$$\boldsymbol{w}' \leftarrow \boldsymbol{w} - \rho \frac{\partial J}{\partial \boldsymbol{w}}$$

ただし、ニューラルネットワーク
による識別面は非線形なので、
誤差関数はもっと複雑な形

7.2 誤差逆伝播法による学習

- 閾値論理ユニットの入出力



7.2 誤差逆伝播法による学習

- 学習パターン x_p が入力されたときのユニット j の入力

$$h_{jp} = \sum_i w_{ij} g_{ip}$$

- ユニット j の出力

$$g_{jp} = f(h_{jp})$$

- 出力層における誤差の定義

$$J_p = \frac{1}{2} \sum_l (g_{lp} - b_{lp})^2$$

- ユニット j の重みの調整式

$$w'_{ij} = w_{ij} - \rho \frac{\partial J_p}{\partial w_{ij}}$$

ユニット j の重み
が変化すれば、
誤差も変化する

7.2 誤差逆伝播法による学習

- 調整量の計算

$$\frac{\partial J_p}{\partial w_{ij}} = \frac{\partial J_p}{\partial h_{jp}} \cdot \frac{\partial h_{jp}}{\partial w_{ij}}$$

g_{ip}

- 右辺第1項を ε_{jp} とおく

$$\varepsilon_{jp} = \frac{\partial J_p}{\partial h_{jp}} = \frac{\partial J_p}{\partial g_{jp}} \cdot \frac{\partial g_{jp}}{\partial h_{jp}} = \frac{\partial J_p}{\partial g_{jp}} \cdot f'(h_{jp})$$

- ユニット j が出力層の場合

$$\frac{\partial J_p}{\partial g_{jp}} = g_{jp} - b_{jp}$$

- ユニット j が中間層の場合

$$\frac{\partial J_p}{\partial g_{jp}} = \sum_k \frac{\partial J_p}{\partial h_{kp}} \cdot \frac{\partial h_{kp}}{\partial g_{jp}} = \sum_k \varepsilon_{kp} w_{jk}$$


合成関数 $f(g(x))$ の微分

$y = f(u), u = g(x)$
と分けて

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$$

7.2 誤差逆伝播法による学習

- シグモイド関数の適用
 - 勾配計算の際に微分可能なものを用いる



7.2 誤差逆伝播法による学習

- 誤差の変化量

$$\varepsilon_{jp} = \begin{cases} (g_{jp} - b_{jp})g_{jp}(1 - g_{jp}) & \text{出力層の場合} \\ (\sum_k \varepsilon_{kp} w_{jk})g_{jp}(1 - g_{jp}) & \text{中間層の場合} \end{cases}$$

- 重みの修正式

$$w'_{ij} = \begin{cases} w_{ij} - \rho(g_{jp} - b_{jp})g_{jp}(1 - g_{jp})g_{ip} & \text{出力層の場合} \\ w_{ij} - \rho(\sum_k \varepsilon_{kp} w_{jk})g_{jp}(1 - g_{jp})g_{ip} & \text{中間層の場合} \end{cases}$$

7.2 誤差逆伝播法による学習

1. リンクの重みを小さな初期値に設定
2. 個々の学習データ (x_p, b_p) に対して以下繰り返し
 - a) 入力 x_p に対するネットワークの出力 g_p を計算
 - b) 出力層のk番目のユニットに対してエラー量 ε を計算

$$\varepsilon_k \leftarrow (g_k - b_k)g_k(1 - g_k)$$

- c) 中間層のh番目のユニットに対してエラー量 ε を計算

$$\varepsilon_j \leftarrow \left(\sum_k \varepsilon_k w_k \right) g_j (1 - g_j)$$


- d) 重みの更新

$$w_{ji} \leftarrow w_{ji} + \rho \varepsilon_j x_{pi}$$

局所最適解の可能性が高いので、初期値を変えて繰り返す


7.2 誤差逆伝播法による学習

- 識別面の複雑さ
 - 中間層のユニット数に関する
 - シグモイド関数（非線形）を任意の重み・方向で足し合わせることで複雑な非線形識別面を構成



7.3 ディープニューラルネットワーク

- 深層学習：多階層ニューラルネットによる学習
 - 表現学習：抽出する特徴も学習する




7.3.1 勾配消失問題とは

- 多階層における誤差逆伝播法の問題点
 - 修正量が消失／発散する


順方向：非線形

逆方向：線形



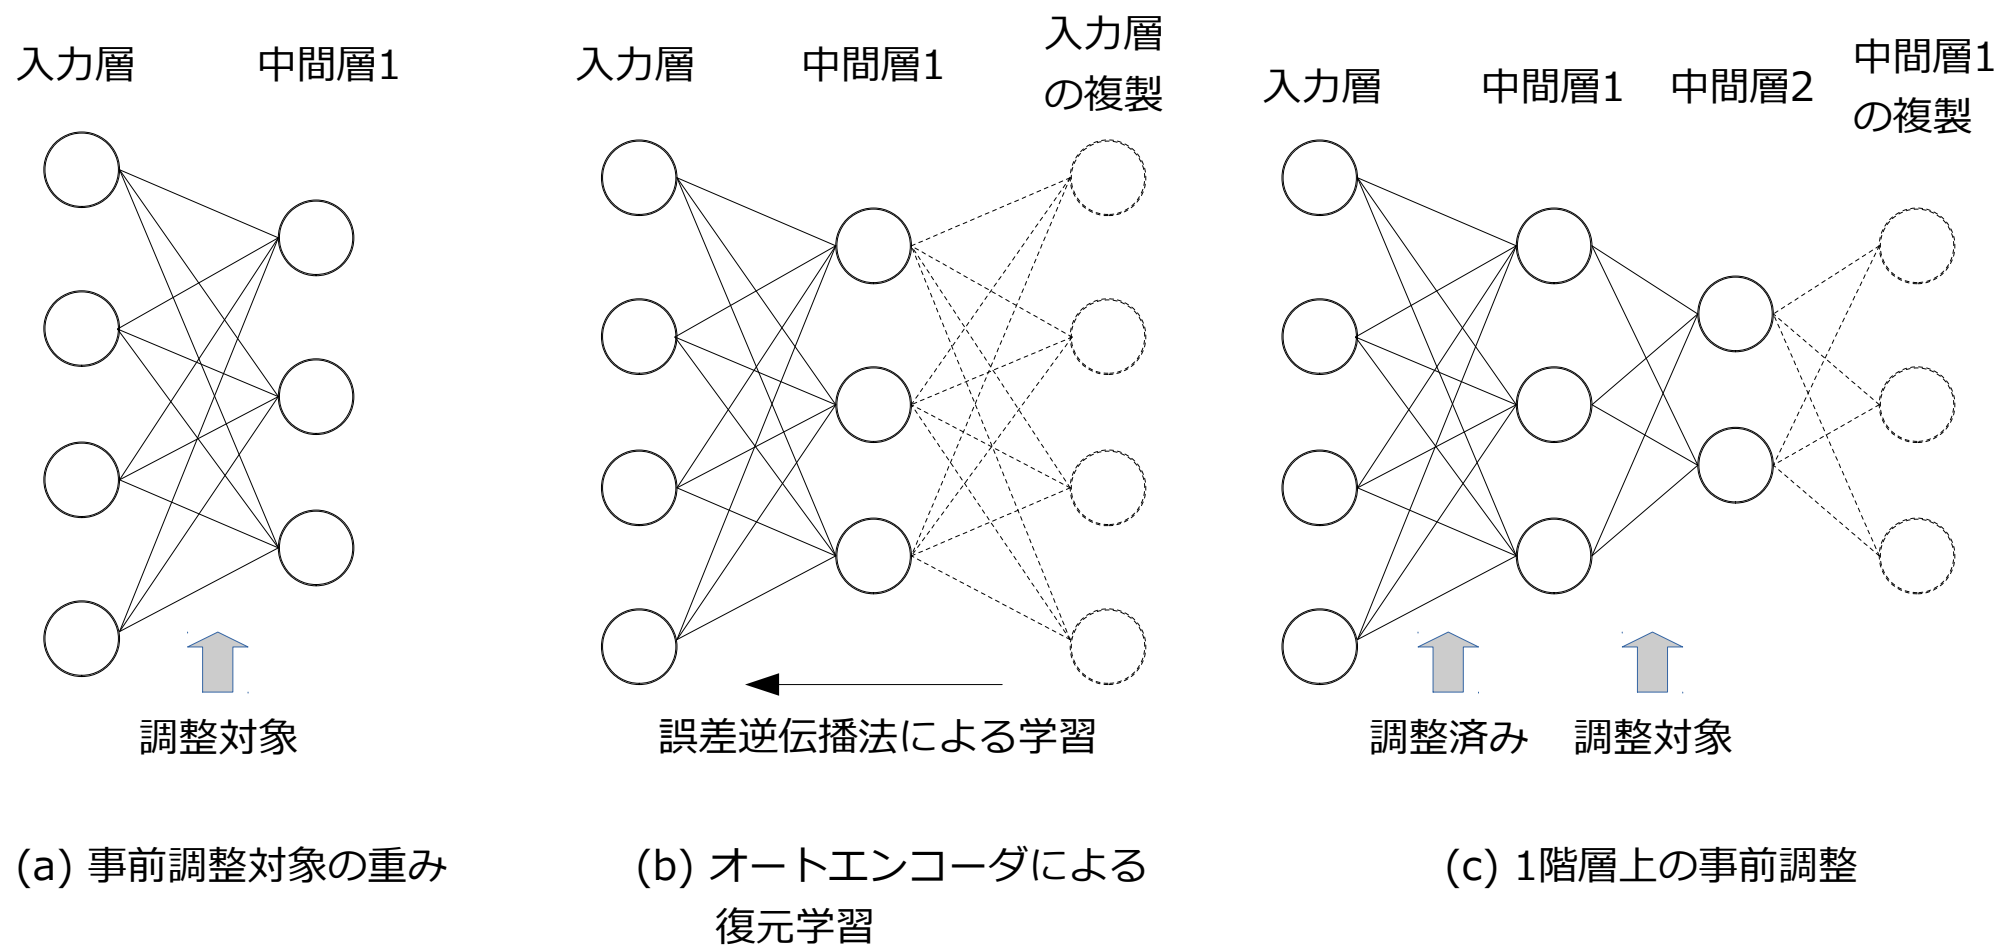
7.3.2 多階層学習における工夫

- 事前学習法
 - 深層学習における初期パラメータ学習



7.3.2 多階層学習における工夫


- 事前学習法のアイデア




7.3.2 多階層学習における工夫

- 活性化関数をrectified linear関数に ➡ RELU

$$f(x) = \max(0, x)$$



(a) rectified linear 関数




(b) (a)の導関数

- RELUの利点
 - 誤差消失が起こりにくい
 - 0を出力するユニットが多くなる

7.3.2 多階層学習における工夫


- 過学習の回避

- ドロップアウト：ランダムに一定割合のユニットを消して学習を行う




重みが偏る可能性
= 汎用性の低下

通常の学習




片方だけでもなるべく
正解に近づこうとする
= 汎用性の向上



学習した重みを p 倍


ドロップアウト
 $p = 0.5$



下位2つのユニットが活性化
(出力=1) したときのみ、上位
のユニットも活性化させたい

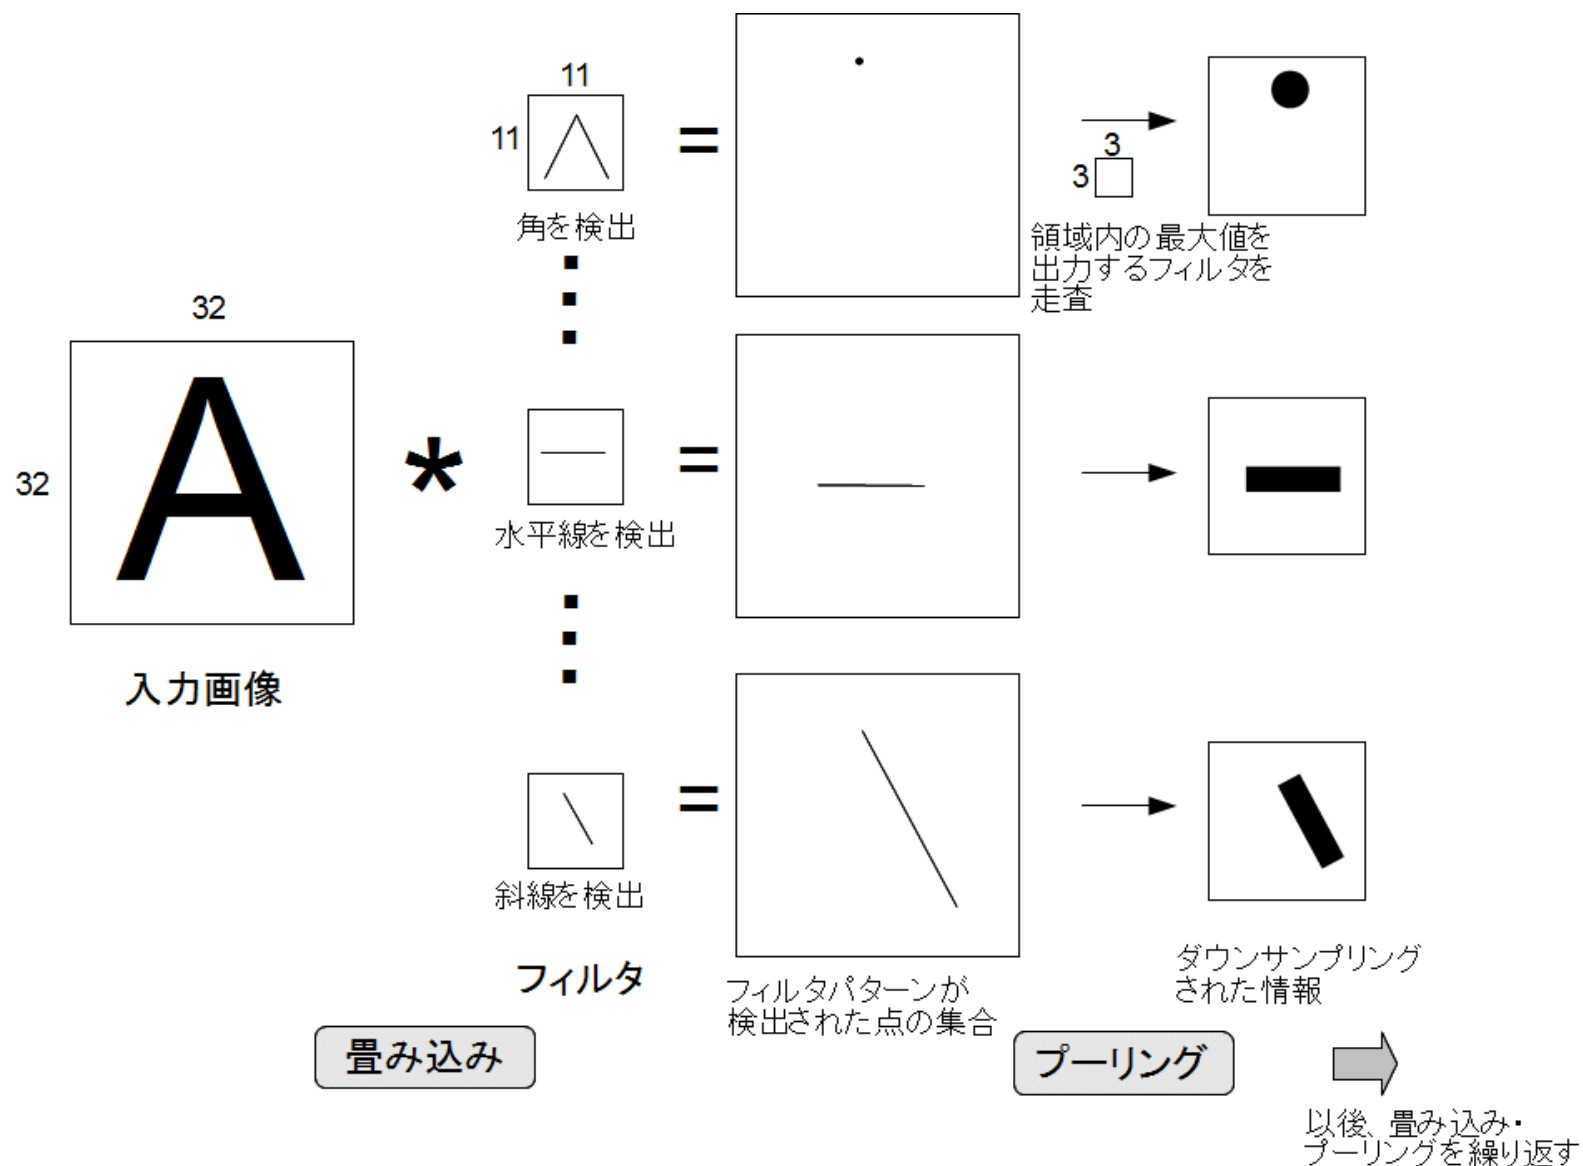
7.3.3 特化した構造をもつニューラルネットワーク

- 畳み込みニューラルネットワーク
 - 画像認識に適する




7.3.3 特化した構造をもつニューラルネットワーク

• 畳み込みニューラルネットワークの演算

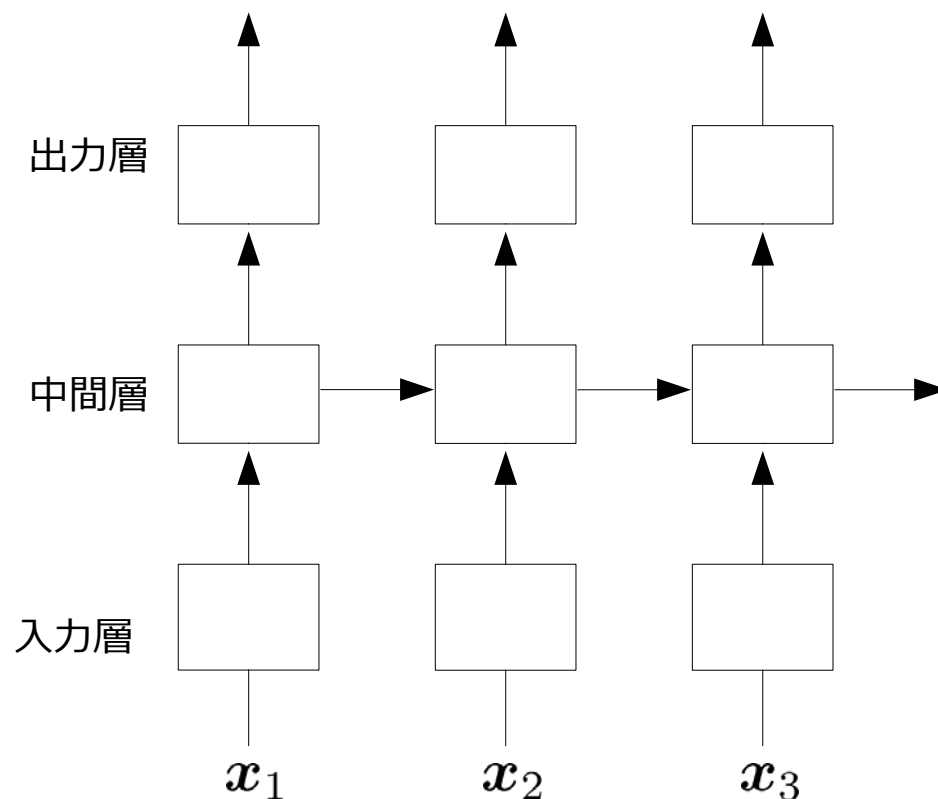


7.3.3 特化した構造をもつニューラルネットワーク

- リカレントニューラルネットワーク
 - 時系列信号の認識や自然言語処理に適する



(a) リカレントニューラルネットワーク



(b) 帰還路を時間方向に展開