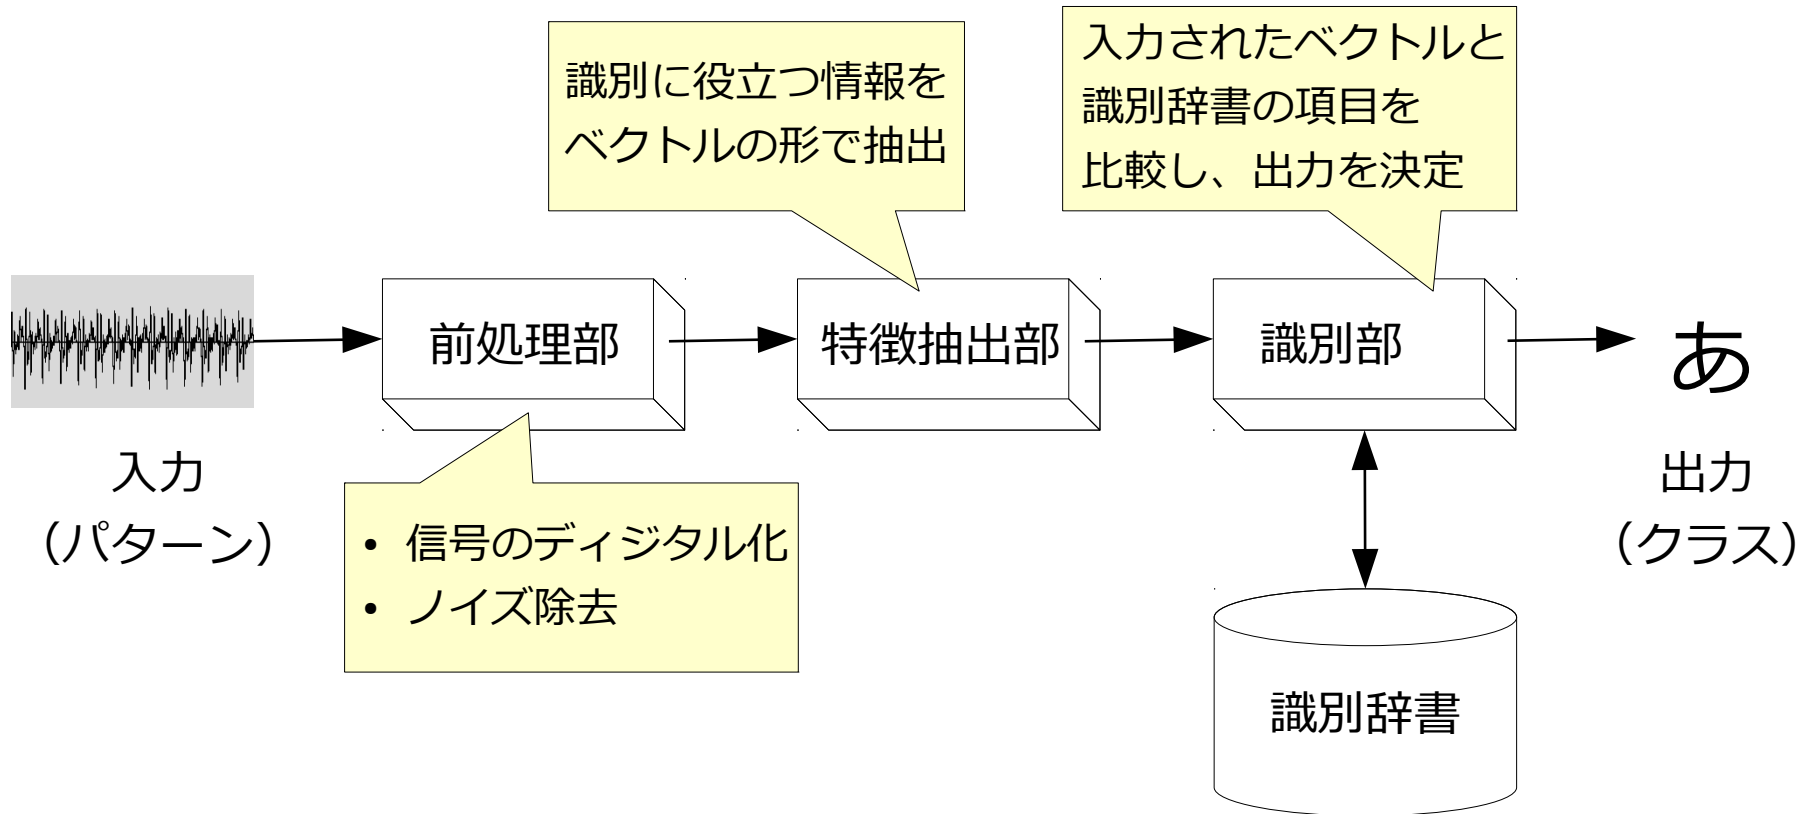
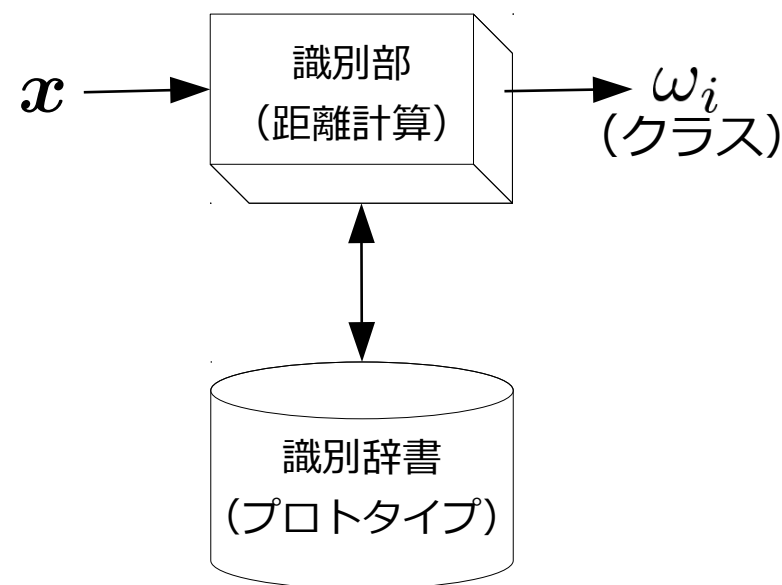
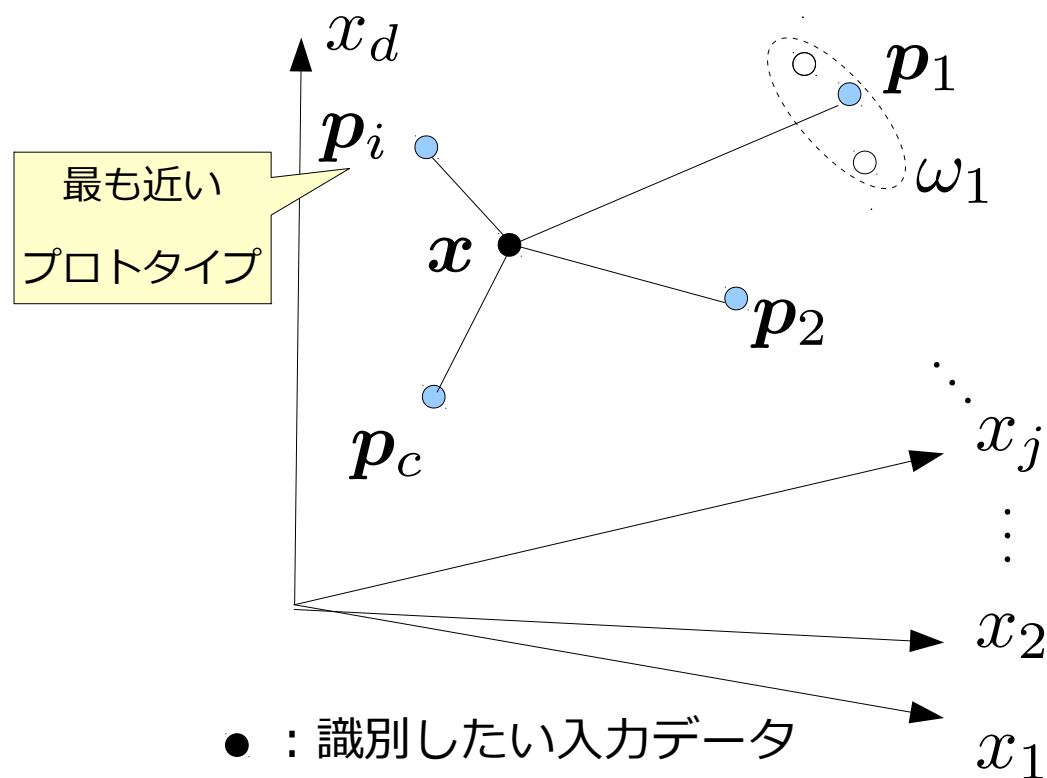


1. パターン認識システムの構成



1. 最近傍決定則 (NN 法)




$$\mathbf{x} = (x_1, x_2, \dots, x_d)^T$$

$$\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{id})^T$$


$$D(\mathbf{x}, \mathbf{p}_i) = \|\mathbf{x} - \mathbf{p}_i\| = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2 + \dots + (x_d - p_{id})^2}$$

2. アナログ信号のデジタル化



- 標本化と量子化
 - 細かすぎず、粗すぎず




アナログ信号



標本化



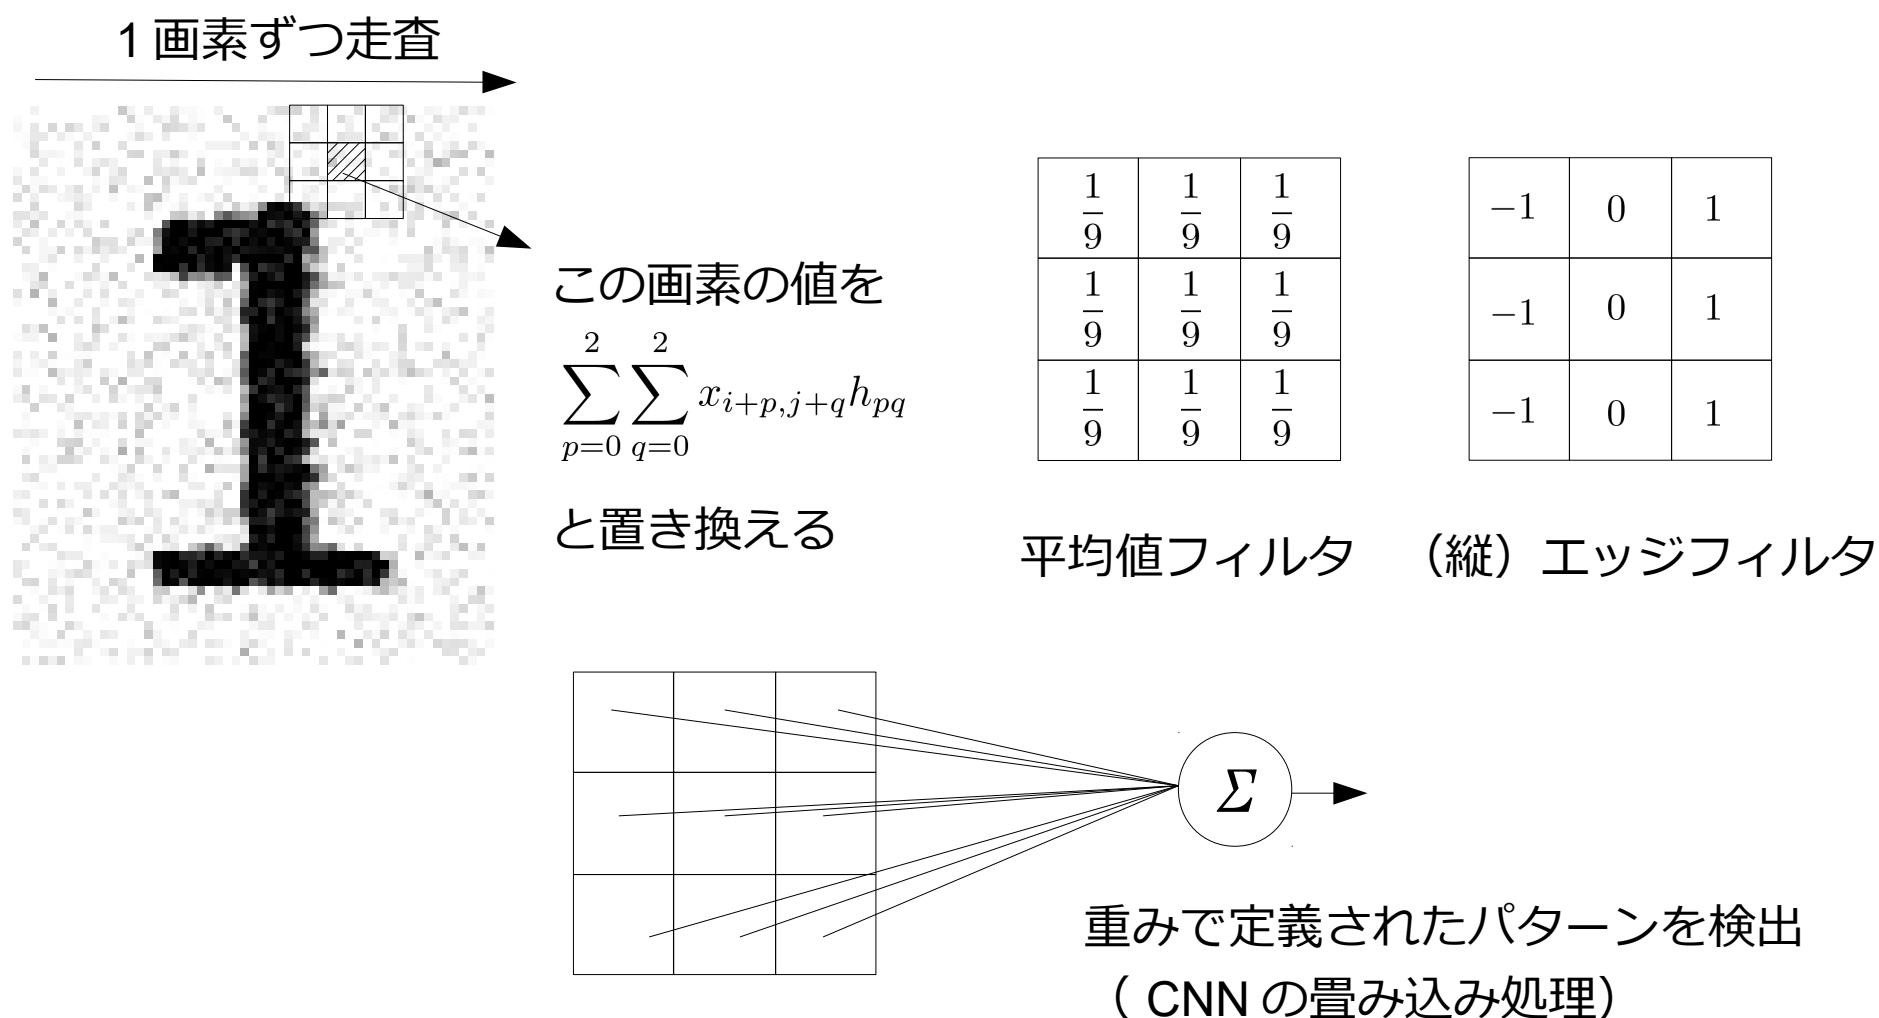
量子化



デジタル信号

2. 特徴抽出をしやすくする処理

- フィルタの適用



3. 特徴抽出部


- 特徴抽出部の入出力
 - 入力：デジタル信号
 - 出力：パターンの特徴を表す d 次元ベクトル

$$\boldsymbol{x} = (x_1, x_2, \dots, x_d)^T$$

- 特徴抽出処理
 - パターンの変動に影響されにくい特徴を選ぶ
 - 各軸のスケールを揃える：標準化処理

$$x'_i = \frac{x_i - m_i}{\sigma_i} \quad m_i, \sigma_i : \text{軸 } i \text{ の平均、標準偏差}$$

3. 主成分分析



共分散行列 Σ の計算

\bar{x}_1, \bar{x}_2 : 平均値、 N : データ数

対角成分は分散、
非対角成分は相関を表す

$$\Sigma = \frac{1}{N} \begin{pmatrix} \sum (x_1 - \bar{x}_1)^2 & \sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) \\ \sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) & \sum (x_2 - \bar{x}_2)^2 \end{pmatrix}$$

Σ は

半正定値(→固有値がすべて0以上の実数)

対称行列(→固有ベクトルが実数かつ直交)

であるので、以下のように分解できる


$$\Sigma' = U^T \Sigma U = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$$

λ は固有値の大きい順、 U は対応する固有ベクトル U_1, U_2 を並べたもの

λ_1 に対応する固有ベクトル U_1 で
2次元データを1次元に射影


$$u_1 = U_1^T x$$

$$\text{寄与率} = \frac{\lambda_1}{\lambda_1 + \lambda_2}$$



4. プロトタイプと識別面の関係

- 特徴空間の分割
 - クラスを分離する境界
 - …プロトタイプから等距離にある領域
 - 2次元の NN 法では垂直 2 等分線
 - 多次元では超平面
 - 決定境界あるいは
識別面と呼ぶ
 - 直線（超平面）で分割できる場合を**線形分離可能**と呼ぶ



4. 識別関数の設定

- 1 クラス 1 プロトタイプの NN 法の定式化
 - クラス : $\omega_1, \dots, \omega_c$
 - プロトタイプ : $\mathbf{p}_1, \dots, \mathbf{p}_c$
 - 入力パターン : \mathbf{x} (特徴ベクトル)
 - NN 法 : $D(\mathbf{x}, \mathbf{p}_i) = \|\mathbf{x} - \mathbf{p}_i\|$ を最小にする i を探す
 - $\rightarrow \|\mathbf{x} - \mathbf{p}_i\|^2 = \|\mathbf{x}\|^2 - 2\mathbf{p}_i^T \mathbf{x} + \|\mathbf{p}_i\|^2$
 - $\rightarrow g_i(\mathbf{x}) = \mathbf{p}_i^T \mathbf{x} - \frac{1}{2}\|\mathbf{p}_i\|^2$ を最大にする i を探す
 - $\rightarrow g_i(\mathbf{x}) = w_{i0} + \sum_{j=1}^d w_{ij} x_j = \mathbf{w}_i^T \mathbf{x}$
 - $d+1$ 次元

$\mathbf{x} \in \omega_i$ について、 $g_i(\mathbf{x})$ が最大になるように \mathbf{w} を調整すればよい

4. パーセプトロンの学習アルゴリズム

- 2 クラス識別で $g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ と定義
 1. \mathbf{w} の初期値を適当に決める
 2. 学習パターンからひとつ \mathbf{x} を選び、 $g(\mathbf{x})$ を計算
 3. 誤識別が起きたときのみ、 \mathbf{w} を修正

$$\mathbf{w}' = \mathbf{w} + \rho \mathbf{x} \quad (\text{クラス 1 のパターンをクラス 2 と誤ったとき})$$

$$\mathbf{w}' = \mathbf{w} - \rho \mathbf{x} \quad (\text{クラス 2 のパターンをクラス 1 と誤ったとき})$$


学習係数

4. 2,3 を全ての学習パターンについて繰り返す
5. すべて識別できたら終了。そうでなければ 2 へ

学習データが線形分離可能な場合は、識別面を見つけて終了

4. k-NN 法

- k-NN法とは
 - 全ての学習データをプロトタイプとする
 - 入力に近い順から k 個のプロトタイプのクラスを調べ、多数決を取る
 - 入力への近さを重みとした重み付き多数決を用いる場合もある



5. 誤差評価に基づく学習

- 2 クラス問題を考える場合

- 誤差関数

$$J(\mathbf{w}) = \frac{1}{2} \sum_{p=1}^n (\mathbf{w}^T \mathbf{x}_p - b_p)^2$$

最小二乗学習

- 教師信号 b_p は $\mathbf{x}_p \in \omega_1$ のとき 1、 $\mathbf{x}_p \in \omega_2$ のとき -1

- パターン行列 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)^T$

教師信号ベクトル $\mathbf{b} = (b_1, \dots, b_n)^T$

とすると $J(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{b}\|^2$

5. 誤差評価に基づく学習

- 解析的な解法

- $J(w)$ が最小となる w を求める

$$\frac{\partial J}{\partial w} = X^T (Xw - b) = 0$$

$$\Leftrightarrow X^T Xw = X^T b$$

$$\Leftrightarrow w = (X^T X)^{-1} X^T b$$

最小二乗法

- 最急降下法

$$\begin{aligned} w' &= w - \rho \frac{\partial J}{\partial w} \\ &= w - \rho \sum_{p=1}^n (w^T x_p - b_p) x_p \end{aligned}$$

確率的最急降下法

各データに対して更新


ミニバッチ法

適切な個数でまとめて更新

6. SVM

- 線形 SVM

- マージン最大となる線形識別面を求める



6. SVM

- 学習データ

$$\{(\mathbf{x}_i, y_i)\} \quad i = 1, \dots, n, \quad y_i = 1 \text{ or } -1$$

- 線形識別面の式

$$\mathbf{w}^T \mathbf{x} + w_0 = 0$$

- 識別面の制約の導入（係数を定数倍しても平面は不変）

$$\min_{i=1, \dots, n} |\mathbf{w}^T \mathbf{x}_i + w_0| = 1$$

- 学習パターンと識別面との最小距離（＝マージン）

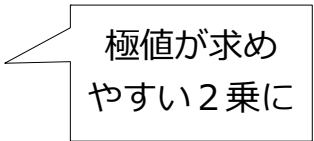
$$\min_{i=1, \dots, n} Dist(\mathbf{x}_i) = \min_{i=1, \dots, n} \frac{|\mathbf{w}^T \mathbf{x}_i + w_0|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

これを
最大化

点と直線の距離の公式

$$r = \frac{|ax + by + c|}{\sqrt{a^2 + b^2}}$$

6. SVM

- 目的関数： $\min \frac{1}{2} ||\mathbf{w}||^2$ 
- 制約条件： $y_i(\mathbf{w}^T \mathbf{x}_i + w_0) \geq 1 \quad i = 1, \dots, n$
- 解法：ラグランジュの未定乗数法
 - 問題 $\min f(x) \quad s.t. \quad g(x) = 0$
 - ラグランジュ関数 $L(x, \alpha) = f(x) - \alpha g(x)$
 - $\alpha \geq 0$
 - x, α で偏微分して 0 になる値が極値

6. SVM

- 計算

$$L(\mathbf{w}, w_0, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x} + w_0) - 1)$$

$$\frac{\partial L}{\partial w_0} = 0 \quad \Rightarrow \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$




$$L(\boldsymbol{\alpha}) = \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^n \alpha_i$$

$$\alpha_i \geq 0$$

最大化 2 次計画問題
→ $\boldsymbol{\alpha}$ が求まる

6. SVM

- 特徴ベクトルの次元数を増やす



ただし、元の空間でのデータ間の
距離関係は保持するように

6. SVM

- 非線形変換関数： $\phi(\mathbf{x})$
- カーネル関数
 - 元の空間での距離が変換後の空間の内積に対応

$$K(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}')$$

線形カーネル
 $(\mathbf{x}^T \mathbf{x}')^p$
を用いる場合もある

- カーネル関数の例

- 多項式カーネル $K(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + 1)^p$

- ガウシアンカーネル $K(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{\sigma^2}\right)$

この形であれば、対応する非線形変換が存在することが数学的に保証されている

6. SVM

- 変換後の識別関数： $g(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + w_0$
- SVM で求めた \mathbf{w} の値を代入

$$\begin{aligned} g(\mathbf{x}) &= \sum_{i=1}^n \alpha_i y_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) + w_0 \\ &= \sum_{i=1}^n \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i) + w_0 \end{aligned}$$

非線形変換の
式は不要！！！！

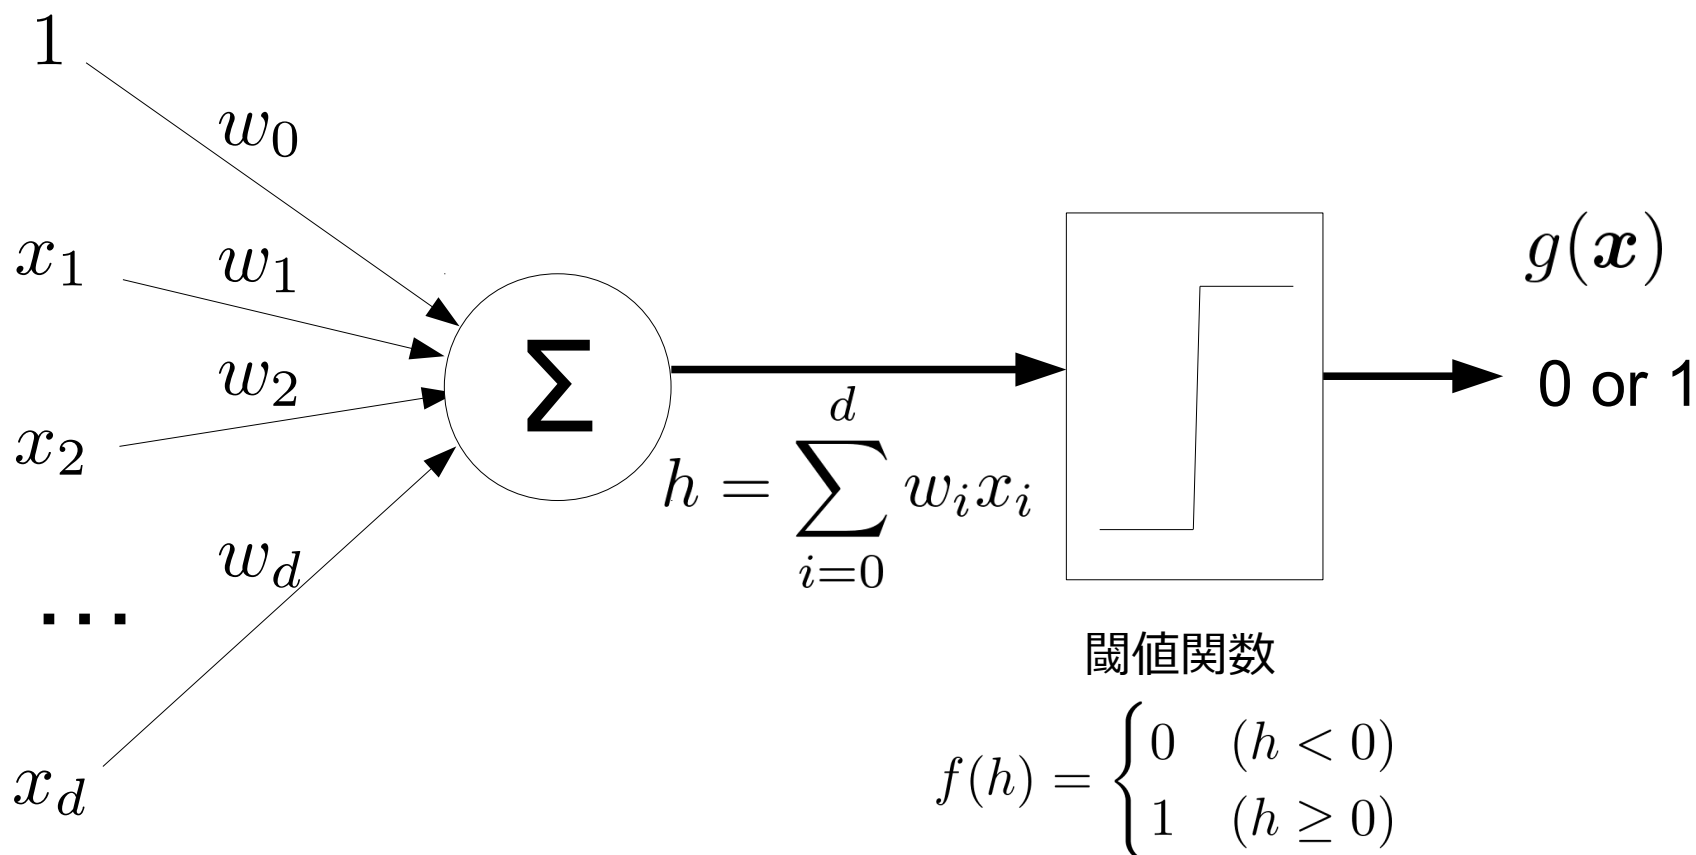
カーネルトリック

7. ニューラルネットワーク

- 単層パーセプトロンの定義

以後、 w は w_0 を含む

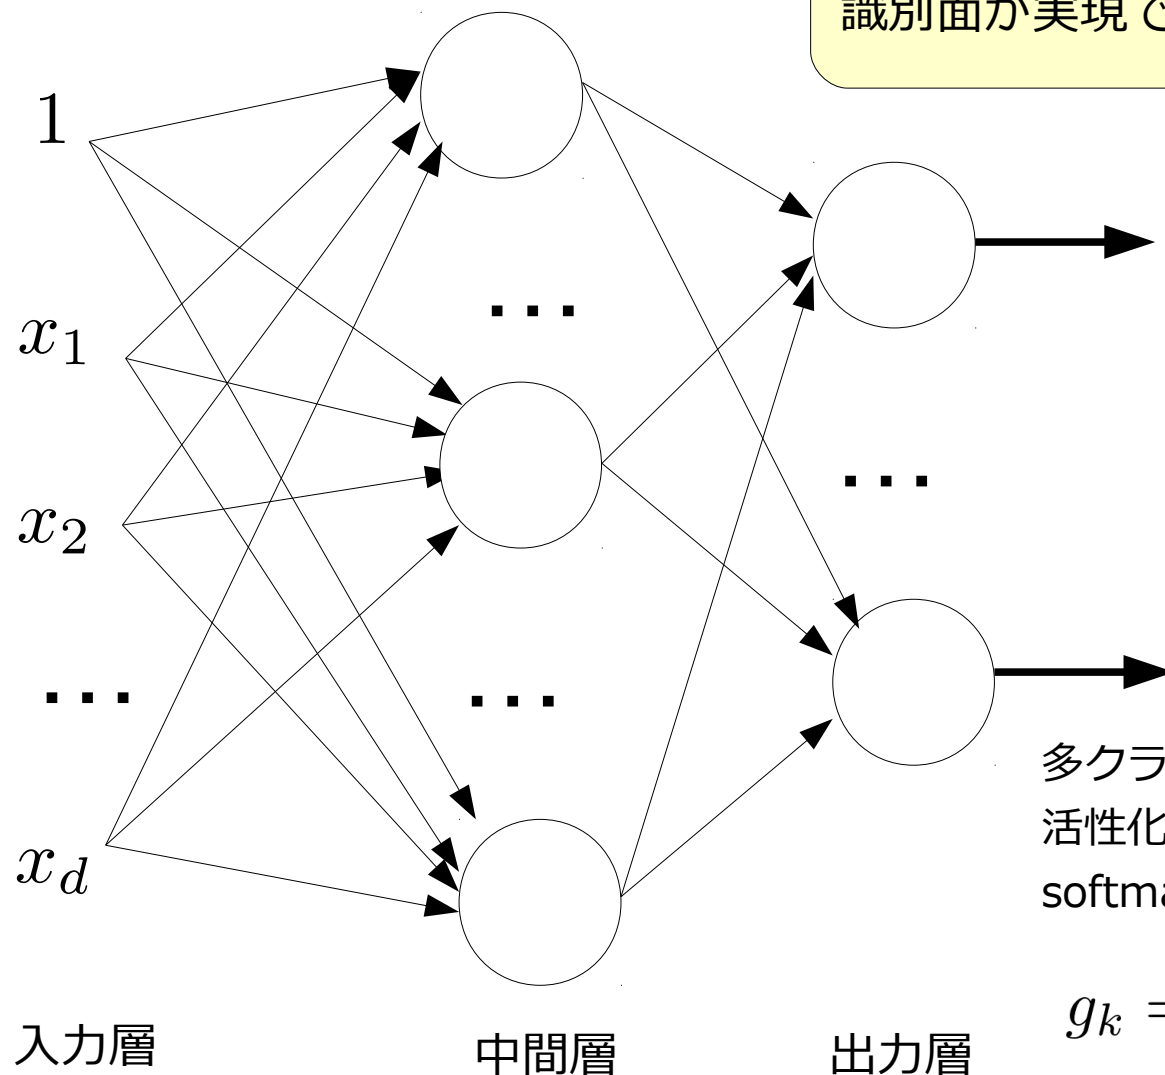
- $w^T x = 0$ という特徴空間上の識別面を表現



7. ニューラルネットワーク

- 多層パーセプトロン

特徴空間上で複雑な非線形
識別面が実現できる

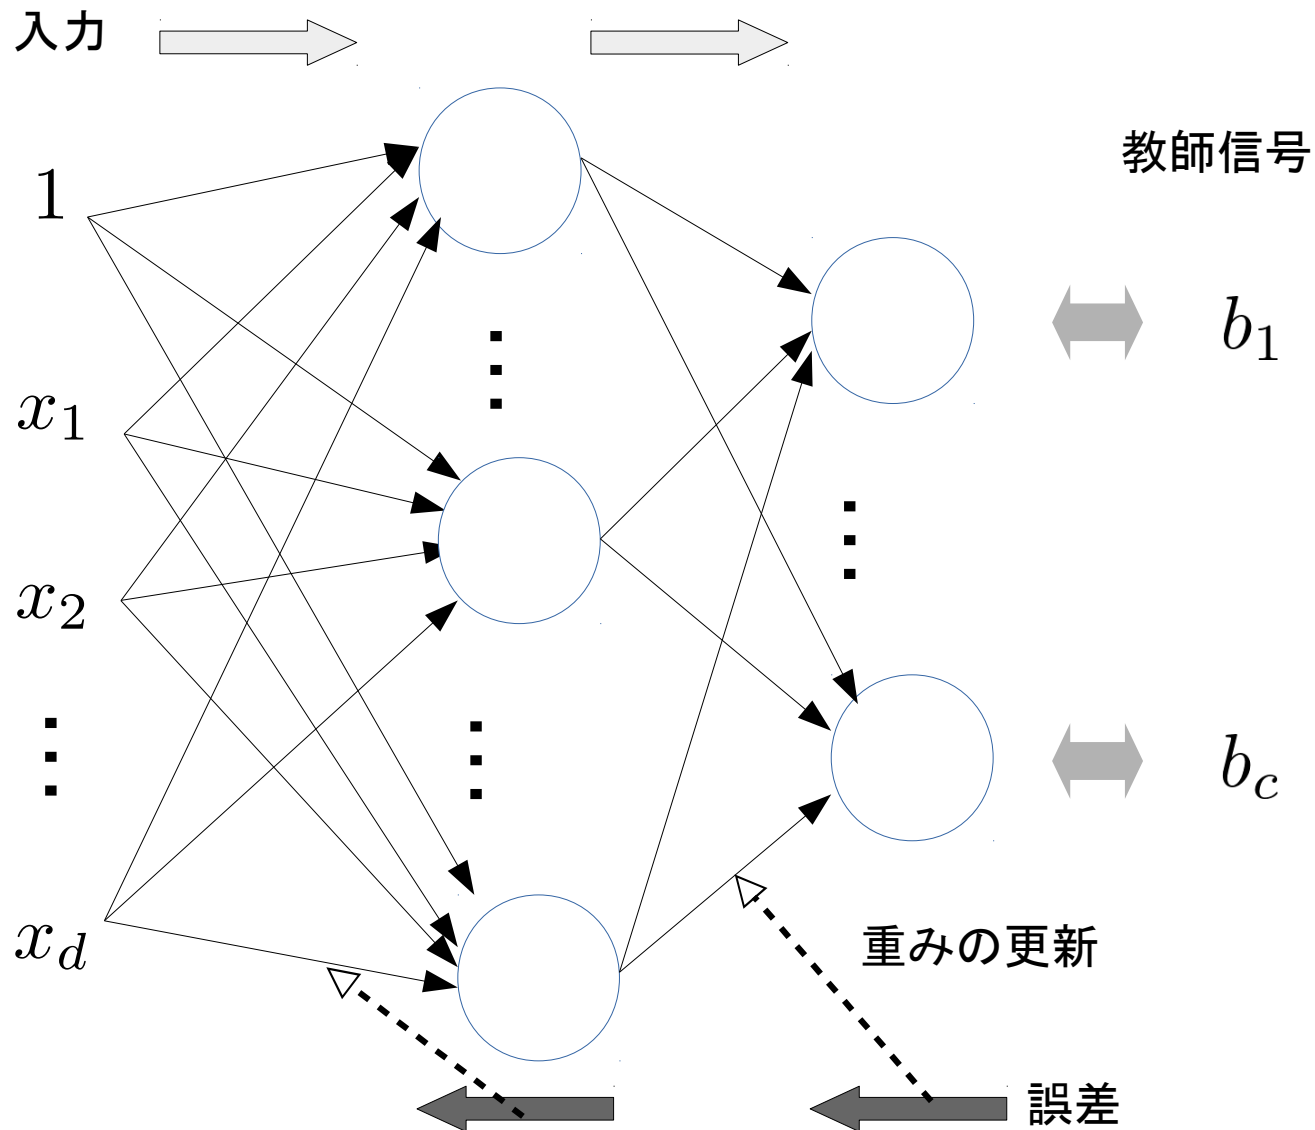


多クラス問題の出力層には
活性化関数として以下の
softmax 関数を用いる

$$g_k = \frac{\exp(h_k)}{\sum_{j=1}^c \exp(h_j)}$$

7. ニューラルネットワーク

- 誤差逆伝播法



7. ニューラルネットワーク

1. リンクの重みを小さな初期値に設定

2. 個々の学習データ (x_p, b_p) に対して以下繰り返し

a) 入力 x_p に対するネットワークの出力 g_p を計算

b) 出力層の k 番目のユニットに対してエラー量 ε を計算

$$\varepsilon_k \leftarrow (g_k - b_k)g_k(1 - g_k)$$

c) 中間層の h 番目のユニットに対してエラー量 ε を計算

$$\varepsilon_j \leftarrow \left(\sum_k \varepsilon_k w_k \right) g_j (1 - g_j)$$

d) 重みの更新

$$w_{ji} \leftarrow w_{ji} + \rho \varepsilon_j x_{pi}$$

局所最適解の可能性が高いので、初期値を変えて繰り返す

8. 統計的手法

- 事後確率最大法（ベイズ決定則）
 - $P(\omega_i | \mathbf{x})$ を最大にするクラス ω_i を識別結果とする

$$\arg \max_{i=1, \dots, c} P(\omega_i | \mathbf{x})$$

$$= \arg \max_{i=1, \dots, c} \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})}$$

ベイズの定理

$$= \arg \max_{i=1, \dots, c} p(\mathbf{x} | \omega_i) P(\omega_i)$$

8. 統計的手法

- 事前確率 $P(\omega_i)$ の求め方

- 最尤推定

- 学習データ数 : N
 - クラス ω_i のデータ数 : n_i
 - 事前確率の最尤推定値

$$P(\omega_i) = \frac{n_i}{N}$$


8. 統計的手法

- クラス分布 $p(\mathbf{x}|\omega_i)$ の求め方
 - 確率分布の形を仮定して、そのパラメータを学習データから推定
 - 例) 正規分布：平均と共分散行列を推定

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mathbf{m}_i)^t \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \mathbf{m}_i)\right\}$$


\mathbf{m}_i : 平均ベクトル

$\boldsymbol{\Sigma}_i$: 共分散行列

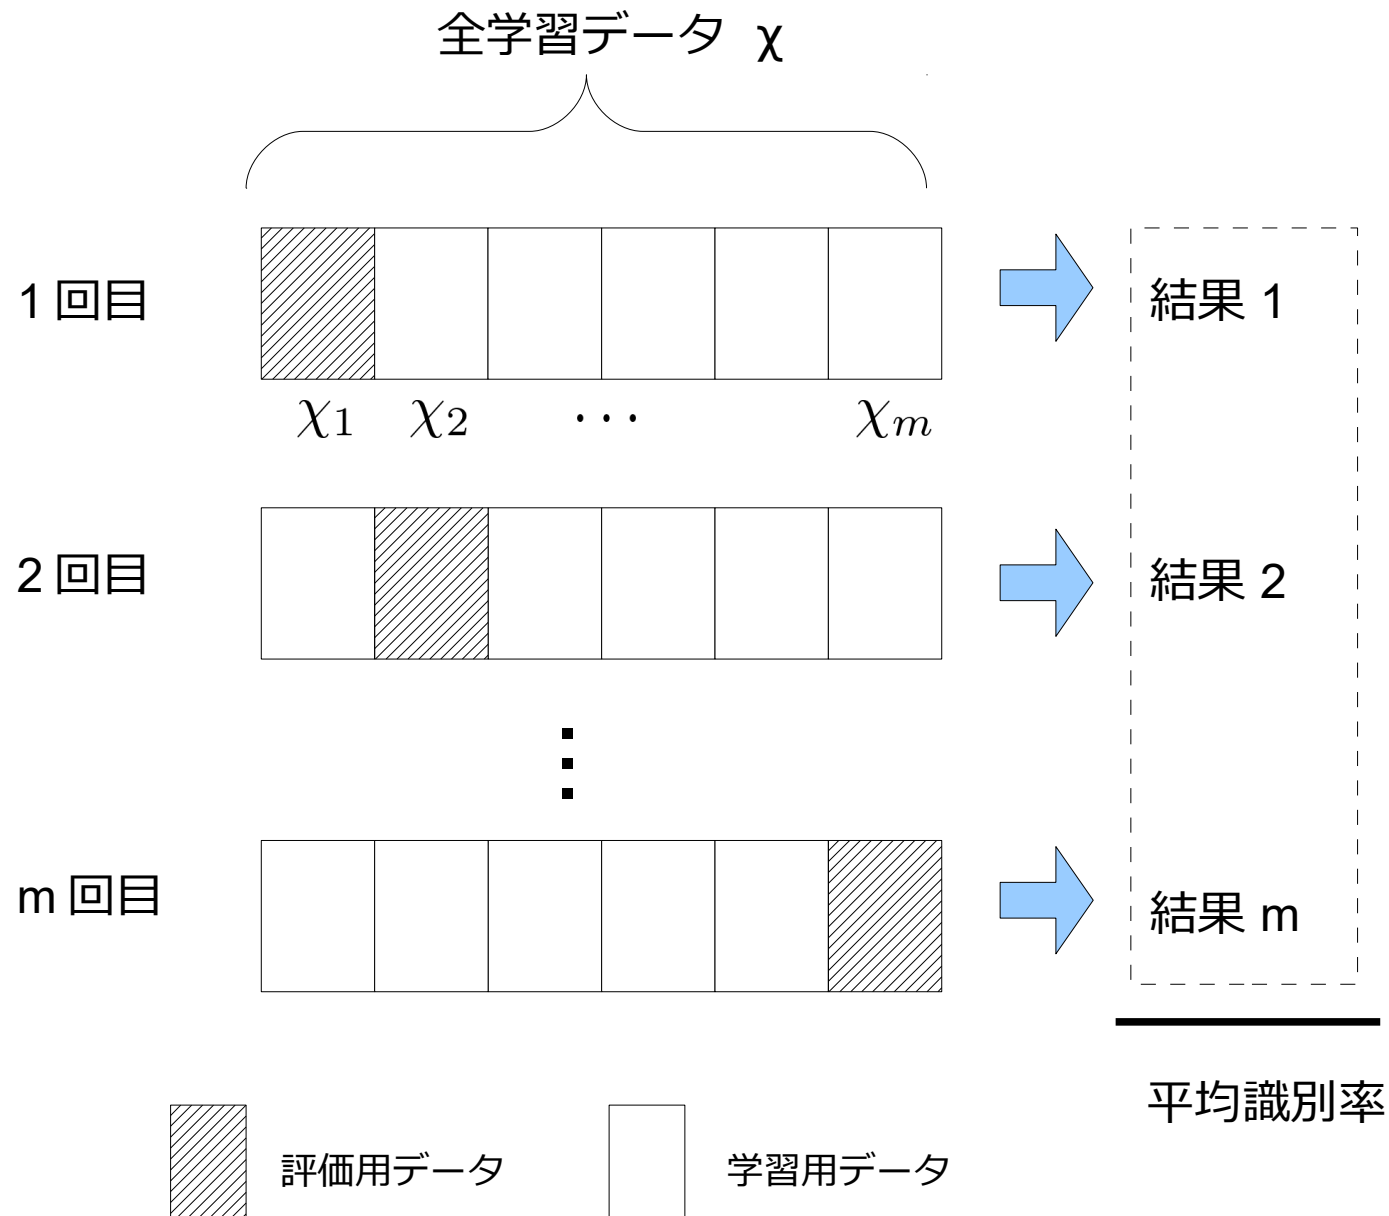


9. 分割学習法

- ハイパーパラメータ調整を含む分割学習法
 - 全学習データ χ を学習用データ集合 χ_T 、調整用データ集合 χ_H 、評価用データ集合 χ_E に分割する
 - χ_T を用いて識別機を設計、 χ_H を用いてハイパーパラメータを調整、 χ_E を用いて誤識別率を推定する



9. 交差確認法



9. ハイパーパラメータ調整

- パラメータ ➡ 学習可能
 - 識別関数の重み
 - ニューラルネットワークの結合の重み
 - k-NN 法のプロトタイプ的位置
- ハイパーパラメータ ➡ 学習結果によって調整
 - 識別関数の次数
 - ニューラルネットワークの中間ユニット数
 - k-NN 法の k

9. ハイパーパラメータ調整

- ハイパーパラメータが複数ある場合
 - グリッドサーチ：各格子点で e_λ を求める

