機械学習基礎実践 演習テキスト

荒木雅弘

2018 年 6 月 4 日

第 1 章

パターン認識概要

1.1　演習の目的

プロトタイプが与えられたという前提で、最近傍決定則を Scilab でコーディングし、パターン認識の基本的な手順を理解します。

1.2　準備

演習問題を解く際に用いる Scilab の機能を確認します。

1. 変数に行列を代入する
2. 行列のサイズを求める（`size` 関数）
3. 行列から特定の行を抜き出す
4. 行列から特定の列を抜き出す
5. ゼロ行列を作成する（`zeros` 関数）
6. 変数にベクトルを代入する
7. ベクトルの大きさを求める（`sum`,`sqrt`,`norm` 関数）
8. 2 つのベクトルの距離を求める
9. `for` 文による繰り返し
10. 変数の値を表示する（`disp` 関数）
11. 最小値を求める（`min` 関数）
12. 最小値を与える位置を求める
13. 行列を複製する（`repmat` 関数）
14. 行列を結合する
15. ベクトルを行列に変換
16. ベクトルを文字列に変換
17. 正規表現で文字列マッチング

```
--> M = [1 2 3; 4 5 6]
 M  =
    1.    2.    3.
    4.    5.    6.

--> [r c] = size(M)
```

```
 c  =
    3.
 r  =
    2.

--> size(M,'r')
 ans  =
   2.

--> size(M,'c')
 ans  =
   3.

--> M(1,:)
 ans  =
    1.    2.    3.

--> M(:,2)
 ans  =
    2.
    5.

--> zeros(2, 3)
 ans  =
    0.    0.    0.
    0.    0.    0.

--> z = zeros()
 z  =
   0.

--> z(3) = 5
 z  =
   0.
   0.
   5.

--> v1 = [1 1]
 v1  =
    1.    1.

--> v2 = [7 9]
 v2  =
    7.    9.

--> sqrt(sum(v1.^2))
 ans  =
    1.4142136

--> norm(v1)
 ans  =
    1.4142136

--> norm(v1 - v2)
 ans  =
    10.

--> for i = 1:5
-->   disp(i^2)
```

```
--> end

    1.
    4.
    9.
    16.
    25.

--> a = [5 8 7 2 3];

--> min(a)
 ans  =
    2.

--> [m, p] = min(a)
 p  =
    4.
 m  =
    2.

--> repmat(M,[1 2])
 ans  =
   1.   2.   3.   1.   2.   3.
   4.   5.   6.   4.   5.   6.

--> repmat(M,[2 1])
 ans  =
   1.   2.   3.
   4.   5.   6.
   1.   2.   3.
   4.   5.   6.

--> f=[]
 f  =
    []

--> f = [f [1 2]']
 f  =
   1.
   2.

--> f = [f [3 4]']
 f  =
   1.   3.
   2.   4.

--> matrix([1 2 3 4 5 6], [2, 3])
 ans  =
   1.   3.   5.
   2.   4.   6.

--> strcat(string([0 1 0 1 0]))
 ans  =
 01010

--> regexp(ans, '/101/')
 ans  =
   2.
```

実践演習 1-1

ソースコード 1.1 の（ア），（イ）を埋め，例題 1.1 の計算過程を実行する Scilab のコードを完成させよ．

ソースコード 1.1　例題 1.1

```
clear;
P = [[0,1,1,1,0,..
      1,0,0,0,1,..
      1,0,0,0,1,..
      1,0,0,0,1,..
      0,1,1,1,0]',..
     [0,0,1,0,0,..
      0,0,1,0,0,..
      0,0,1,0,0,..
      0,0,1,0,0,..
      0,0,1,0,0]',..
     [0,1,1,1,1,..
      1,0,0,1,0,..
      0,0,1,0,0,..
      0,1,0,0,0,..
      1,1,1,1,1]',..
     [0,1,1,1,0,..
      1,0,0,0,1,..
      0,0,1,1,0,..
      1,0,0,0,1,..
      0,1,1,1,0]',..
     [0,0,1,0,0,..
      0,1,0,0,0,..
      1,0,0,1,0,..
      1,1,1,1,1,..
      0,0,0,1,0]'];

x = [0,0,0,1,0,..
     0,0,0,1,0,..
     0,0,0,1,0,..
     0,0,0,1,0,..
     0,0,0,1,0]';

dist = zeros();
for i = 1:  （ア）
    dist(i) = norm(P(  （イ）  ) - x);
end

[mindist, ans] = min(dist);
disp("Ans = "+string(ans-1))
```

実践演習 1-2

ソースコード 1.1 の `for` ループ処理を `repmat` 関数を用いた行列演算に置き換えよ．

実践演習 1-3

演習問題 1.1 の指示に従い，特徴抽出を行う機能をソースコード 1.1 に追加して，特徴抽出後の特徴ベクトルを用いて識別を行え．ただし，特徴ベクトルは，縦・横の直線数の計算のみでよい．

第 2 章

前処理

2.1 演習の目的

画像データを対象に、パターン認識の前処理段階で行うフィルタ処理を Scilab でコーディングし、効果を確認します。

2.2 Scilab への画像処理モジュールインストール

Scilab で画像を扱う際には、外部モジュールである Image Processing and Computer Vision Module を使うと便利です。以下の手順でインストールしてください。

1. Scilab を起動後、メニューの [アプリケーション] から [モジュール管理] を選択し、モジュール管理画面を表示。
2. 左側ペインから [画像処理] を選択。
3. 画像処理が展開され、[Image Processing and Computer Vision Toolbox] が表示されるので、それを選択。
4. 右側ペインの [インストール] ボタンを押してインストール開始。
5. インストールが終了したら Scilab を再起動し、起動後に”Start IPCV 1.2 for Scilab 6.0”というメッセージが表示されればインストール成功。

2.3 準備

演習では、扱いやすい濃淡画像を対象データとします。画像を行列データとして読み込んだ後、各種フィルタ処理を Scilab でコーディングします。

1. 画像データを行列として読み込む（`imread` 関数）
2. 画像データを倍精度浮動小数点数に変換 （`im2double` 関数）
3. 画像を表示する（`imshow` 関数）
4. 画像をファイルに出力する（`imwrite` 関数）
5. 中間値を求める（`median` 関数）
6. 2 重ループ

```
-->im=imread('test1.pgm')  // im は整数（0〜255）の 120x120 行列
```

```
-->im2=im2double(im)    // 整数から倍精度表現（0〜1）に変換

-->imshow(im2)
```

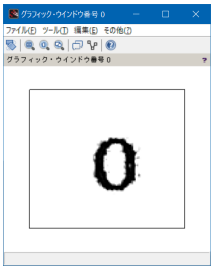

```
-->imwrite(im2, 'out.png') // pgm, jpg, png, bmp, tiff も可

-->a = [5 8 7 2 3];

-->median(a)
 ans  =
    5.

-->b = [5 8 7 2 3 4];

-->median(b)
 ans  =
    4.5

-->for i=1:9
-->  for j=1:9
-->   printf("%3d",i*j)
-->  end
-->  printf("\n")
-->end
  1  2  3  4  5  6  7  8  9
  2  4  6  8 10 12 14 16 18
  3  6  9 12 15 18 21 24 27
  4  8 12 16 20 24 28 32 36
  5 10 15 20 25 30 35 40 45
  6 12 18 24 30 36 42 48 54
  7 14 21 28 35 42 49 56 63
  8 16 24 32 40 48 56 64 72
  9 18 27 36 45 54 63 72 81
```

実践演習 2-1

空欄（ア），（イ）を埋め，入力画像にメディアンフィルタを適用する Scilab のコードを完成させよ．

```
clear;

// 画像データの読み込み
im = im2double(imread('test1.pgm'));
// 2次元配列 im のサイズ取得
[h w] = size(im);
// 結果格納用の配列 resultim を用意
resultim = ones(im);
```

```
// メディアンフィルタ適用
for y = 2:h-1
    for x = 2:w-1
        resultim(   (ア)     ) = median(im(    (イ)    ));
    end
end

// 結果の表示とファイルへの出力
imshow([im, resultim])
imwrite([im, resultim], 'out.png');
```

実践演習 2-2

実践演習 2-1 のコードに平均値フィルタ処理を加え、原画像、メディアンフィルタ適用後、平均値フィルタ適用後の画像を並べて結果を比較せよ。

実践演習 2-3

入力画像に Sobel フィルタ（第 2 章講義スライド参照）を適用するコードを作成せよ。

実践演習 2-4

実践演習 2-3 のコードに、最大値プーリングを行う処理を追加せよ。

第 3 章

特徴抽出

3.1　演習の目的

パターン認識の特徴抽出段階で行う標準化と主成分分析を Scilab でコーディングし、多次元データの可視化手順を習得します。

3.2　準備

1. 平均値を求める（mean 関数）
2. 分散を求める（variance 関数）
3. 標準偏差を求める（stdev 関数）
4. 行列に対し、列ごとに平均値・分散を求める
5. 行列に対し、共分散行列を求める（cov 関数）
6. 主成分分析を行う（pca 関数）
7. 複数のグラフの表示場所を設定する（subplot 関数）
8. グラフを表示する（plot2d 関数）
9. CSV ファイルを読み込む （csvRead 関数）

```
-->a = [5 8 7 2 3];

-->mean(a)
 ans  =
    5.

-->variance(a)
 ans  =
    6.5

-->stdev(a)
 ans  =
    2.5495098

-->M = [5 5; 8 4; 7 6; 2 8; 3 9]
 M  =
    5.    5.
    8.    4.
    7.    6.
    2.    8.
```

```
    3.    9.

-->mean(M, 'r')
 ans  =
    5.    6.4

-->variance(M, 'r')
 ans  =
    6.5    4.3

-->cov(M)
 ans  =
    6.5  - 4.5
  - 4.5    4.3

-->[l f c] = pca(M)
 c  =                          // 主成分
  - 0.4773960    0.4773960
  - 1.6504435  - 0.0136571
  - 0.6910991  - 0.4183013
    1.3776458    0.2864548
    1.4412928  - 0.3318924
 f  =                          // 固有ベクトル
  - 0.7071068  - 0.7071068
    0.7071068  - 0.7071068
 l  =                          // 固有値・全体に対する比
    1.8511804    0.9255902
    0.1488196    0.0744098

--> subplot(2, 1 ,1)

--> plot2d(M(:,1), M(:,2), style=-9, rect=[0,0,10,10])

--> subplot(2, 1 ,2)

--> plot2d(c(:,1)', zeros(1,length(c(:,1))), style=-4, rect=[-2,-1,2,1])

--> M = csvRead('iris.csv');
```

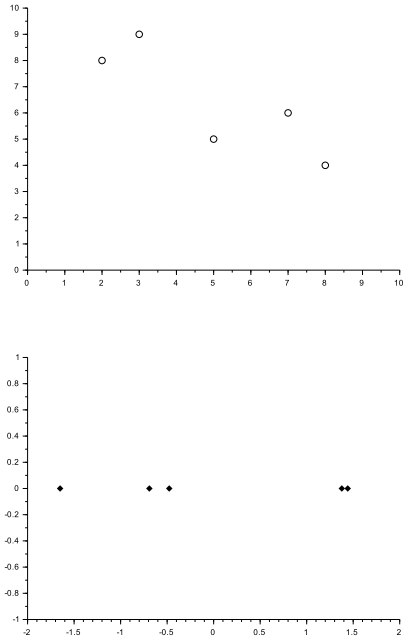

実践演習 3-1

ソースコード 3.1 の空欄を埋め、データの標準化と主成分分析を行う Scilab のコードを完成させよ。

ソースコード 3.1　標準化・主成分分析

```
clear;

x=[3 2; 3 4; 5 4; 5 6];
[n d] =  （ア） (x);
// 元データの表示
subplot(2,1,1);
plot2d(x(:,1), x(:,2), style=-9, rect=[0,0,8,8])

// 標準化
m =   （イ）  (x, 'r');
s =   （ウ）  (x, 'r');
normX = (x - repmat( （エ） ,[n,1])) ./ repmat( （オ） , [n,1]);

// 標準化後のデータの表示
subplot(2,1,2);
plot2d(normX(:,1), normX(:,2), style=-10, rect=[-2,-2,2,2])

// 主成分分析
[lambda, facpr, comprinc] =   （カ）  (normX);
z = normX * facpr(:,1);
disp(z)
```

実践演習 3-2

アヤメの分類問題のサンプルデータ iris.csv を読み込み、4 次元のデータを 2 次元で可視化せよ。なお、iris データは、花びらの幅・長さ、萼の幅・長さのデータから、3 種類のアヤメを識別するための学習データである。

第 4 章

最近傍決定則

4.1 演習の目的

パーセプトロンのアルゴリズムと k-NN 法を Scilab で実装し、学習手順や認識手順を確認します。

4.2 準備

1. 論理値型 (T or F)
2. ソート （gsort 関数）
3. ベクトルの一部を抜き出す
4. ベクトルの指定した要素（複数）をその順番に抜き出す
5. 要素数を数える（member 関数）

```
-->f = %T
 f  =
  T

-->if f
-->  disp(3)
-->end
    3.

-->f = %F
 f  =
  F

-->if f
-->  disp(3)
-->end

-->v = [50 33 89 78 45];

-->gsort(v)
 ans  =
   89.   78.   50.   45.   33.

-->gsort(v,'g','i')  // 昇順'i' を指定するためにはソートの種類（全要素）を表す'g' も必要
 ans  =
   33.   45.   50.   78.   89.
```

```
-->[a b] = gsort(v,'g','i')  // b は整列後の結果の元の位置
 b  =
   2.   5.   1.   4.   3.
 a  =
   33.   45.   50.   78.   89.

-->v(1:3)  // ベクトル v の先頭から 3 要素
 ans  =
   50.   33.   89.

-->v([2 1 5])  // ベクトル v の第 2, 第 1, 第 5 要素
 ans  =
   33.   50.   45.

-->v2 = [1 2 1 1 2 1 1 3 2];

-->members(1, v2)  // ベクトル v2 に 1 が各何回出現したか
 ans  =
    5.

-->members([1:3],v2)  // ベクトル v2 に 1 から 3 がそれぞれ何回出現したか
 ans  =
    5.    3.    1.
```

実践演習 4-1

パーセプトロンの学習規則を記述した以下の Scilab のコードを完成させよ。学習データは教科書例題 4.2（p.53）に示すものである。

```
clear;
X = [1.0; 0.5; -0.2; -1.3]; // 学習データ
y = [1 1 2 2]'; // 正解クラス
w = [0.2, 0.3]'; // 初期重み
roh = 0.5; // 学習係数
flag = %T;  // 重みに変更があれば TRUE(%T)
[n, d] = size(X);
X = [ones(n,1), X]; // x_0 軸を追加

while flag
  flag = %F;
  for i = 1:n
    x = X(i,:)'
    g = w' * x;
    disp(w');
    if y(i) == (ア)    & (イ)
      w = w + roh *  (ウ)   ;
      flag = %T;
    elseif y(i) ==  (エ)   &  (オ)
      w = w - roh *   (ウ)    ;
      flag = %T;
    end
  end
end
printf("Results: w0=%6.3f, w1=%6.3f\n",w(1), w(2));
```

実践演習 4-2

3-NN 法（多数決）を Scilab を用いてコーディングし，教科書例題 4.4（p.59）中の図 4.17 に示す学習データを用いて，$\boldsymbol{x} = (3, 4)$ を識別せよ．

```
clear;
X = [1 4; 2 3; 4 3; 5 4; 2 1; 3 2; 3 3; 4 1]; // 学習データ
y = [1 1 1 1 2 2 2 2]'; // 正解クラス
k = 3;
x = [3 4]'; // 入力
[n, d] = size(X);

// 入力と学習データとの距離を計算
dist = sqrt(sum((X-repmat(x', [n,1])) .^2, 'c'));

// k−NNによる識別
...
```

実践演習 4-3

実践演習 4-2 で作成したコードで、$\boldsymbol{x} = (2.1, 3)$ を識別すると、ごく近いクラス ω_1 のデータ $(2, 3)$ があるにも関わらず、クラス ω_2 に識別されてしまう。このようなことを避けるために、近いものから k 個のデータまでの距離の逆数を重みとし、クラスごとの重みの総和で識別結果を出すようなコードに変更せよ。