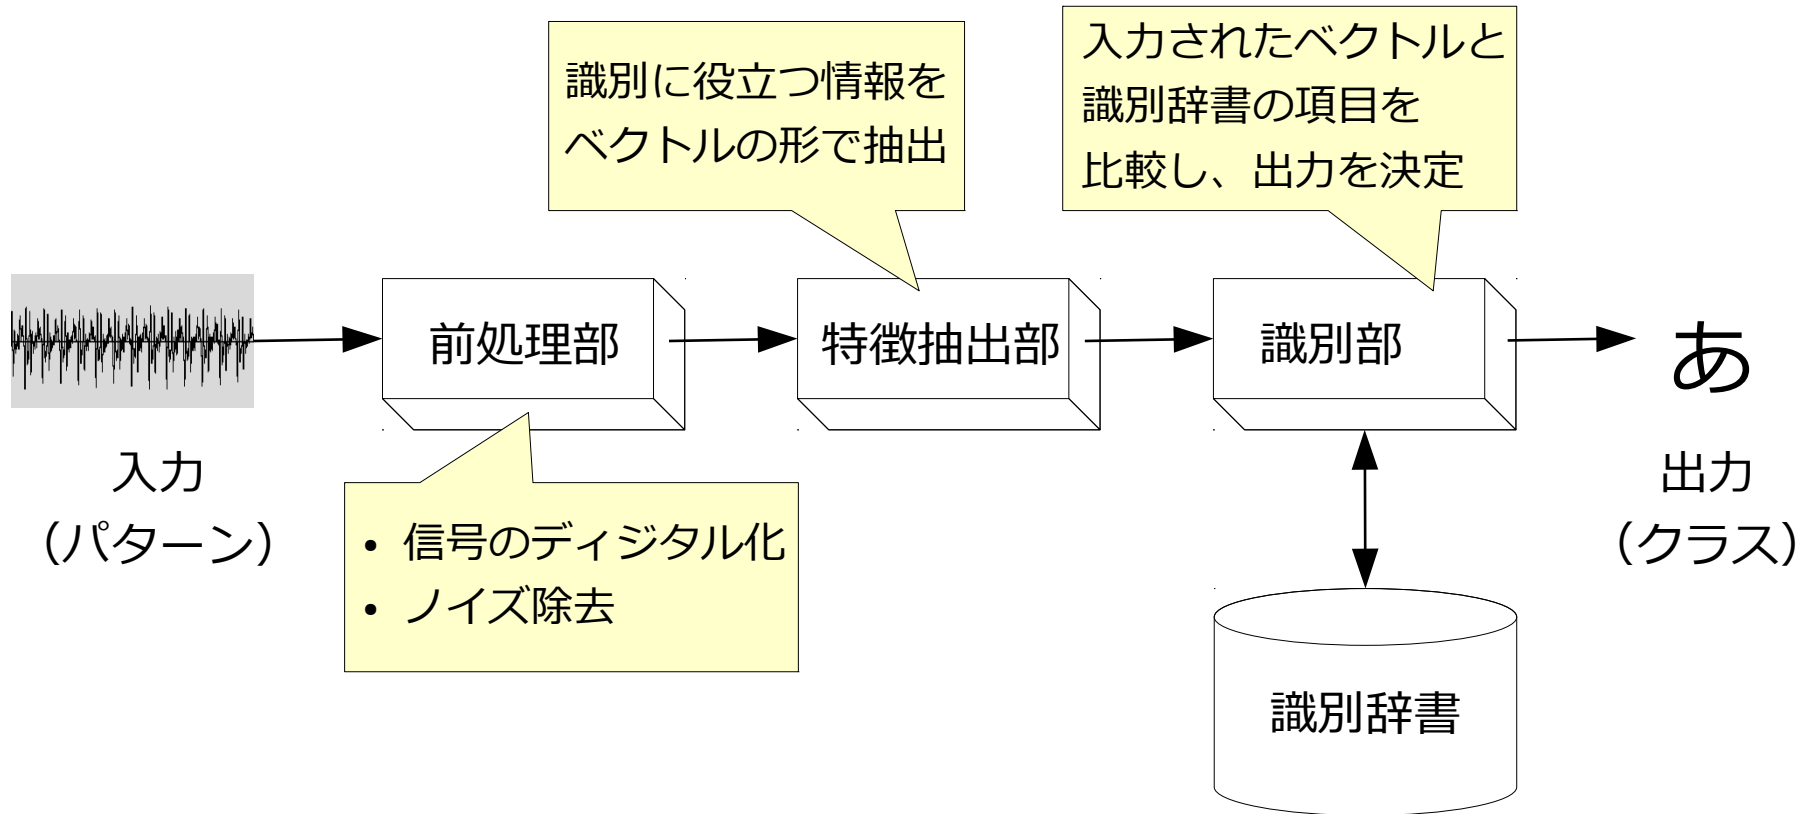
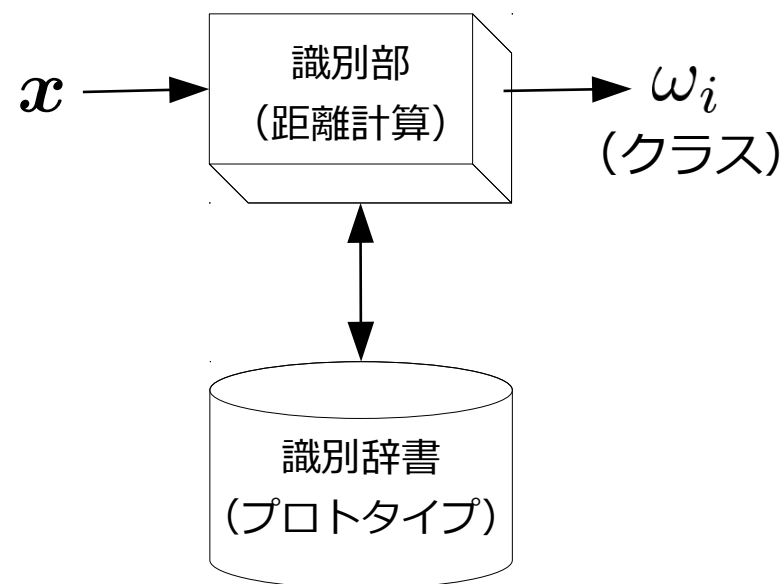
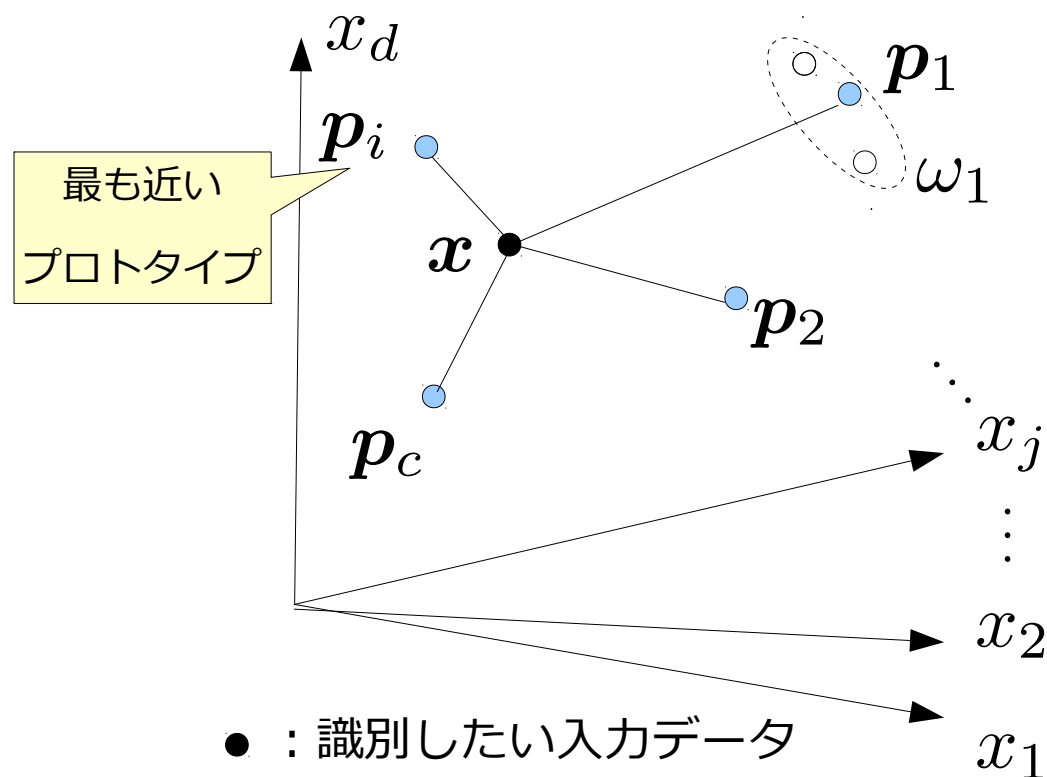


# 1. パターン認識システムの構成



# 1. 最近傍決定則 (NN 法)




$$\mathbf{x} = (x_1, x_2, \dots, x_d)^T$$

$$\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{id})^T$$


$$D(\mathbf{x}, \mathbf{p}_i) = \|\mathbf{x} - \mathbf{p}_i\| = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2 + \dots + (x_d - p_{id})^2}$$

## 2. アナログ信号のデジタル化



- 標本化と量子化
  - 細かすぎず、粗すぎず




アナログ信号



標本化



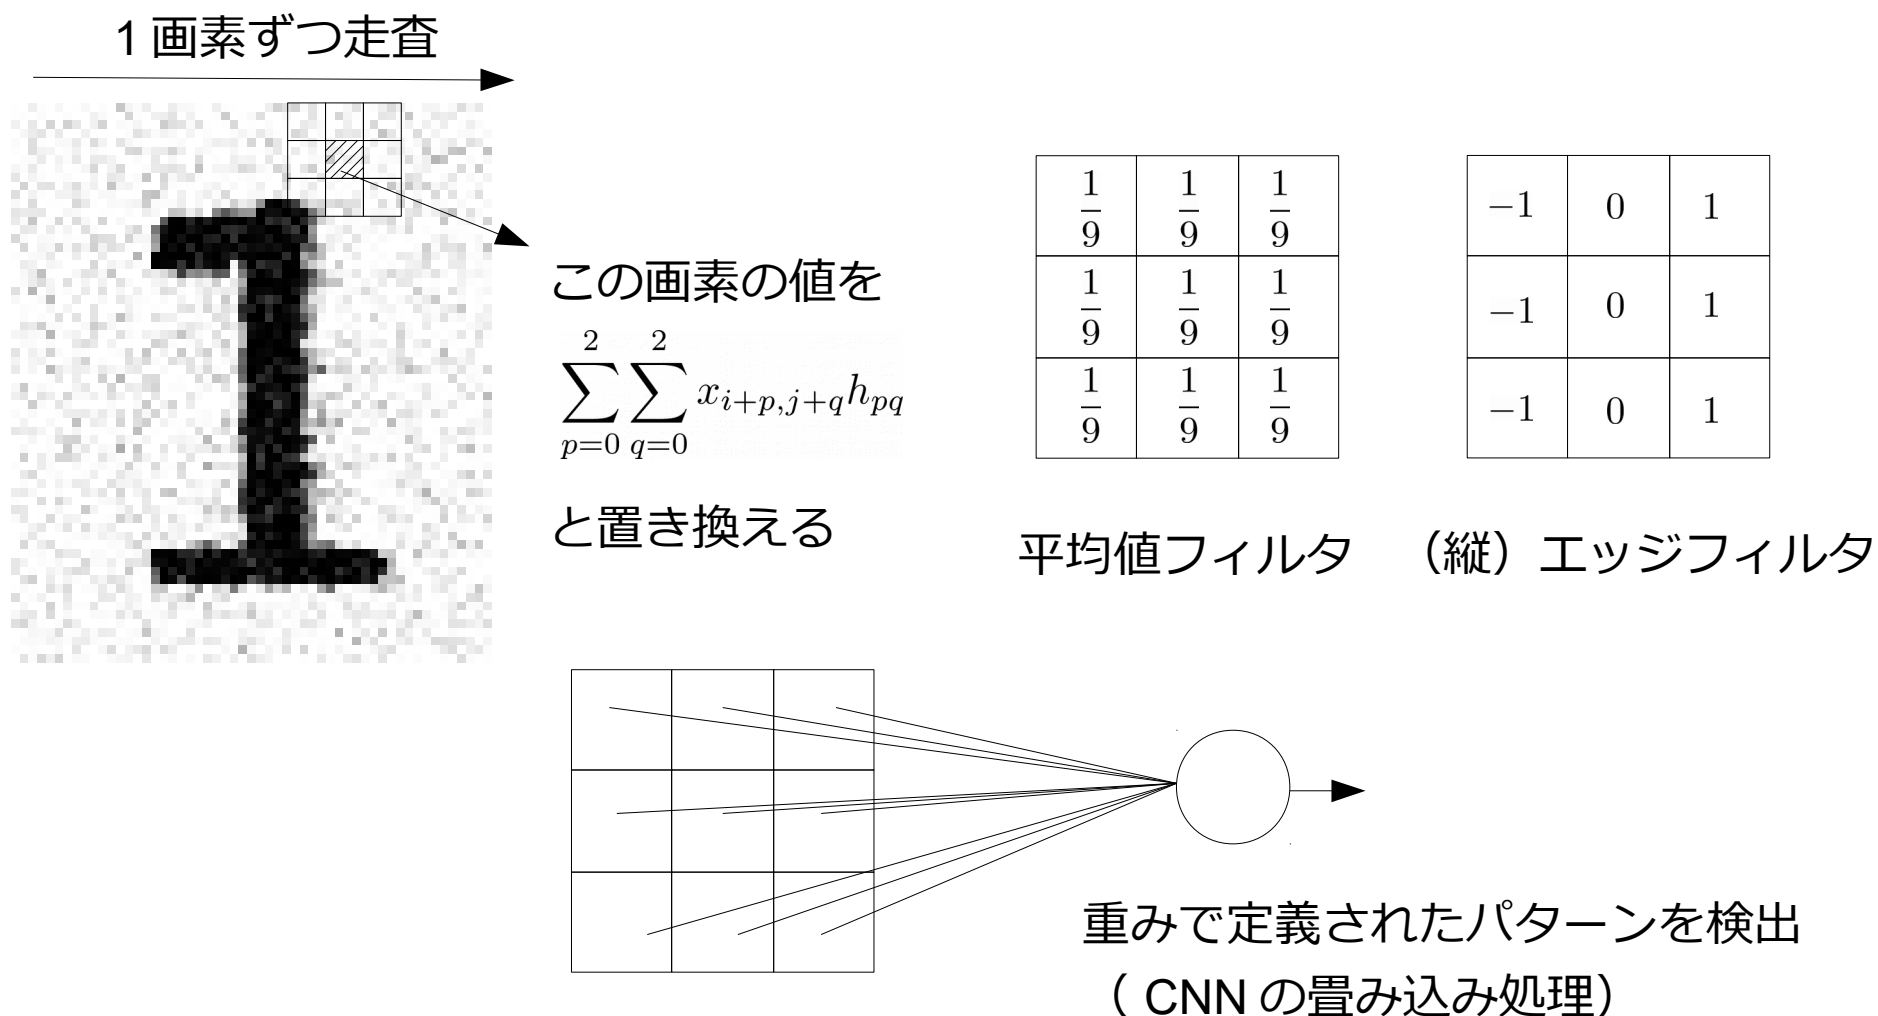
量子化



デジタル信号

## 2. 特徴抽出をしやすくする処理

- フィルタの適用



### 3. 特徴抽出部


- 特徴抽出部の入出力
  - 入力：デジタル信号
  - 出力：パターンの特徴を表す  $d$  次元ベクトル

$$\boldsymbol{x} = (x_1, x_2, \dots, x_d)^T$$

- 特徴抽出処理
  - パターンの変動に影響されにくい特徴を選ぶ
  - 各軸のスケールを揃える：標準化処理

$$x'_i = \frac{x_i - m_i}{\sigma_i} \quad m_i, \sigma_i : \text{軸 } i \text{ の平均、分散}$$

# 3. 主成分分析



共分散行列  $\Sigma$  の計算

$\bar{x}_1, \bar{x}_2$  : 平均値、 $N$  : データ数

$$\Sigma = \frac{1}{N} \begin{pmatrix} \sum (x_1 - \bar{x}_1)^2 & \sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) \\ \sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) & \sum (x_2 - \bar{x}_2)^2 \end{pmatrix}$$

対角成分は分散、  
非対角成分は相関を表す

$\Sigma$  は


半正値 (→ 固有値が全て 0 以上の実数)

対称行列 (→ 固有ベクトルが実数かつ直交)

であるので

$$\Sigma' = U^T \Sigma U = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$$

$\lambda$  は固有値の大きい順、  
 $U$  は対応する固有ベクトルを並べたもの




$\lambda_1$  に対応する固有ベクトルからなる行列  $U_1$  で  
2次元データを1次元に射影

$$u_1 = U_1^T \mathbf{x}$$

## 4. プロトタイプと識別面の関係

- 特徴空間の分割
  - クラスを分離する境界
    - …プロトタイプから等距離にある領域
      - 2次元の NN 法では垂直 2 等分線
      - 多次元では超平面
      - 決定境界あるいは  
**識別面**と呼ぶ
    - 直線（超平面）で分割できる場合を**線形分離可能**と呼ぶ



## 4. 識別関数の設定

- 1 クラス 1 プロトタイプの NN 法の定式化
  - クラス :  $\omega_1, \dots, \omega_c$
  - プロトタイプ :  $\mathbf{p}_1, \dots, \mathbf{p}_c$
  - 入力パターン :  $\mathbf{x}$  (特徴ベクトル)
  - NN 法 :  $D(\mathbf{x}, \mathbf{p}_i) = \|\mathbf{x} - \mathbf{p}_i\|$  を最小にする  $i$  を探す
    - $\rightarrow \|\mathbf{x} - \mathbf{p}_i\|^2 = \|\mathbf{x}\|^2 - 2\mathbf{p}_i^T \mathbf{x} + \|\mathbf{p}_i\|^2$
    - $\rightarrow g_i(\mathbf{x}) = \mathbf{p}_i^T \mathbf{x} - \frac{1}{2}\|\mathbf{p}_i\|^2$  を最大にする  $i$  を探す
    - $\rightarrow g_i(\mathbf{x}) = w_{i0} + \sum_{j=1}^d w_{ij}x_j = \mathbf{w}_i^T \mathbf{x}$ 
      - $d+1$  次元

$\mathbf{x} \in \omega_i$  について、 $g_i(\mathbf{x})$  が最大になるように  $\mathbf{w}$  を調整すればよい



## 4. パーセプトロンの学習アルゴリズム

- 2 クラス識別で  $g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  と定義
  1.  $\mathbf{w}$  の初期値を適当に決める
  2. 学習パターンからひとつ  $\mathbf{x}$  を選び、  $g(\mathbf{x})$  を計算
  3. 誤識別が起きたときのみ、  $\mathbf{w}$  を修正

$$\mathbf{w}' = \mathbf{w} + \rho \mathbf{x} \quad (\text{クラス 1 のパターンをクラス 2 と誤ったとき})$$

$$\mathbf{w}' = \mathbf{w} - \rho \mathbf{x} \quad (\text{クラス 2 のパターンをクラス 1 と誤ったとき})$$


学習係数

4. 2,3 を全ての学習パターンについて繰り返す
5. すべて識別できたら終了。そうでなければ 2 へ

学習データが線形分離可能な場合は、識別面を見つけて終了

## 4. k-NN 法

- k-NN法とは
  - 全ての学習データをプロトタイプとする
  - 入力に近い順から  $k$  個のプロトタイプのクラスを調べ、多数決を取る
  - 入力への近さを重みとした重み付き多数決を用いる場合もある



## 5. 誤差評価に基づく学習

- 2 クラス問題を考える場合

- 誤差関数

$$J(\boldsymbol{w}) = \frac{1}{2} \sum_{p=1}^n (\boldsymbol{w}^T \boldsymbol{x}_p - b_p)^2$$

最小二乗学習

- 教師信号  $b_p$  は  $\boldsymbol{x}_p \in \omega_1$  のとき 1、 $\boldsymbol{x}_p \in \omega_2$  のとき -1

- パターン行列  $\boldsymbol{X} = (\boldsymbol{x}_1, \dots, \boldsymbol{x}_n)^T$

教師信号ベクトル  $\boldsymbol{b} = (b_1, \dots, b_n)^T$

とすると  $J(\boldsymbol{w}) = \frac{1}{2} \|\boldsymbol{X}\boldsymbol{w} - \boldsymbol{b}\|^2$

## 5. 誤差評価に基づく学習

- 解析的な解法

- $J(w)$  が最小となる  $w$  を求める

$$\frac{\partial J}{\partial w} = X^T (Xw - b) = 0$$

$$\Leftrightarrow X^T Xw = X^T b$$

$$\Leftrightarrow w = (X^T X)^{-1} X^T b$$

最小二乗法

- 最急降下法

$$\begin{aligned} w' &= w - \rho \frac{\partial J}{\partial w} \\ &= w - \rho \sum_{p=1}^n (w^T x_p - b_p) x_p \end{aligned}$$

確率的最急降下法

各データに対して更新


ミニバッチ法

適切な個数でまとめて更新

## 6. SVM

- 線形 SVM

- マージン最大となる線形識別面を求める



## 6. SVM

- 学習データ

$$\{(\mathbf{x}_i, y_i)\} \quad i = 1, \dots, n, \quad y_i = 1 \text{ or } -1$$

- 線形識別面の式

$$\mathbf{w}^T \mathbf{x} + w_0 = 0$$

- 識別面の制約の導入（係数を定数倍しても平面は不変）

$$\min_{i=1, \dots, n} |\mathbf{w}^T \mathbf{x}_i + w_0| = 1$$

- 学習パターンと識別面との最小距離（＝マージン）

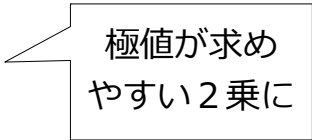
$$\min_{i=1, \dots, n} Dist(\mathbf{x}_i) = \min_{i=1, \dots, n} \frac{|\mathbf{w}^T \mathbf{x}_i + w_0|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

これを  
最大化

点と直線の距離の公式

$$r = \frac{|ax + by + c|}{\sqrt{a^2 + b^2}}$$

## 6. SVM

- 目的関数：  $\min \frac{1}{2} ||\mathbf{w}||^2$  
- 制約条件：  $y_i(\mathbf{w}^T \mathbf{x}_i + w_0) \geq 1 \quad i = 1, \dots, n$
- 解法：ラグランジュの未定乗数法
  - 問題  $\min f(x) \quad s.t. \quad g(x) = 0$
  - ラグランジュ関数  $L(x, \alpha) = f(x) - \alpha g(x)$ 
    - $\alpha \geq 0$
    - $x, \alpha$  で偏微分して 0 になる値が極値

# 6. SVM

- 計算

$$L(\mathbf{w}, w_0, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x} + w_0) - 1)$$

$$\frac{\partial L}{\partial w_0} = 0 \quad \Rightarrow \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$



$$L(\boldsymbol{\alpha}) = \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^n \alpha_i$$


$$\alpha_i \geq 0$$

最大化 2 次計画問題  
→  $\boldsymbol{\alpha}$  が求まる



## 6. SVM

- 特徴ベクトルの次元数を増やす



ただし、元の空間でのデータ間の  
距離関係は保持するように

## 6. SVM

- 非線形変換関数：  $\phi(\mathbf{x})$
- カーネル関数
  - 元の空間での距離が変換後の空間の内積に対応

$$K(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}')$$

線形カーネル  
 $(\mathbf{x}^T \mathbf{x}')^p$   
を用いる場合もある

- カーネル関数の例

– 多項式カーネル  $K(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + 1)^p$

– ガウシアンカーネル  $K(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{\sigma^2}\right)$

この形であれば、対応する非線形変換が存在することが数学的に保証されている

## 6. SVM

- 変換後の識別関数：  $g(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + w_0$
- SVM で求めた  $\mathbf{w}$  の値を代入

$$\begin{aligned} g(\mathbf{x}) &= \sum_{i=1}^n \alpha_i y_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) + w_0 \\ &= \sum_{i=1}^n \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i) + w_0 \end{aligned}$$

非線形変換の  
式は不要！！！！

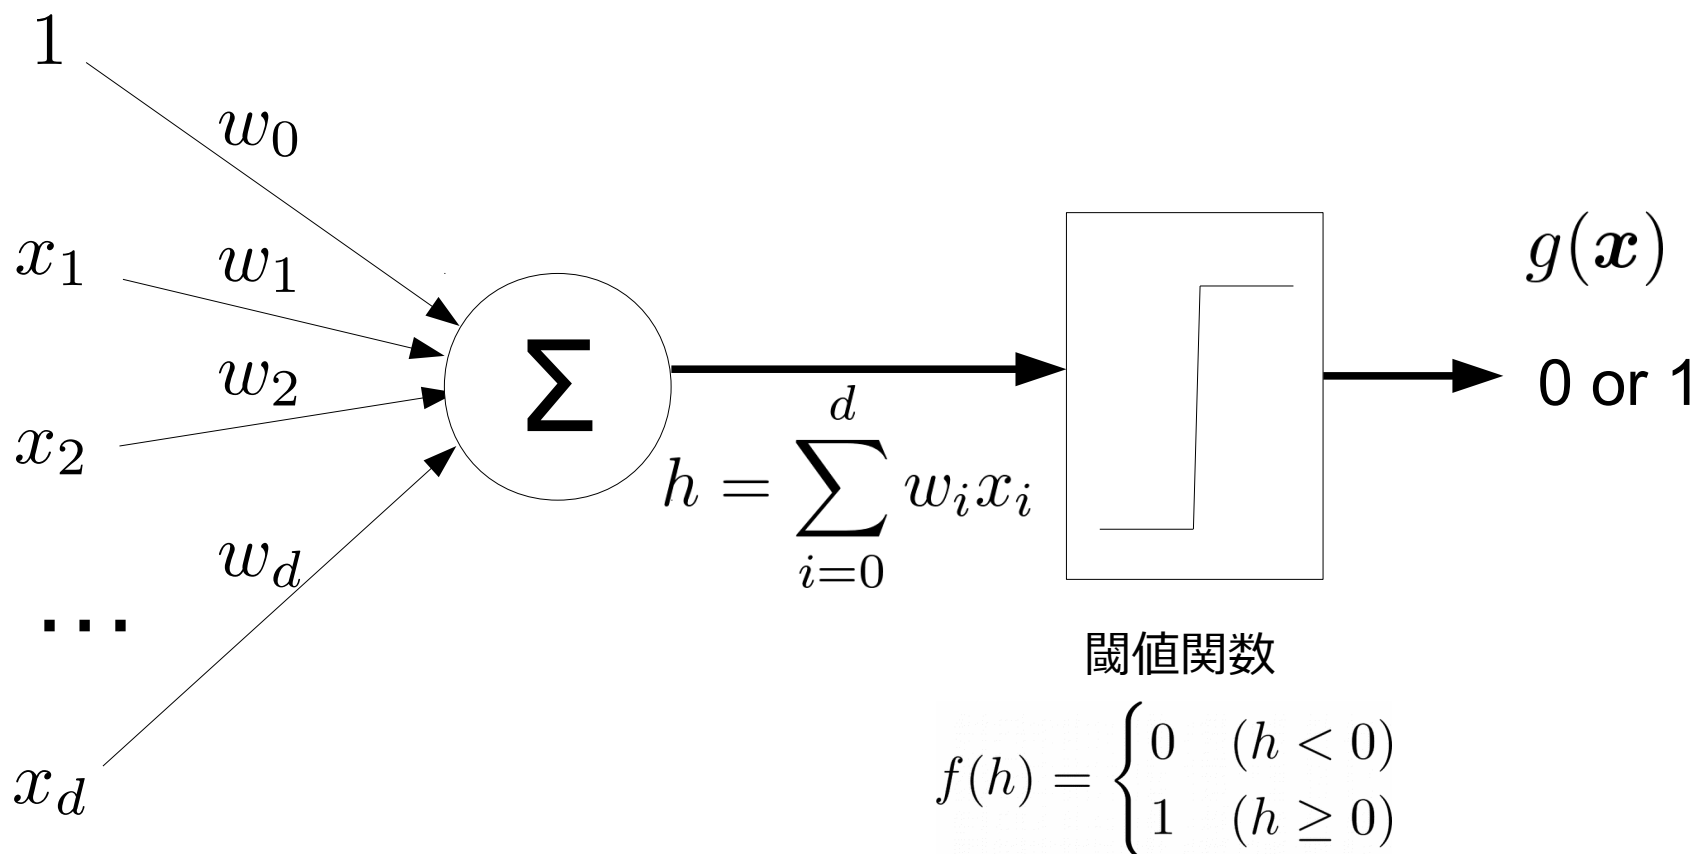
**カーネルトリック**

# 7. ニューラルネットワーク

- 単層パーセプトロンの定義

以後、 $w$  は  $w_0$  を含む

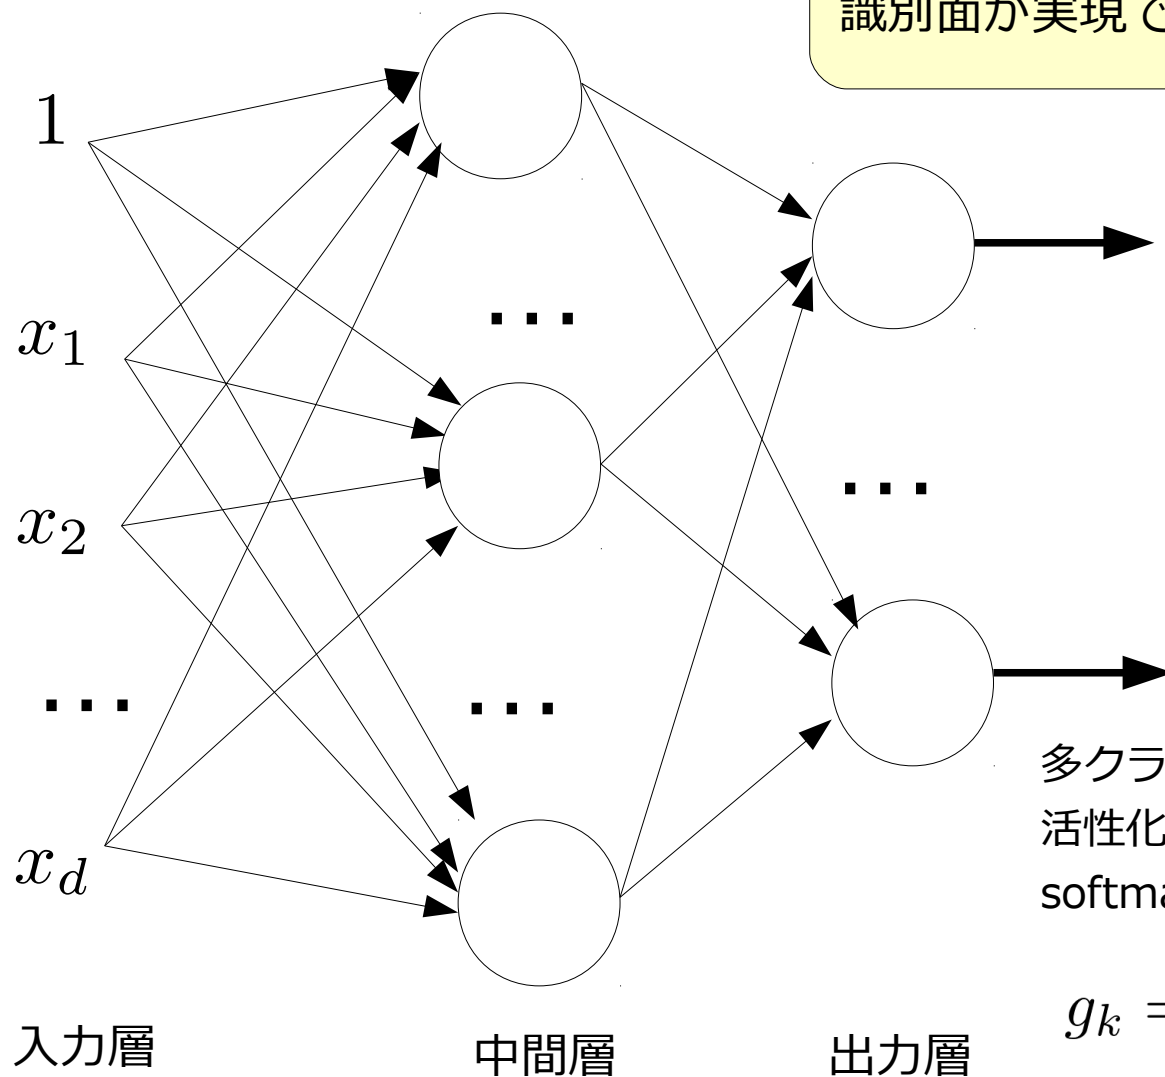
- $w^T x = 0$  という特徴空間上の識別面を表現



# 7. ニューラルネットワーク

- 多層パーセプトロン

特徴空間上で複雑な非線形  
識別面が実現できる

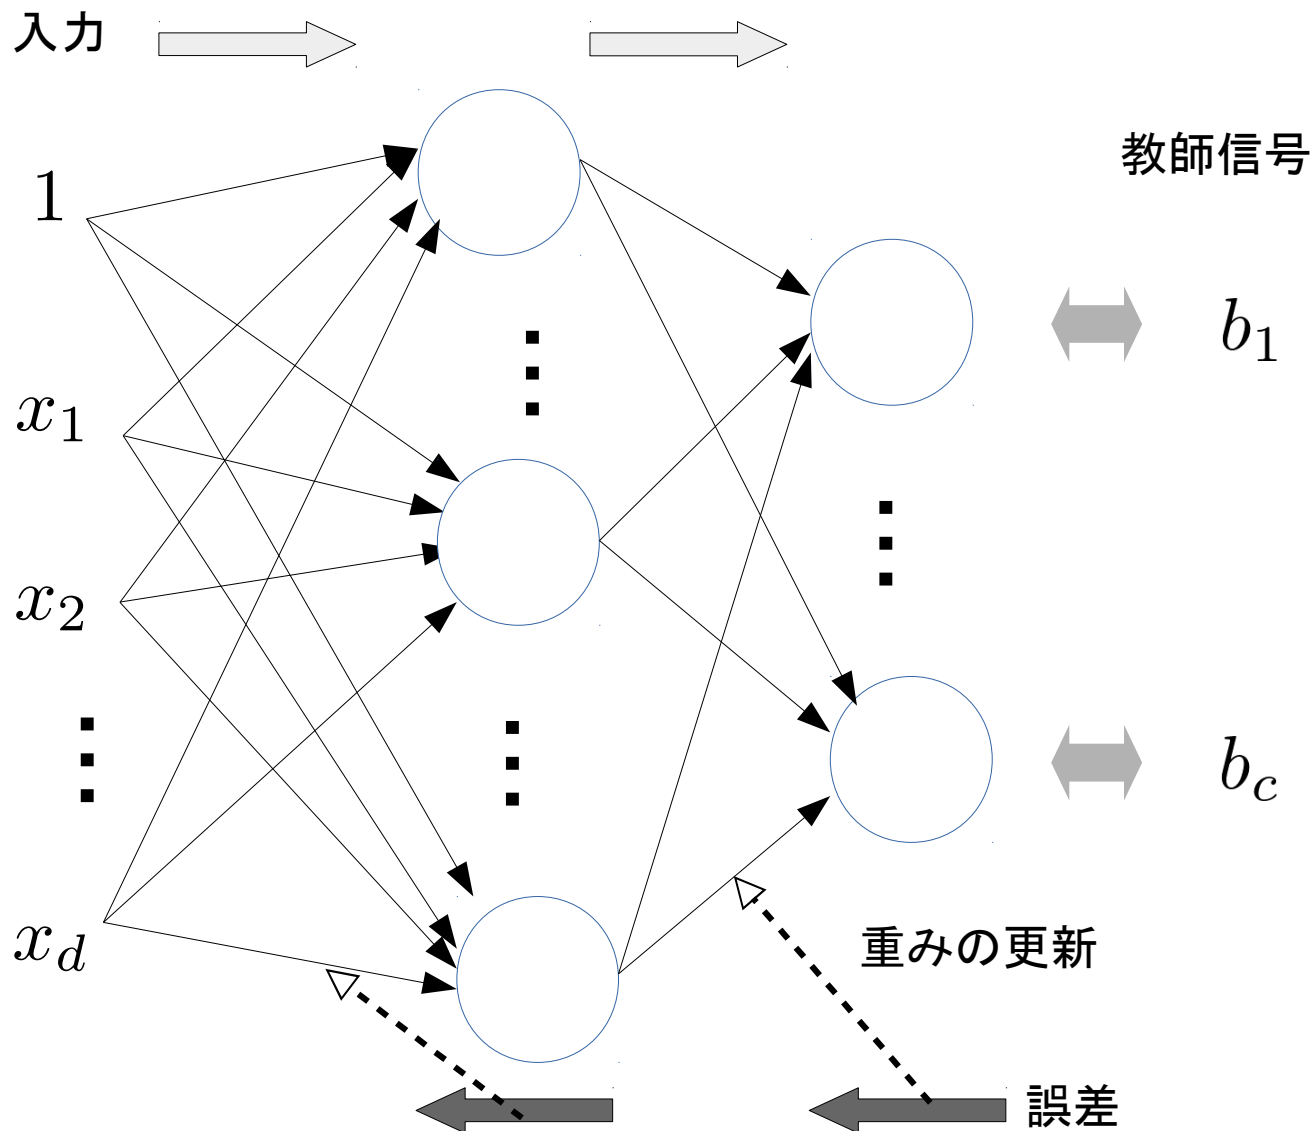


多クラス問題の出力層には  
活性化関数として以下の  
softmax 関数を用いる

$$g_k = \frac{\exp(h_k)}{\sum_{j=1}^c \exp(h_j)}$$

# 7. ニューラルネットワーク

- 誤差逆伝播法



# 7. ニューラルネットワーク

1. リンクの重みを小さな初期値に設定

2. 個々の学習データ  $(x_p, b_p)$  に対して以下繰り返し

a) 入力  $x_p$  に対するネットワークの出力  $g_p$  を計算

b) 出力層の  $k$  番目のユニットに対してエラー量  $\varepsilon$  を計算

$$\varepsilon_k \leftarrow (g_k - b_k)g_k(1 - g_k)$$

c) 中間層の  $h$  番目のユニットに対してエラー量  $\varepsilon$  を計算

$$\varepsilon_j \leftarrow \left( \sum_k \varepsilon_k w_k \right) g_j(1 - g_j)$$

d) 重みの更新

$$w_{ji} \leftarrow w_{ji} + \rho \varepsilon_j x_{pi}$$

局所最適解の可能性が高いので、初期値を変えて繰り返す

## 8. 統計的手法

- 事後確率最大法（ベイズ決定則）
  - $P(\omega_i | \mathbf{x})$  を最大にするクラス  $\omega_i$  を識別結果とする

$$\arg \max_{i=1, \dots, c} P(\omega_i | \mathbf{x})$$

$$= \arg \max_{i=1, \dots, c} \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})}$$

ベイズの定理

$$= \arg \max_{i=1, \dots, c} p(\mathbf{x} | \omega_i) P(\omega_i)$$



## 8. 統計的手法

- 事前確率  $P(\omega_i)$  の求め方
  - 最尤推定
    - 学習データ数 :  $N$
    - クラス  $\omega_i$  のデータ数 :  $n_i$
    - 事前確率の最尤推定値

$$P(\omega_i) = \frac{n_i}{N}$$


## 8. 統計的手法

- クラス分布  $p(\boldsymbol{x}|\omega_i)$  の求め方
  - 確率分布の形を仮定して、そのパラメータを学習データから推定
  - 例 ) 正規分布：平均と共分散行列を推定

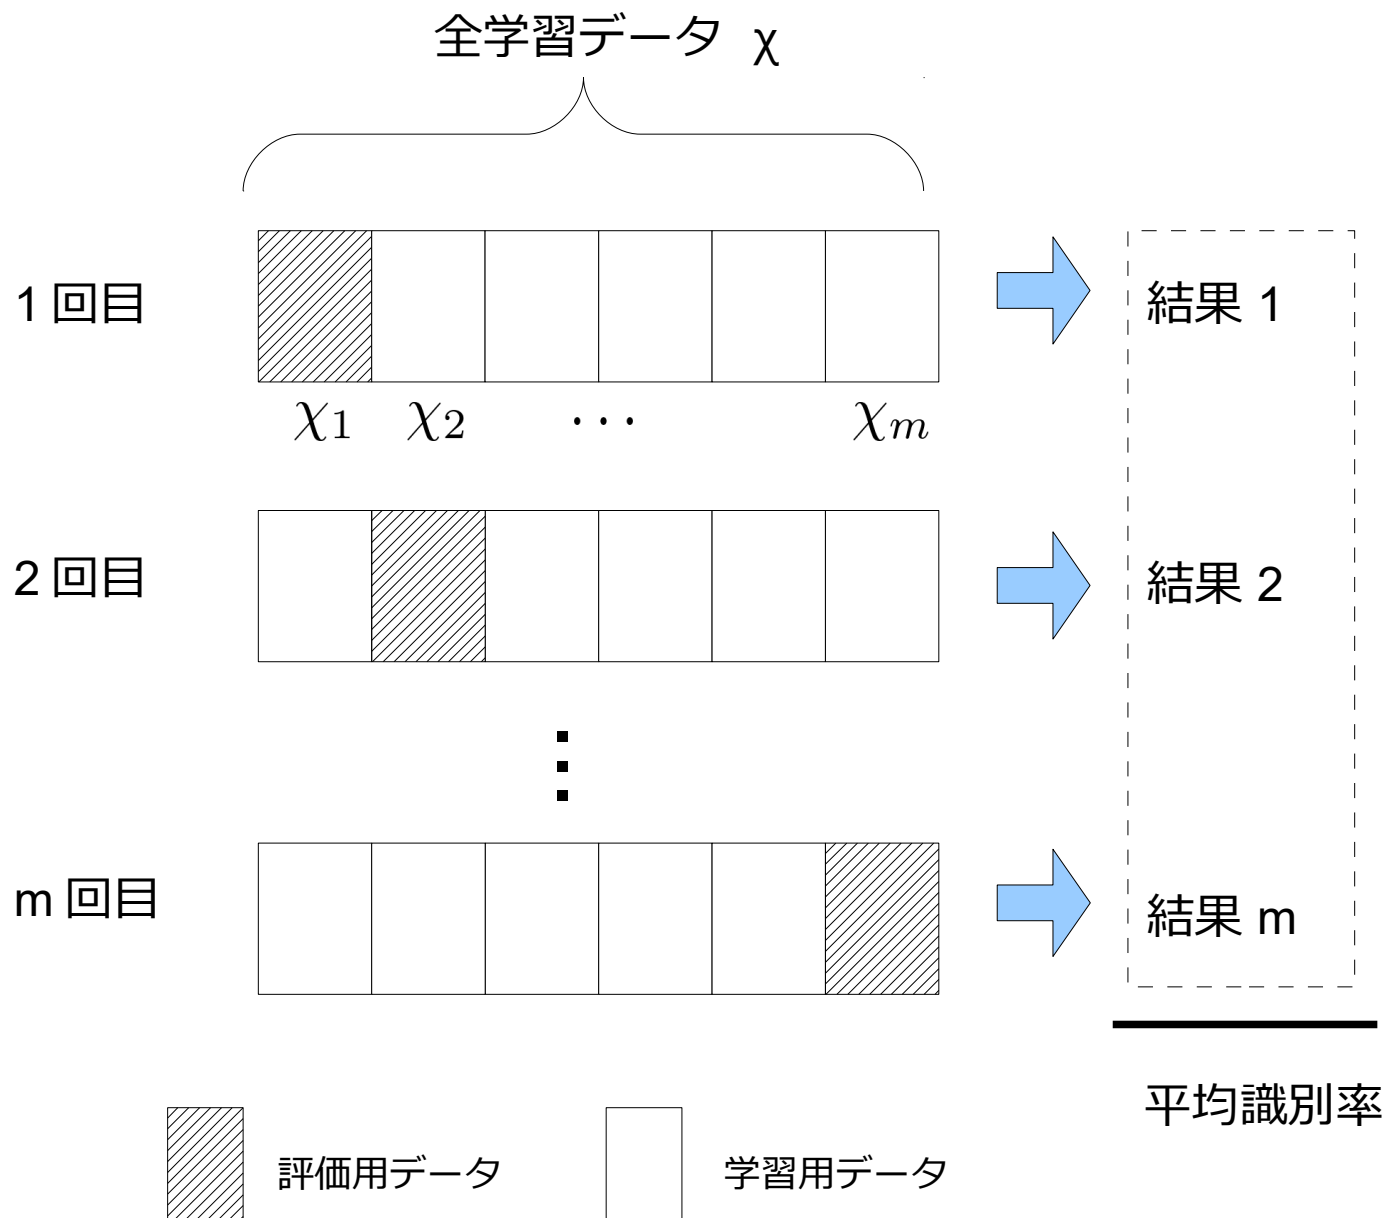
$$p(\boldsymbol{x}|\omega_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{m}_i)^t \boldsymbol{\Sigma}_i^{-1} (\boldsymbol{x} - \boldsymbol{m}_i)\right\}$$

$\boldsymbol{m}_i$  : 平均ベクトル

$\boldsymbol{\Sigma}_i$  : 共分散行列



# 9. 交差確認法



## 9. ハイパーパラメータ調整

- パラメータ ➡ 学習可能
  - 識別関数の重み
  - ニューラルネットワークの結合の重み
  - k-NN 法のプロトタイプ的位置
- ハイパーパラメータ ➡ 学習結果によって調整
  - 識別関数の次数
  - ニューラルネットワークの中間ユニット数
  - k-NN 法の k

## 9. ハイパーパラメータ調整

- ハイパーパラメータが複数ある場合
  - グリッドサーチ：各格子点で  $e_\lambda$  を求める

