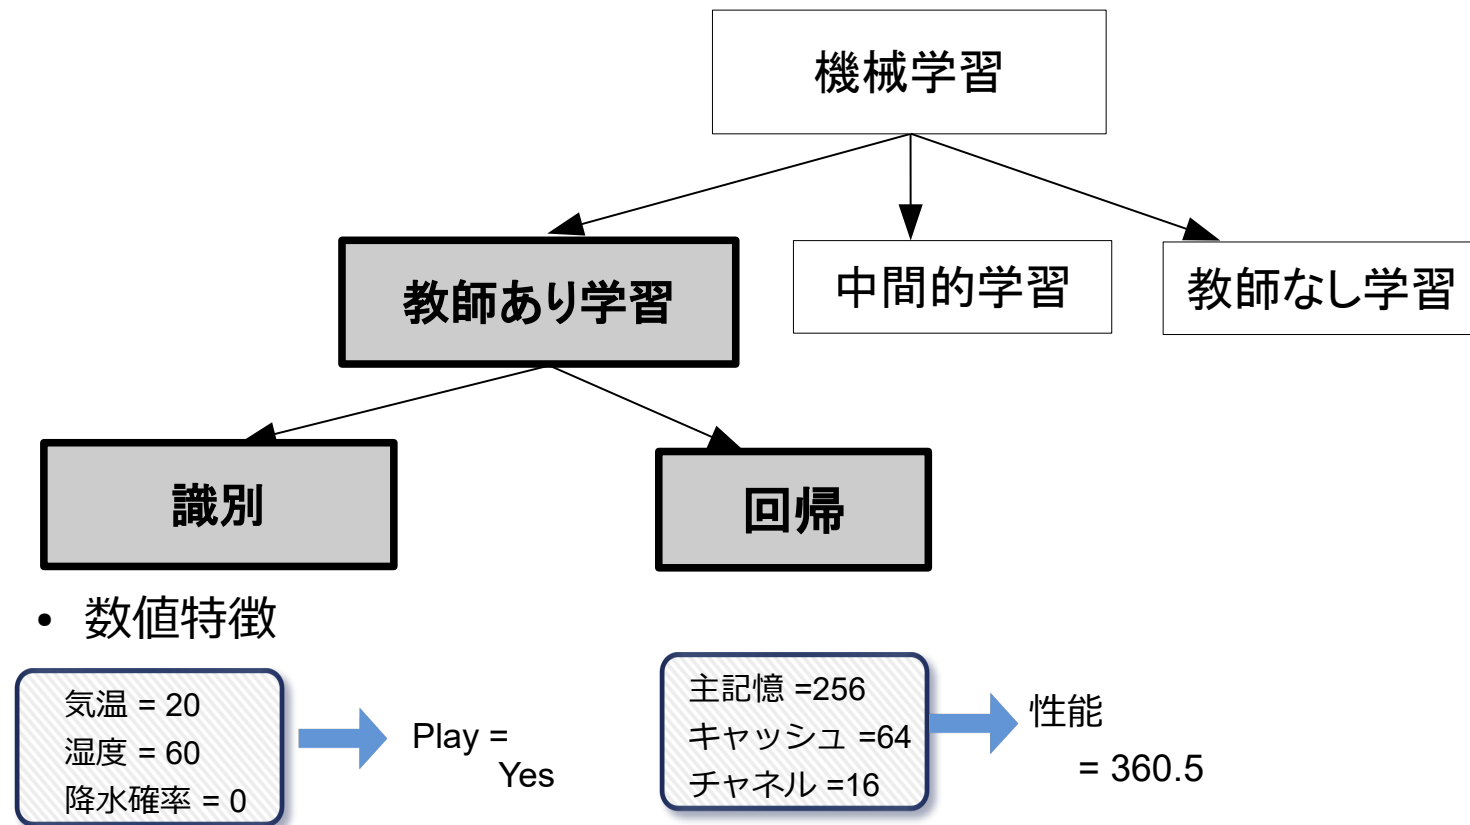


7. サポートベクトルマシン




7. サポートベクトルマシン

- マージンを最大化する識別面を求める

識別面と、最も
近いデータとの
距離

境界部分のデータ
にのみ注目



○ ○ : サポートベクトル

7.1 サポートベクトルマシンとは

- 学習データ

$$\chi = \{(\mathbf{x}_i, y_i)\} \quad i = 1, \dots, N, \quad y_i = 1 \text{ or } -1$$

- 識別面の式

$$\mathbf{w}^T \mathbf{x}_i + w_0 = 0$$

- 識別面の制約（係数を定数倍しても平面は不変）

$$\min_{i=1, \dots, N} |\mathbf{w}^T \mathbf{x}_i + w_0| = 1$$

- 学習パターンと超平面との最小距離

点と直線の距離の公式

$$r = \frac{|ax + by + c|}{\sqrt{a^2 + b^2}}$$

$$\min_{i=1, \dots, N} Dist(\mathbf{x}_i) = \min_{i=1, \dots, N} \frac{|\mathbf{w}^T \mathbf{x}_i + w_0|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

7.1 サポートベクトルマシンとは

- 目的関数： $\min \frac{1}{2} ||\boldsymbol{w}||^2$
- 制約条件： $y_i(\boldsymbol{w}^T \boldsymbol{x}_i + w_0) \geq 1 \quad i = 1, \dots, N$
- 解法：ラグランジュの未定乗数法
 - 問題 $\min f(x) \quad s.t. \quad g(x) = 0$
 - ラグランジュ関数 $L(x, \alpha) = f(x) + \alpha g(x)$
 - $\alpha \geq 0$
 - x, α で偏微分して 0 になる値が極値


7.1 サポートベクトルマシンとは

- 計算

$$L(\mathbf{w}, w_0, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + w_0) - 1)$$

$$\frac{\partial L}{\partial w_0} = 0 \quad \Rightarrow \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$



$$L(\alpha) = \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^N \alpha_i$$

α についての
2次計画問題

7.1 サポートベクトルマシンとは

- 定数項の計算
 - 各クラスのサポートベクトルから求める

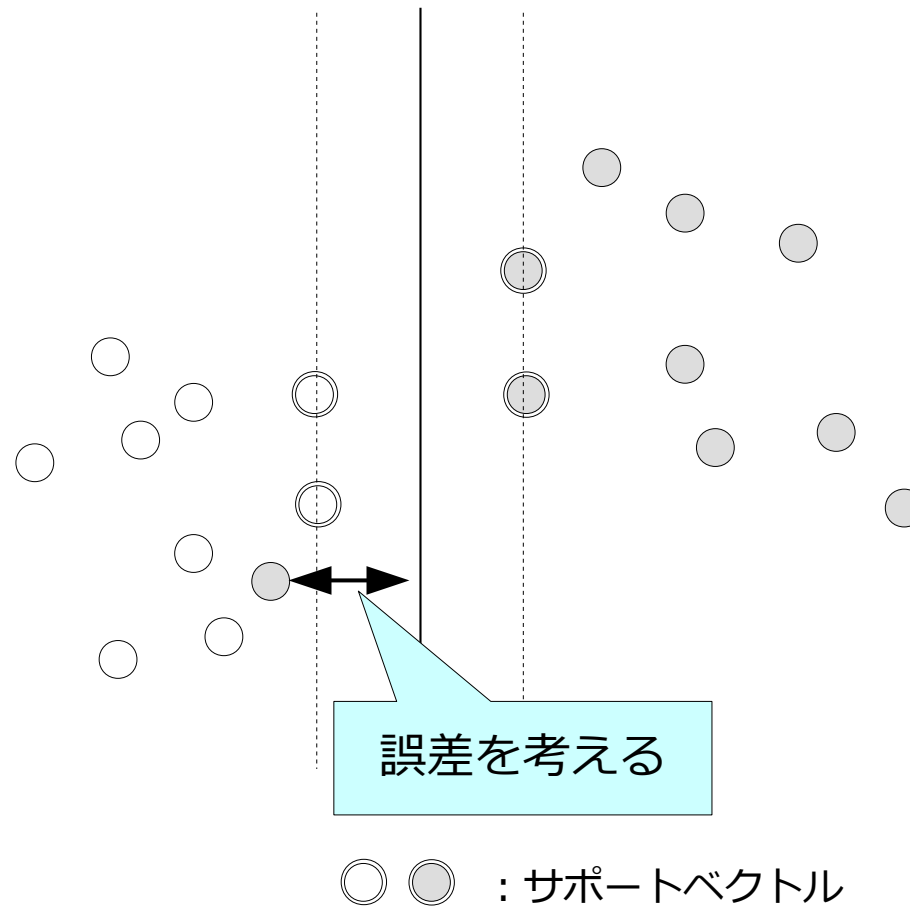
$$w_0 = -\frac{1}{2}(\boldsymbol{w}^T \boldsymbol{x}_{s1} + \boldsymbol{w}^T \boldsymbol{x}_{s2})$$

- 識別関数

$$\begin{aligned} g(\boldsymbol{x}) &= \boldsymbol{w}^T \boldsymbol{x} + w_0 \\ &= \sum_{i=1}^n \alpha_i y_i \boldsymbol{x}^T \boldsymbol{x}_i + w_0 \end{aligned}$$

7.2 ソフトマージンによる誤識別データの吸収

- 少量のデータが線形分離性を妨げている場合



7.2 ソフトマージンによる誤識別データの吸収

- スラック変数 ξ_i の導入

$$y_i(\mathbf{w}^T \mathbf{x}_i + w_0) \geq 1 - \xi_i \quad i = 1, \dots, N$$

- 最小化問題の修正

$$\min\left(\frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i\right)$$

スラック変数も
小さい方がよい

- 計算結果


- α_i の 2 次計画問題に $0 \leq \alpha_i \leq C$ が加わるだけ

7.2 ソフトマージンによる誤識別データの吸収

- C: エラー事例に対するペナルティ
 - 大きな値：誤識別データの影響が大きい
 - 複雑な識別面
 - 小さな値：誤識別データの影響が小さい
 - 単純な識別面

7.3 カーネル関数を用いた SVM

- 特徴ベクトルの次元を増やす



ただし、元の空間でのデータ間の
距離関係は保持するように

7.3 カーネル関数を用いた SVM

- 非線形変換関数： $\phi(\boldsymbol{x})$
- カーネル関数

$$K(\boldsymbol{x}, \boldsymbol{x}') = \phi(\boldsymbol{x})^T \phi(\boldsymbol{x}')$$

2つの引数値の
近さを表す

- 元の空間での距離が変換後の空間の内積に対応
- \boldsymbol{x} と \boldsymbol{x}' が近ければ $K(\boldsymbol{x}, \boldsymbol{x}')$ は大きい値

7.3 カーネル関数を用いた SVM

- カーネル関数の例（scikit-learn の定義）

- 線形 $K(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$

- 元の特徴空間でマージン最大の平面

- 多項式 $K(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + r)^d$

- d 項の相関を加える

- RBF $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$

- γ の値：大→複雑 小→単純な識別面

- シグモイド $K(\mathbf{x}, \mathbf{x}') = \tanh(\mathbf{x}^T \mathbf{x}' + r)$

- ベクトルの近さを基準に閾値関数的な振る舞い

7.3 カーネル関数を用いた SVM

- 変換後の識別関数： $g(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + w_0$
- SVM で求めた \mathbf{w} の値を代入

$$\begin{aligned} g(\mathbf{x}) &= \sum_{i=1}^N \alpha_i y_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) + w_0 \\ &= \sum_{i=1}^N \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i) + w_0 \end{aligned}$$

非線形変換の
式は不要！！！！

カーネルトリック

まとめ

- Weka デモ
 - Reuters-Corn データ
 - SMO (Poly カーネル、 RBF カーネル)
- SVM
 - マージン最大となる線形識別面を求める方法
 - カーネル関数を用いてデータを高次元空間に写像して線形分離可能性を高める
 - 高次元特徴でも学習が可能