



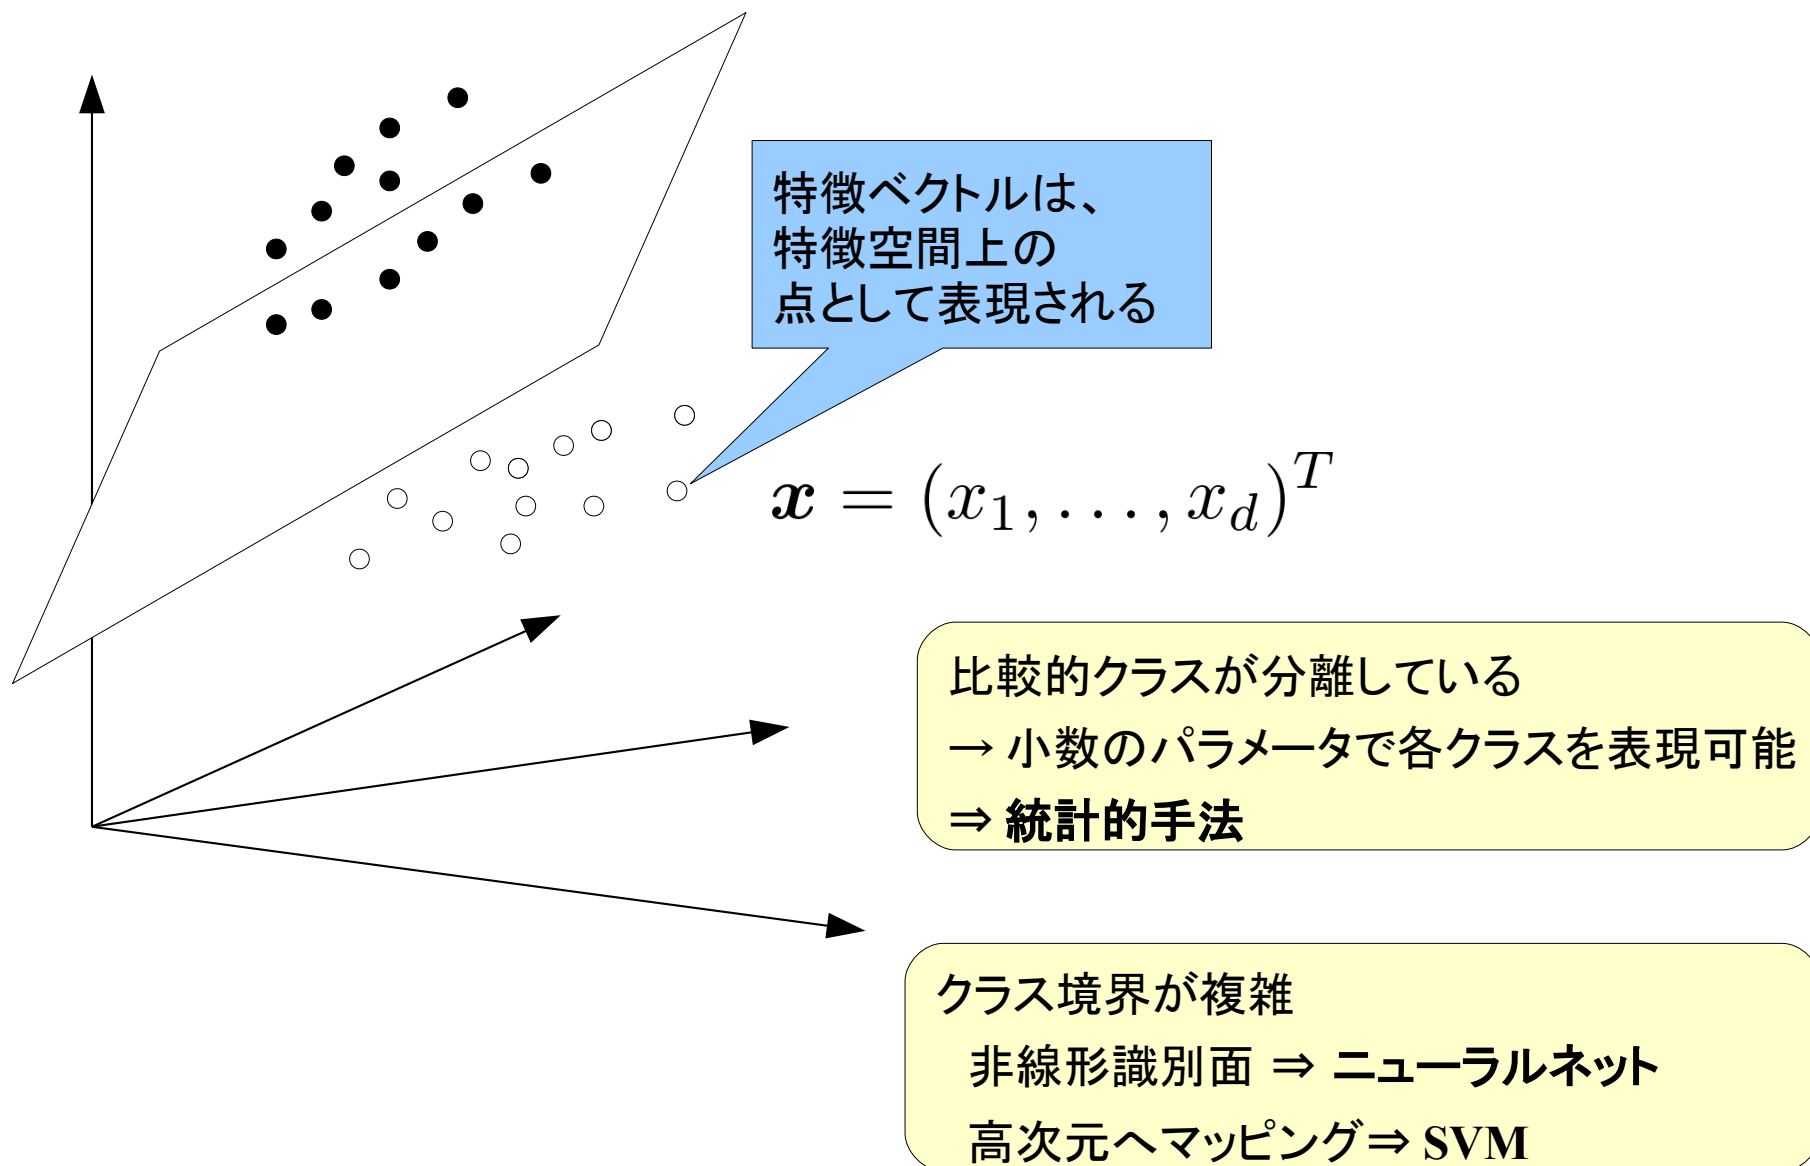
5. 識別 — 生成モデルと識別モデル —



- ラベル特徴
- 数値特徴



5.1 数値特徴に対する「教師あり・識別」問題の定義



統計的識別とは（復習）

- 最大事後確率則による識別

\mathbf{x} : 特徴ベクトル

$$C_{MAP} = \arg \max_i P(\omega_i | \mathbf{x}) \quad \omega_i \ (1 \leq i \leq c) : \text{クラス}$$

- ベイズの定理 $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$

$$\begin{aligned} C_{MAP} &= \arg \max_i P(\omega_i | \mathbf{x}) \\ &= \arg \max_i \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})} \end{aligned}$$

$$= \arg \max_i P(\mathbf{x} | \omega_i) P(\omega_i)$$

尤度

事前確率 $P(\omega_i) = \frac{n_i}{N}$

尤度 $P(\mathbf{x}|\omega_i)$ の推定 (復習)

- カテゴリ特徴の場合
 - $P(\text{sunny, hot, high, FALSE} | \text{yes})$ などの値をすべての特徴・クラスの組合せについて求めるのは難しい
- ナイーブベイズの近似

$$P(\mathbf{x}|\omega_i) = P(x_1, \dots, x_d|\omega_i)$$


$$\approx \prod_{j=1}^d P(x_j|\omega_i)$$

$P(\text{sunny} | \text{yes})$ などを
求めて掛け合わせる

5.2 数値特徴に対するベイズ識別

5.2.1 数値特徴に対するナイーブベイズ識別

- 数値特徴の場合
 - $P(5.1, 3.5, 1.4, 0.2 | \text{iris-setosa})$ などの値をすべての特徴・クラスの組合せについて求めるのは**不可能**
 - ナイーブベイズの近似
 - $P(5.1 | \text{iris-setosa})$ の値をどうやって求める？



5.2.1 数値特徴に対するナイーブベイズ識別

- 確率密度関数 $p(x_j|\omega_i)$ の推定


- 正規分布を仮定

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- データから平均 μ と分散 σ^2 を最尤推定

データの平均と分散を
正規分布のパラメータとする

$P(\text{sepal length} | \text{iris-setosa})$
などが正規分布すると仮定する



iris データのナイーブベイズ識別

Attribute	Class		
	Iris-setosa	Iris-versicolor	Iris-virginica
	(0.33)	(0.33)	(0.33)
=====			
sepal length			
mean	4.9913	5.9379	6.5795
std. dev.	0.355	0.5042	0.6353
weight sum	50	50	50
precision	0.1059	0.1059	0.1059
sepal width			
mean	3.4015	2.7687	2.9629
std. dev.	0.3925	0.3038	0.3088
weight sum	50	50	50
precision	0.1091	0.1091	0.1091

• • •

正規分布とは

- 離散型二項分布の例

- n 枚のコインを投げた時の、表の枚数の度数

- $n=1$ 1 1

- $n=2$ 1 2 1

- $n=3$ 1 3 3 1

- $n=4$ 1 4 6 4 1

- $n=5$ 1 5 10 10 5 1

- ...

- $n \rightarrow \infty$ の時の分布が正規分布

5.2.2 生成モデルの考え方


- 事後確率を求めるにあたって、同時確率を求めている
 - データが生成される様子をモデル化しているとも見ること出来る
 - 事前確率に基づいてクラスを選ぶ
 - そのもとで、特徴ベクトルを出力する

$$\begin{aligned} P(\omega_i | \mathbf{x}) &= \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})} \\ &= \frac{p(\omega_i, \mathbf{x})}{p(\mathbf{x})} \end{aligned}$$

事後確率を求めるより、
難しい問題を解いている
のではないかな？

5.3.3 識別モデルの考え方

- 事後確率を直接求める




5.3.4 ロジスティック識別

- ロジスティック識別
 - 入力为正例である確率

$$P(\oplus|\boldsymbol{x}) = \frac{1}{1 + \exp(-(\boldsymbol{w} \cdot \boldsymbol{x} + w_0))}$$

$-\infty \sim +\infty$ の値域を持つものを、順序を変えずに $0 \sim 1$ にマッピング



シグモイド関数

5.3.4 ロジスティック識別

- 最適化対象 = モデルが学習データを生成する確率


$$E(\mathbf{w}) = -\log P(D|\mathbf{w}) = -\log \prod_{\mathbf{x}_i \in D} o_i^{y_i} (1 - o_i)^{(1-y_i)}$$

- $E(\mathbf{w})$ を最急降下法で最小化

$$w_j \leftarrow w_j - \eta \frac{\partial E(\mathbf{w})}{\partial w_j}$$

$$o = P(\oplus | \mathbf{x})$$
$$y = 0 \text{ or } 1$$

正解ラベル



5.3.4 ロジスティック識別

- 重み更新量の計算

$$\begin{aligned}\frac{\partial E(\boldsymbol{w})}{\partial w_j} &= - \sum_{\boldsymbol{x}_i \in D} \left(\frac{y_i}{o_i} - \frac{1 - y_i}{1 - o_i} \right) o_i (1 - o_i) x_{ij} \\ &= - \sum_{\boldsymbol{x}_i \in D} (y_i - o_i) x_{ij}\end{aligned}$$

- 重みの更新式

$$w_j \leftarrow w_j + \eta \sum_{\boldsymbol{x}_i \in D} (y_i - o_i) x_{ij}$$

この更新を全データ集合ではなく、個別のデータに対して行うのが、
確率的最急降下法

まとめ

- Weka デモ
 - iris データ、 glass データ
 - NaiveBayes, SimpleLogistic
- ナイーブベイズ
 - 特徴の各次元に対して、 1 次元正規分布のパラメータ（平均・分散）を最尤推定
- ロジスティック識別
 - 特徴の重み付き和で得られる「そのクラスらしさ」を確率値に変換

次回までの勉強

- Weka
 - インストールして、各章の例題・演習問題を実行
- Python
 - Google Colaboratory で各章の例題・演習問題を実行
 - Google アカウントが必要
- 余裕があれば
 - Chainer チュートリアル (1 ～ 6)
<https://tutorials.chainer.org/ja/tutorial.html>