



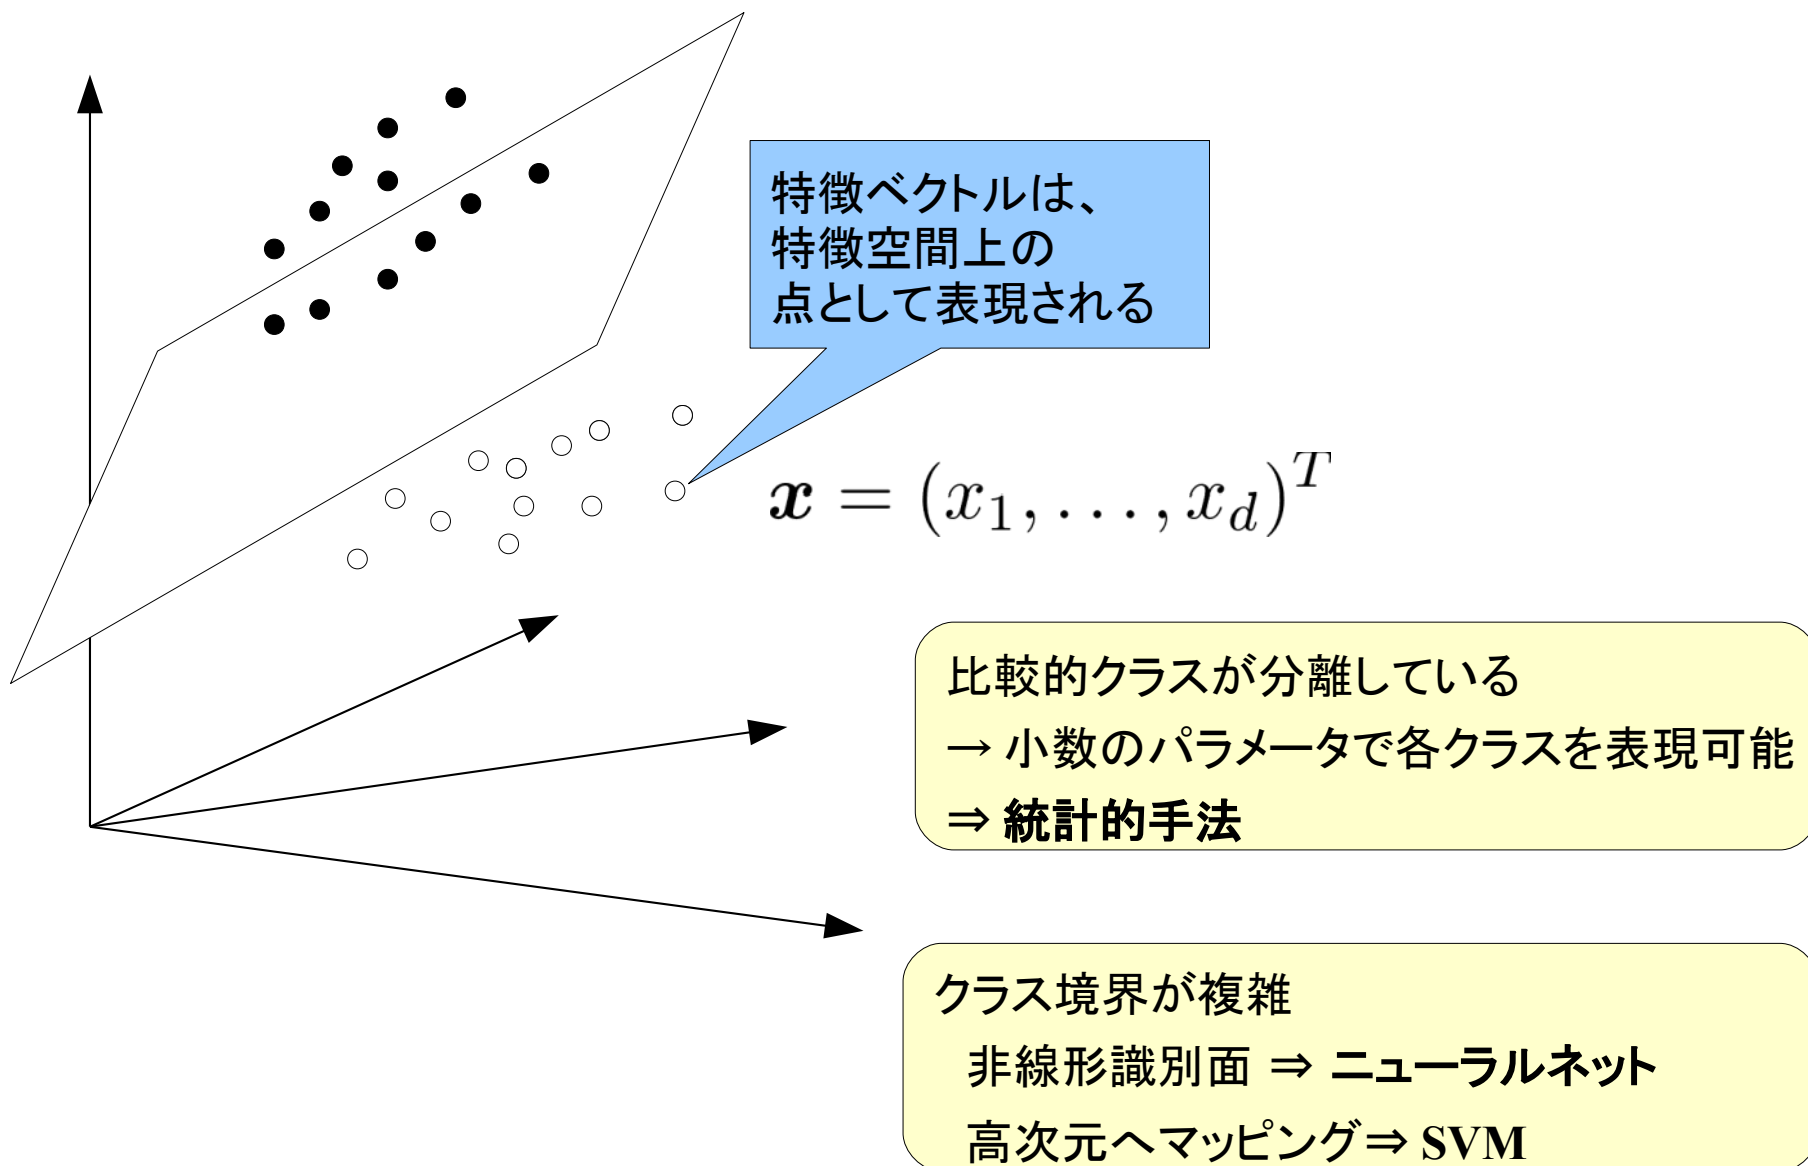
# 5. 識別 — 生成モデルと識別モデル —



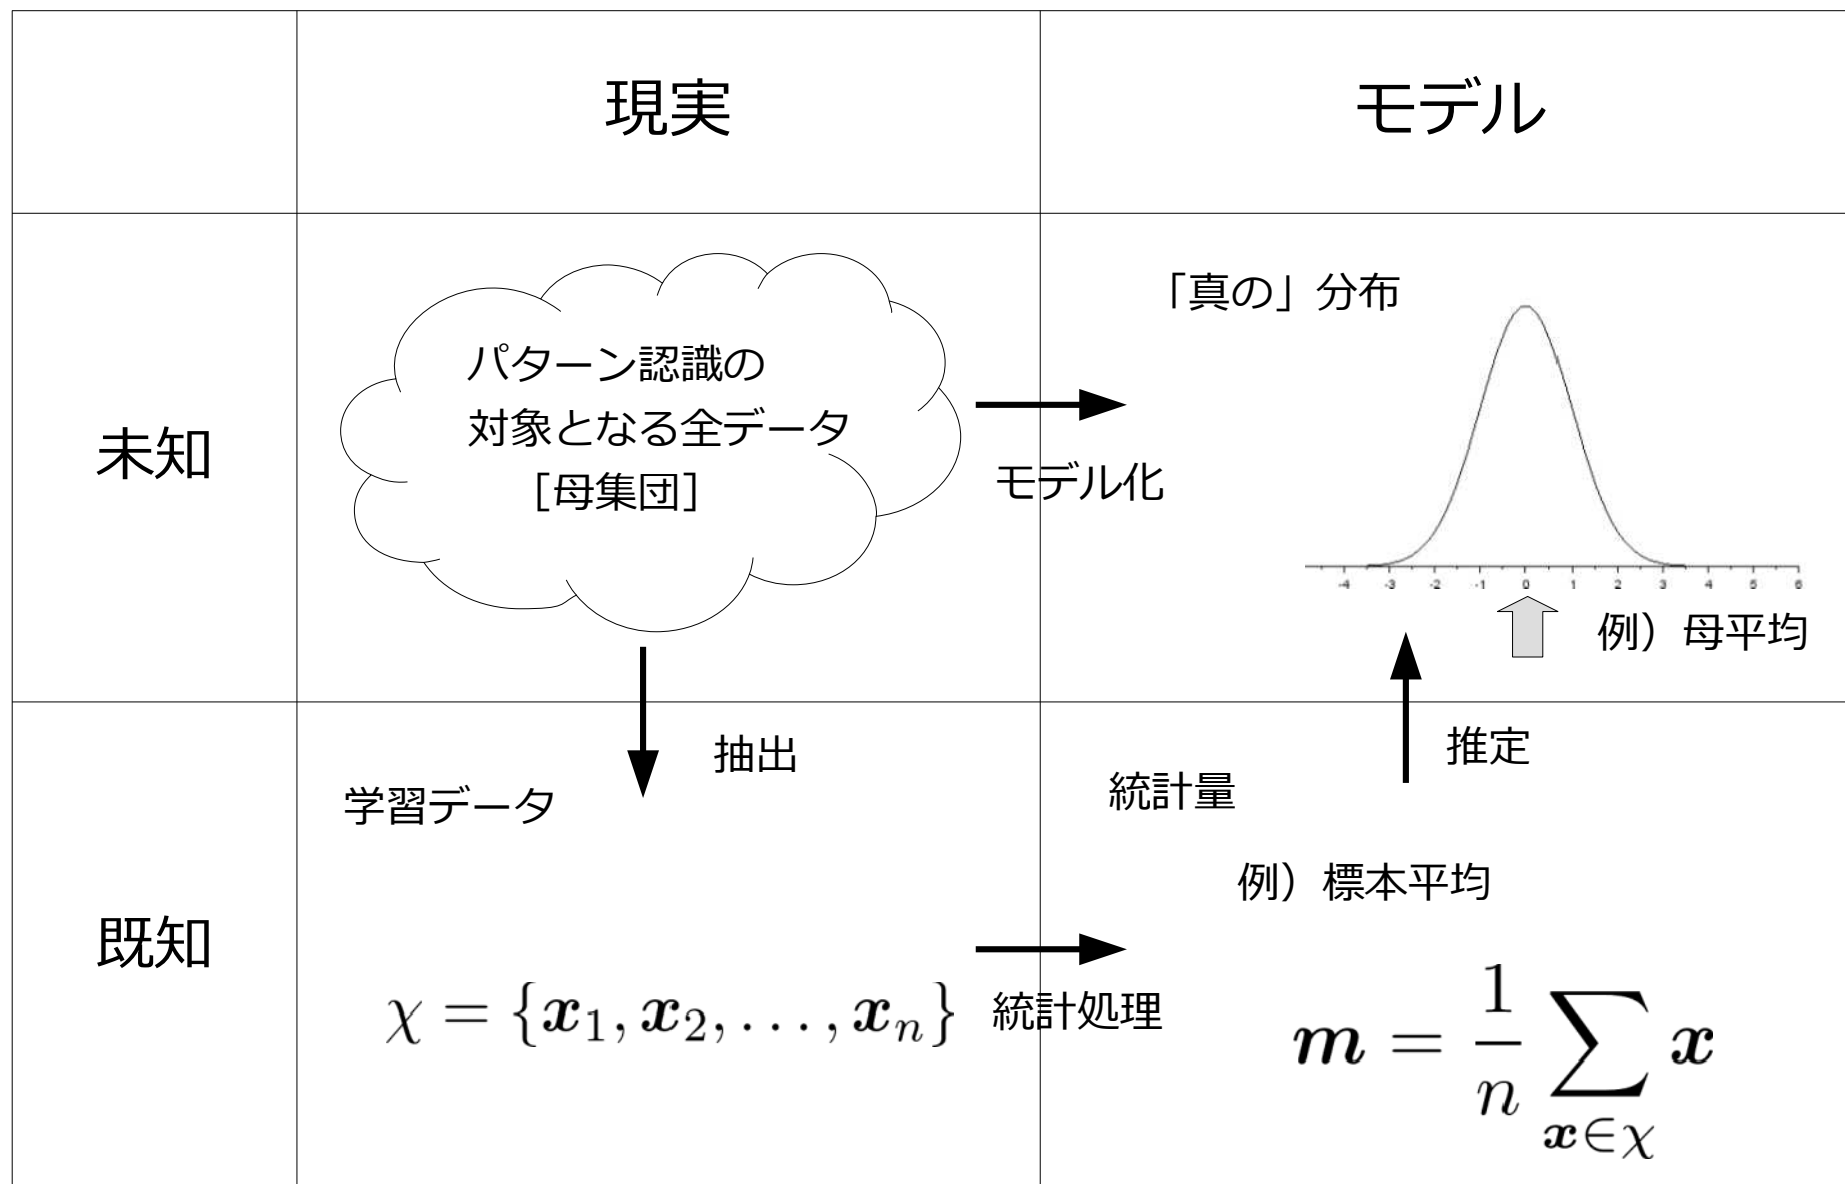
- ラベル特徴
- 数値特徴



## 5.1 数値特徴に対する「教師あり・識別」問題の定義



# 統計的識別手法の考え方



# 統計的識別とは（復習）

- 最大事後確率則による識別

$\mathbf{x}$  : 特徴ベクトル

$$C_{MAP} = \arg \max_i P(\omega_i | \mathbf{x}) \quad \omega_i \ (1 \leq i \leq c) : \text{クラス}$$

- ベイズの定理  $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$

$$\begin{aligned} C_{MAP} &= \arg \max_i P(\omega_i | \mathbf{x}) \\ &= \arg \max_i \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})} \\ &= \arg \max_i P(\mathbf{x} | \omega_i) P(\omega_i) \end{aligned}$$

尤度

事前確率  $P(\omega_i) = \frac{n_i}{N}$

# 尤度 $P(\mathbf{x}|\omega_i)$ の推定 (復習)

- カテゴリ特徴の場合
  - $P(\text{sunny, hot, high, FALSE} | \text{yes})$  などの値をすべての特徴・クラスの組合せについて求めるのは難しい
- ナイーブベイズの近似

$$P(\mathbf{x}|\omega_i) = P(x_1, \dots, x_d|\omega_i)$$


$$\approx \prod_{j=1}^d P(x_j|\omega_i)$$

$P(\text{sunny} | \text{yes})$  などを  
求めて掛け合わせる

## 5.2 数値特徴に対するベイズ識別

### 5.2.1 数値特徴に対するナイーブベイズ識別

- 数値特徴の場合
  - $P(5.1, 3.5, 1.4, 0.2 | \text{iris-setosa})$  などの値をすべての特徴・クラスの組合せについて求めるのは**不可能**
  - ナイーブベイズの近似
    - $P(5.1 | \text{iris-setosa})$  の値をどうやって求める？



## 5.2.1 数値特徴に対するナイーブベイズ識別

- 確率密度関数  $p(x_j|\omega_i)$  の推定


- 正規分布を仮定

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- データから平均  $\mu$  と分散  $\sigma^2$  を最尤推定

データの平均と分散を  
正規分布のパラメータとする

$P(\text{sepal length} | \text{iris-setosa})$   
などが正規分布すると仮定する



# 正規分布とは

- 離散型二項分布の例

- $n$  枚のコインを投げた時の、表の枚数の度数

- $n=1$                       1   1

- $n=2$                       1   2   1

- $n=3$                       1   3   3   1

- $n=4$                       1   4   6   4   1

- $n=5$                       1   5   10   10   5   1

- ...

- $n \rightarrow \infty$  の時の分布が正規分布



## 5.2.2 生成モデルの考え方

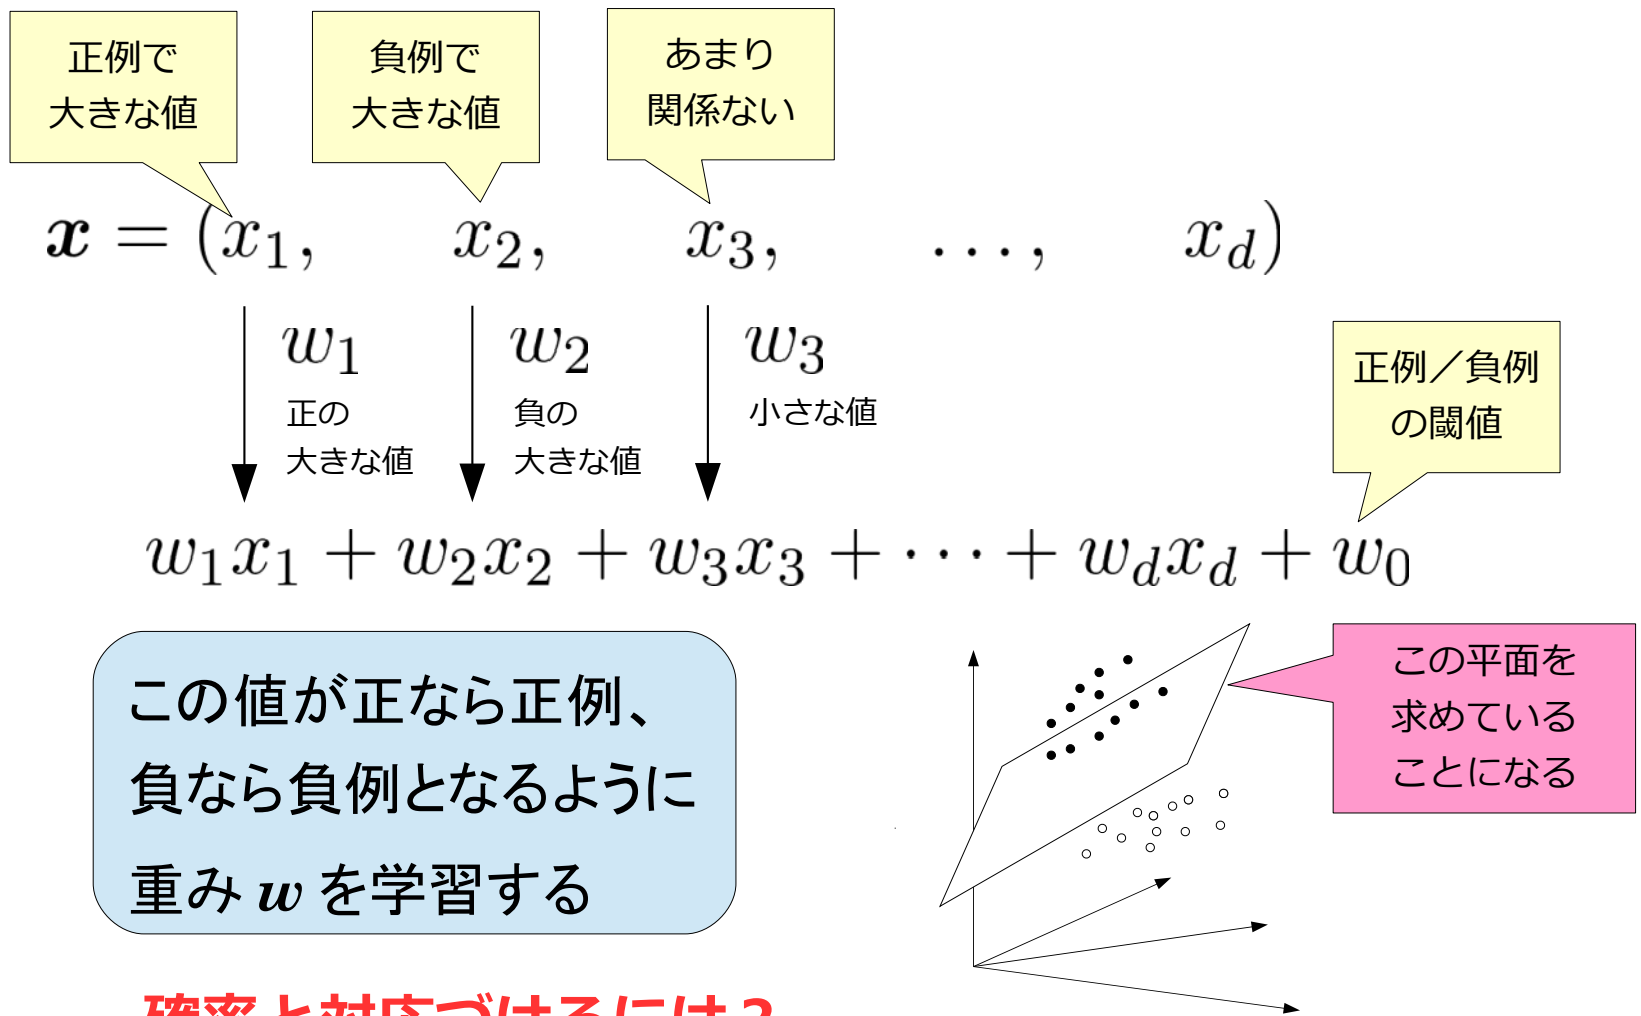
- 事後確率を求めるにあたって、同時確率を求めている
  - データが生成される様子をモデル化しているとも見ること出来る
    - 事前確率に基づいてクラスを選ぶ
    - そのもとで、特徴ベクトルを出力する

$$\begin{aligned} P(\omega_i | \mathbf{x}) &= \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})} \\ &= \frac{p(\omega_i, \mathbf{x})}{p(\mathbf{x})} \end{aligned}$$

事後確率を求めるより、  
難しい問題を解いている  
のではないかな？

## 5.3.3 識別モデルの考え方

- 事後確率を直接求める




## 5.3.4 ロジスティック識別

- ロジスティック識別
  - 入力为正例である確率

$$P(\oplus|\mathbf{x}) = \frac{1}{1 + \exp(-(\mathbf{w} \cdot \mathbf{x} + w_0))}$$

$-\infty \sim +\infty$  の値域を持つ  
ものを、順序を変えずに  
 $0 \sim 1$  にマッピング



シグモイド関数

## 5.3.4 ロジスティック識別

- 最適化対象 = モデルが学習データを生成する確率


$$E(\mathbf{w}) = -\log P(D|\mathbf{w}) = -\log \prod_{\mathbf{x}_i \in D} o_i^{y_i} (1 - o_i)^{(1-y_i)}$$

- $E(\mathbf{w})$  を最急降下法で最小化

$$w_j \leftarrow w_j - \eta \frac{\partial E(\mathbf{w})}{\partial w_j}$$

$$o = P(\oplus | \mathbf{x})$$
$$y = 0 \text{ or } 1$$

正解ラベル



## 5.3.4 ロジスティック識別

- 重み更新量の計算

$$\begin{aligned}\frac{\partial E(\boldsymbol{w})}{\partial w_j} &= \sum_{\boldsymbol{x}_i \in D} \left( \frac{y_i}{o_i} - \frac{1 - y_i}{1 - o_i} \right) o_i (1 - o_i) x_{ij} \\ &= \sum_{\boldsymbol{x}_i \in D} (y_i - o_i) x_{ij}\end{aligned}$$

- 重みの更新式

$$w_j \leftarrow w_j - \eta \sum_{\boldsymbol{x}_i \in D} (y_i - o_i) x_{ij}$$

この更新を全データ集合ではなく、個別のデータに対して行うのが、  
確率的最急降下法

# まとめ

- Weka デモ
  - iris データ、 glass データ
  - NaiveBayes, SimpleLogistic
- ナイーブベイズ
  - 特徴の各次元に対して、 1 次元正規分布のパラメータ（平均・分散）を最尤推定
- ロジスティック識別
  - 特徴の重み付き和で得られる「そのクラスらしさ」を確率値に変換

# 次回までの勉強

- Weka
  - インストールして、各章の例題・演習問題を実行
- Python
  - Google Colaboratory で各章の例題・演習問題を実行
    - Google アカウントが必要
- 余裕があれば
  - Chainer チュートリアル (1 ～ 6)  
<https://tutorials.chainer.org/ja/tutorial.html>