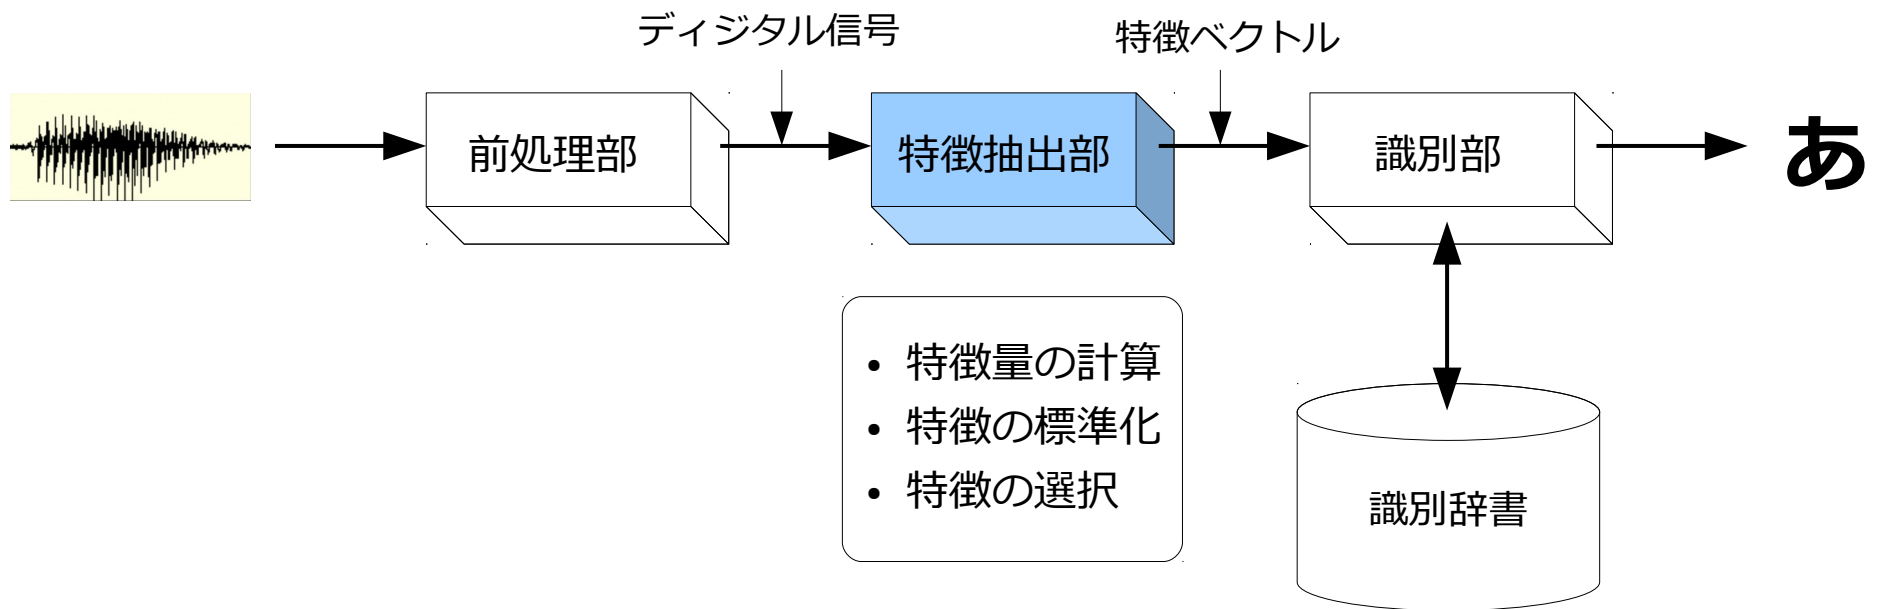



3. パターンの特徴を調べよう



3.1 変動に強い特徴とは


3.1.1 音声の場合

- 音素の違いとは
 - 声帯を振動の有無
(パルス波か雑音か)
 - 声道 (口の開き具合・舌の位置など) の変形
→ 共振周波数の違いが大きな特徴



(a) 発声の仕組みと調音のメカニズム

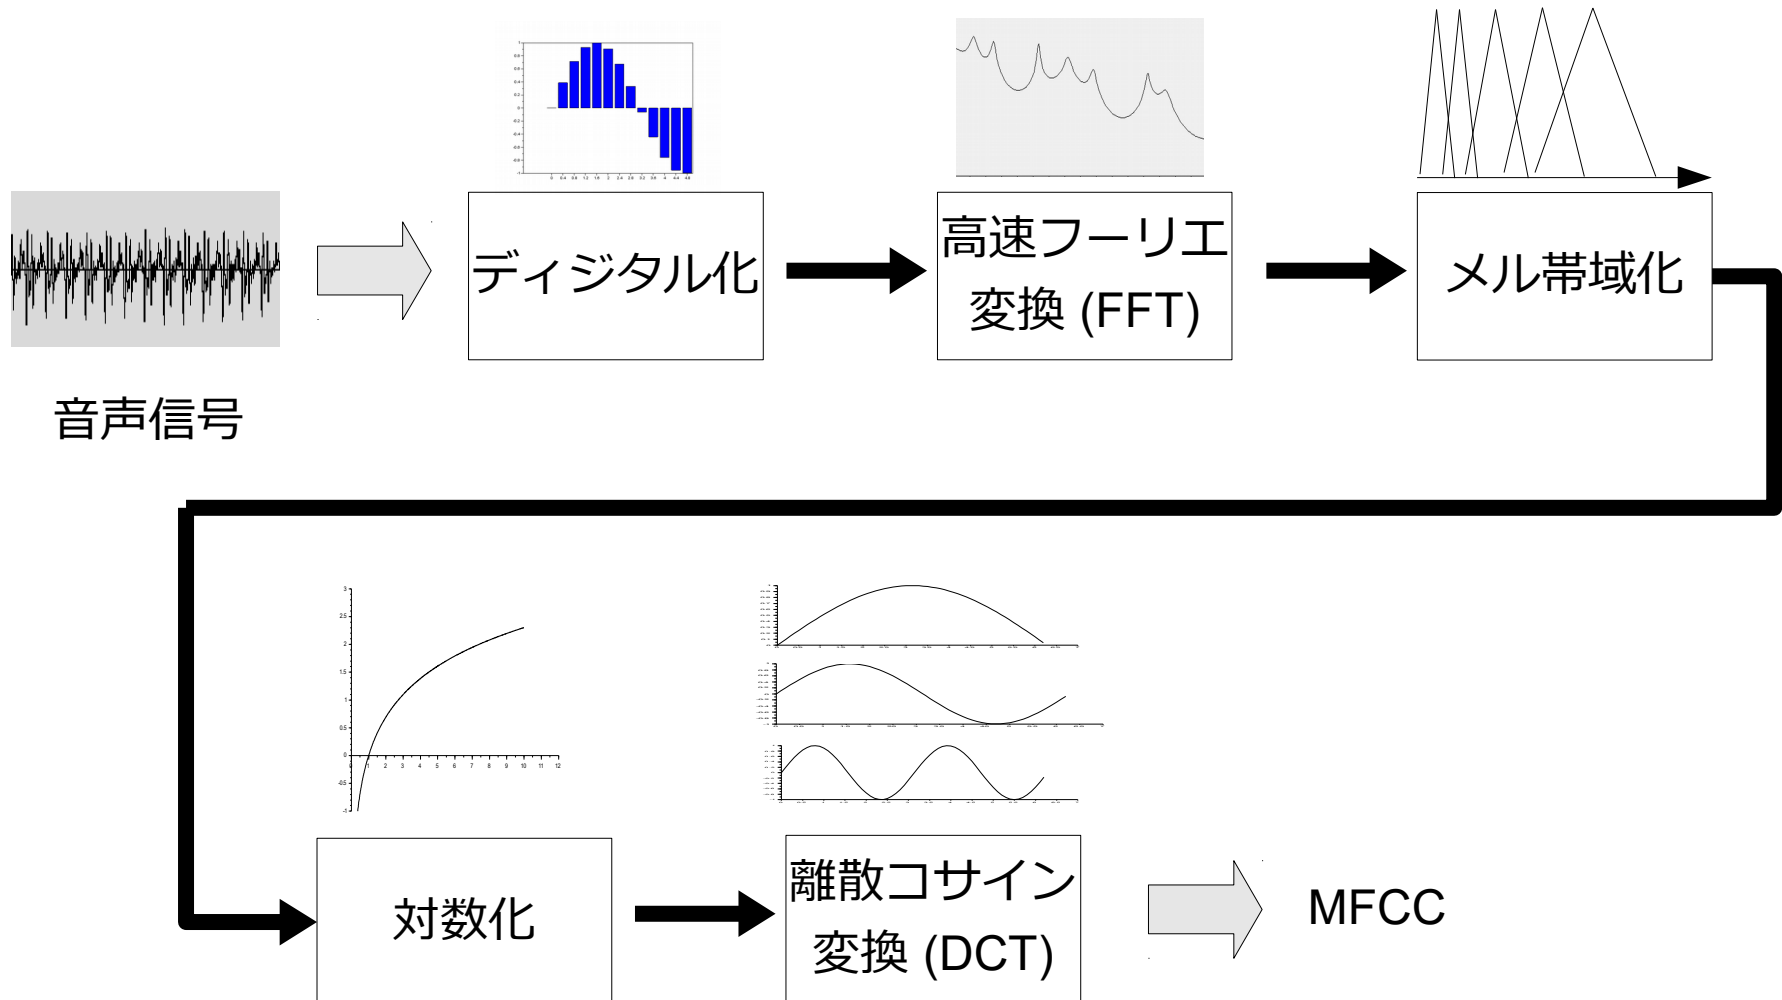
3.1.1 音声の場合



(b) 日本語母音識別のための特徴空間 (男性)


3.1.1 音声の場合

- MFCC (Mel Frequency Cepstrum Coefficient)
 - スペクトルの概形情報を抽出




3.1.2 画像の場合


- 画像の変動
 - 明るさの変化, 拡大・縮小, 回転など
- SIFT 特徴量
 - 2枚の画像の対応抽出などに有効



特徴点抽出



スケール・回転吸収




8方向輝度変化計算

→ x
正規化

3.1.2 画像の場合


- Bag of Visual Words
 - SIFT 特徴量の似ているベクトルを単語と見なし、その出現頻度を特徴として分類問題に適用




⋮

⋮


⋮



学習画像セット




SIFT 特徴量



Visual words 抽出

3.2 特徴のスケールを揃える

- 各軸で値のスケールが異なる場合



標準化の必要性

3.2 特徴のスケールを揃える

- スケールの揃え方
 - 特徴空間の単位超立方体の体積を軸伸縮の前後で一定に保ち、かつパターン相互の距離を最小化
→ 各軸の分散を等しくする
- 平均値を 0 にしておくと分析に便利
- 標準化の式

$$x'_i = \frac{x_i - m_i}{\sigma_i} \quad m_i, \sigma_i : \text{軸 } i \text{ の平均、分散}$$

3.3 特徴は多いほどよいか

3.3.1 偶然に見つかってはまずい

(1) 偶然の傾向とは

- 特徴は多いほどよいか
- 特徴が多くデータ数が少ないと、偶然の傾向が現れるかもしれない
 - ▶ 特徴の次元数が高いほど、偶然の傾向が発見される可能性が高い

3.3.1 偶然に見つかってしまっはまずい

(2) 学習に必要なパターン数

- 超平面の容量 $2(d + 1)$
 - $p(n, d)$: d 次元空間上で、適当に配置された n 個のパターンを任意に 2 クラスに分けたとき、超平面により線形分離できる確率

$$n < 2(d + 1) : p(n, d) \sim 1$$

$$n = 2(d + 1) : p(n, d) = 1/2$$

$$n > 2(d + 1) : p(n, d) \sim 0$$

例題 3.2

$$p(4, 1) = 1/2$$

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(a) データの配置

	○	○	○	○	
	○	○	○		×
	○	○	×	○	
	○	○		×	×
	○	×	○	○	
	○	×	○	×	
	○	×	×	○	
	○		×	×	×
	×		○	○	○
	×	○	○	×	
	×	○	×	○	
	×	○	×	×	
	×	×		○	○
	×	×	○	×	
	×	×	×		○
	×	×	×	×	

(b) 二つに分離可能

3.3.1 偶然に見つかってしまっはまずい

(3) 見つかるはずのないものが見つかった？



- $n \gg 2(d+1)$ のとき
 - $p(n, d) \sim 0$
 - もしこの条件で識別面が見つかったとしたら
 - 偶然には存在しえないものが見つかった
 - その識別面は必然的に存在していた

3.2.2 特徴を減らそう

(1) 力業で次元を減らす

→ 全ての組み合わせを評価する

(2) スマートな主成分分析



3.2.2 特徴を減らそう

- 変換行列

- 変換前の特徴空間におけるパターンの共分散行列 Σ の上位 \tilde{d} 個の固有値に対応する固有ベクトルを列とする行列

$$\mathbf{A} = \underbrace{\begin{pmatrix} a_{11} & \cdots & a_{1\tilde{d}} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{i\tilde{d}} \\ \vdots & & \vdots \\ a_{d1} & \cdots & a_{d\tilde{d}} \end{pmatrix}}_{\tilde{d}} \Bigg\} d$$

- 次元数の削減 $\mathbf{y} = \mathbf{A}^t \mathbf{x}$ d次元から \tilde{d} 次元への削減

共分散行列とは

- データの広がりを調べる→共分散行列

- 1次元の場合

平均

$$m = \frac{1}{n} \sum_{i=1}^n x_i$$

分散

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (m - x_i)^2$$

- 多次元の場合

平均ベクトル



$$m = \frac{1}{n} \sum_{\mathbf{x} \in \chi} \mathbf{x}$$

共分散行列

$$\Sigma = \frac{1}{n} \sum_{\mathbf{x} \in \chi} (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^t$$

共分散行列とは

平均・各軸の分散が等しいデータ



共分散行列 $\Sigma = \begin{pmatrix} x\text{の分散} & x\text{と}y\text{の相関} \\ x\text{と}y\text{の相関} & y\text{の分散} \end{pmatrix}$